

UNIVERSIDADE DE SÃO PAULO
FACULDADE DE FILOSOFIA, LETRAS E CIÊNCIAS HUMANAS
DEPARTAMENTO DE LINGUÍSTICA

Andressa Vieira e Silva

**Detecção automática de ironia por meio de
representações contextuais**

São Paulo
2025

ANDRESSA VIEIRA E SILVA

**Detecção automática de ironia por meio de
representações contextuais**

VERSÃO CORRIGIDA

Tese apresentada ao Programa de Pós-Graduação em Linguística do Departamento de Linguística da Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo para obtenção do título de Doutor em Letras.

Orientador: Prof. Dr. Marcos Lopes

São Paulo
2025

Autorizo a reprodução e divulgação total ou parcial deste trabalho, por qualquer meio convencional ou eletrônico, para fins de estudo e pesquisa, desde que citada a fonte.

Catálogo na Publicação
Serviço de Biblioteca e Documentação
Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo

S586d Silva, Andressa Vieira e
Detecção automática de ironia por meio de
representações contextuais / Andressa Vieira e Silva;
orientador Marcos Fernando Lopes - São Paulo, 2025.
196 f.

Tese (Doutorado)- Faculdade de Filosofia, Letras e
Ciências Humanas da Universidade de São Paulo.
Departamento de Linguística. Área de concentração:
Semiótica e Linguística Geral.

1. IRONIA. 2. LINGUÍSTICA COMPUTACIONAL. 3.
PRAGMÁTICA. 4. EMOÇÕES. I. Lopes, Marcos Fernando,
orient. II. Título.

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 88887.669477/2022-00

This study was financed in part by the Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Finance Code 88887.669477/2022-00

Agradecimentos

Essa pesquisa não se concretizaria sem a ajuda de diversas pessoas que acompanharam meus passos ao longo desses quatro anos, tanto academicamente quanto na minha vida pessoal. Primeiramente, agradeço à minha família por todo o apoio moral e emocional, pelos pequenos atos de cuidado para que eu não adoecesse e pelos momentos em que eles acreditaram em mim e me motivaram a continuar mesmo quando eu estava cansada demais. À minha tia Mazé, que mesmo à distância acompanha meu trajeto acadêmico e está sempre à disposição com uma palavra amiga. Obrigada por ser minha leitora mais entusiasta e me encher de elogios e dicas valiosas.

Agradeço a todos os meus professores pelos ensinamentos que me passaram e que, pouco a pouco, despertaram meu interesse pela pesquisa. Deixo um agradecimento especial a Paula, da qual fui monitora durante o Doutorado, por suas sugestões e bibliografias que me deram ajuda na caracterização de ironia e por suas aulas incríveis de leitura e escrita acadêmica que me ensinaram muito. Ao professor Thigo Pardo, aprendi várias técnicas de anotação de corpus no seu curso de Processamento de Língua Natural, obrigada por isso e pelas sugestões que você levantou durante a minha qualificação. Também não poderia deixar de mencionar o professor Marcelo Ferreira, que participou de todas as minhas qualificações e defesas, quero agradecer-lo pelas cutucadas e provocações que me fizeram repensar diversos aspectos desta pesquisa e adotar uma nova perspectiva sobre a ironia. Ao meu orientador, Marcos Lopes, que me guiou nesse universo chamado de “carreira acadêmica”, que nem sempre é um lugar gentil ou fácil. Fico grata por você ter me acompanhado desde a iniciação científica até o Doutorado e por tudo o que

me ensinou nesses anos com uma tranquilidade inabalável que me trouxe confiança para que eu continuasse nesse percurso.

Também gostaria de agradecer aos meus colegas Rodrigo, Ana Rosa e Giulia que disponibilizaram seu tempo para me ajudar na anotação manual do meu corpus, ainda devo uma bebida a vocês.

Por fim, mas não menos importante, quero agradecer ao ATEEZ por suas músicas que me acompanharam durante a escrita desta tese me trazendo um pouco de forças quando me faltava e me lembrando que é preciso muita determinação para alcançar seus objetivos.

Resumo

A ironia é um fenômeno complexo que se manifesta em formas e contextos variados para indiretamente expressar uma gama de sentimentos, atitudes e opiniões. A interpretação de uma declaração irônica está fortemente ligada a aspectos extralinguísticos, como a intimidade entre os envolvidos no diálogo, o conhecimento de normas de interação social e de mundo e o contexto em que ela foi produzida. Na Linguística Computacional, a ironia é abordada como uma tarefa de classificação automática de um texto em irônico ou não-irônico. Devido à dependência de aspectos extralinguísticos para a sua interpretação, a Detecção Automática de Ironia é uma tarefa difícil de resolver. Além disso, essa tarefa é aplicada sumariamente em textos escritos, portanto pistas advindas da entonação da voz e da expressão facial, presentes em interações cara-a-cara, estão ausentes. Alguns recursos de escrita, como a utilização de aspas, caixa alta e expressões de riso, podem servir de indicações de ironia. Todavia, apesar de úteis do ponto de vista da aplicação, esses marcadores nem sempre estão presentes e são pistas muito rasas que não dão conta do fenômeno da ironia. A presente pesquisa tem como objetivo caracterizar as formas de identificação de uma ironia em rede social a partir de uma abordagem linguístico-computacional. Tomando-a como uma implicatura conversacional, propomos que a interpretação de uma ironia depende de aspectos contextuais, principalmente quando não há evidências linguísticas de sua presença.

A primeira etapa desta pesquisa foi a produção de um corpus de ironia em português composto de conversas da rede social X (anteriormente Twitter). A partir de uma análise do corpus, identificou-se sete traços linguísticos baseados em pistas de ironia, marcações de citações, dissimilaridades do texto com seu contexto conversacional, desconexões sintático-semânticas entre partes do

texto e conflitos de sentimentos que podem fornecer pistas relevantes para a ironia. Com base nesses traços, propomos a ConvContextual+traços, um modelo de rede neural convolucional para a Detecção de Ironia treinada a partir de textos e seus respectivos contextos conversacionais que combina traços manuais linguísticos em sua arquitetura. Os resultados obtidos pelo modelo mostram que a ConvContextual+traços supera os resultados de uma rede neural que recebe como entrada apenas os textos, comprovando a influência da informação contextual na tarefa. Além disso, a inserção dos traços manuais melhoraram a precisão na classe de ironia em 4% em comparação ao modelo sem os traços. Ao mesmo tempo, os traços causaram uma perda na cobertura, o que indica que eles tornaram o modelo muito especializado. Por fim, a análise de erros revelou que muitos dos exemplos classificados erroneamente pelo modelo eram aqueles que dependiam fortemente de conhecimento de mundo e a respeito do autor do texto, os quais também costumam ser os mais desafiadores para os anotadores humanos.

Palavras-chave: Ironia, Detecção Automática de Ironia, Linguística Computacional, Redes sociais.

Abstract

Irony is a complex phenomenon that manifests in various forms and contexts to indirectly express a range of feelings, attitudes, and opinions. The meaning of an ironic statement is strongly tied to extralinguistic aspects, such as the intimacy between the participants in the dialogue, knowledge of social interaction norms and world knowledge, and the context in which it was produced. In Computational Linguistics, irony is addressed as a task of automatically classifying a text as ironic or non-ironic. Due to its reliance on extralinguistic aspects for interpretation, Automatic Irony Detection is a challenging task to solve. Furthermore, this task is primarily applied to written texts, so cues from voice intonation and facial expressions, which are present in face-to-face interactions, are absent. Some writing aspects, such as the use of quotation marks, uppercase letters, and laughter expressions, can serve as indications of irony. However, even though they may be useful from an application perspective, these markers are not always present and they are very superficial clues that do not fully address the phenomenon of irony. The present research aims to characterize the ways of identifying irony on social media from a linguistics-computational approach. Considering it as a conversational implicature, we propose that the interpretation of irony depends on contextual aspects, especially when there is no linguistic evidence of its presence.

The first step in this research was the production of a corpus of irony in Portuguese, composed of conversations from social media platform X (formerly Twitter). From an analysis of the corpus, seven linguistic features based on irony cues were identified, including quotation marks, dissimilarities between the text and its conversational context, syntactic-semantic

disconnections between parts of the text, and conflicts of feelings that could provide relevant clues for irony. Based on these features, we propose the ConvContextual+features, a convolutional neural network model for Irony Detection trained from texts and their respective conversational contexts that combines manual linguistic features into its architecture. The results obtained by the model show that ConvContextual+features outperforms a neural network that receives only the texts as input, proving the influence of contextual information in the task. Additionally, the inclusion of manual features improved the precision of the irony class by 4% compared to the model without the features. At the same time, the features caused a loss in recall, indicating that they made the model too specialized. Finally, the error analysis revealed that many of the examples incorrectly classified by the model were those that heavily depended on world knowledge and knowledge of the author of the text, which are also typically the most challenging for human annotators.

Palavras-chave: Irony, Irony Detection, Computational Linguistics, Social media.

Sumário

1	Introdução	1
1.1	Interesses de Pesquisa	4
1.1.1	Objetivos	6
1.2	Justificativa	7
1.3	Organização desta pesquisa	8
2	A ironia	10
2.1	Delimitação do objeto de estudo	10
2.2	Definições de ironia	11
2.3	A ironia como um fenômeno contextualizado	15
2.4	Definição de ironia adotada nesta pesquisa	19
3	Abordagens computacionais	21
3.1	Processamento de Língua Natural	21
3.2	Primeiras formalizações em Detecção de Ironia	24
3.3	Modelagem para Detecção de Ironia	27
3.3.1	Modelos baseados em regras	28
3.3.2	Modelos de aprendizado de máquina	29
3.4	Inserção de conhecimento contextual	32
4	O papel das emoções para a ironia	34
4.1	Análise de Emoção Textual	35
4.1.1	Modelos de emoções	36
4.2	Técnicas de análise de emoções	40
4.3	Análise de emoções em emojis	42

4.4	As relações entre emoções e ironia	46
5	Elaboração de um corpus de ironia	50
5.1	Conceitos gerais de corpora de ironia	51
5.1.1	Corpora de ironia em português	52
5.2	Coleta de dados para o corpus	53
5.3	Anotação manual do corpus	57
5.4	Estatísticas do corpus	64
6	Arcabouço teórico dos modelos computacionais	68
6.1	Representações vetoriais de palavras	68
6.2	Rede neural convolucional	70
6.2.1	Breve histórico das redes convolucionais	70
6.2.2	Estrutura da rede convolucional	71
6.2.3	Parâmetros da rede convolucional	72
6.2.4	Redes convolucionais em PLN	74
7	Implementação de um modelo para detecção de ironia	76
7.1	Pré-processamento do corpus	76
7.1.1	Limpeza dos dados	76
7.1.2	Tokenização do texto	77
7.1.3	Separação do exemplo em categorias	78
7.1.4	Tratamento de abreviações	78
7.1.5	Substituição de marcas de riso	79
7.1.6	Correção de palavras	79
7.1.7	Remoção de palavras desconhecidas	80
7.1.8	Tratamento de <i>hashtags</i>	81
7.2	Análise de Emoções	83
7.2.1	Modelo de Análise de Emoções textual	83
7.2.2	Corpus de emoções de emojis	87
7.3	Traços do modelo de classificação de ironia	89
7.3.1	Vetor textual	89
7.3.2	Vetor de traços manuais	89
7.3.3	Vetor de traços emotivos	96

7.4	Arquitetura do modelo	96
7.4.1	Rede convolucional	97
7.4.2	Rede de traços	98
7.4.3	Rede de classificação	99
7.4.4	Parâmetros de treinamento do modelo	99
8	Discussões dos resultados	100
8.1	Avaliação do modelo de emoções	100
8.1.1	Análise de erros da classificação de emoções	104
8.2	Validação dos traços manuais para a tarefa de ironia	108
8.2.1	Avaliação dos traços manuais em um modelo	115
8.3	Validação das representações de palavras	120
8.4	Impacto dos traços para o modelo	123
8.5	Comparação dos métodos avaliados	128
8.6	Investigação dos n-gramas ativados pela rede	131
8.7	Análise de erros do modelo	139
9	Conclusões	145
9.1	Contribuições desta pesquisa	145
9.2	Trabalhos futuros	148
	Referências	150
	Apêndices	167
	Apêndice A Manual de Anotação	168
A.1	Manual de Anotação do corpus TwIronia	168
A.1.1	Ironia: definição e exemplos	169
A.1.2	Não-ironia: definição e exemplos	171
A.1.3	Instruções para anotação	173
	Apêndice B Lista de abreviações	175
	Apêndice C Traduções para as emoções de Plutchik	177
C.0.1	Emoção: Anger	177

C.0.2	Emoção: Anticipation	177
C.0.3	Emoção: Disgust	177
C.0.4	Emoção: Fear	178
C.0.5	Emoção: Joy	178
C.0.6	Emoção: Sadness	178
C.0.7	Emoção: Surprise	179
C.0.8	Emoção: Trust	179

Lista de Figuras

4.1	Representação da Roda de emoções de Plutchik.	38
4.2	Exemplo de definições extraídas da Emojipedia.	45
4.3	Exemplo do uso de emoji em um texto irônico.	47
5.1	Exemplo de uma <i>thread</i> extraída do X.	56
5.2	Fragmento da planilha do corpus usada para anotação.	58
5.3	Distribuições gerais do corpus.	64
5.4	Estatísticas de palavras, hashtags, emojis e menções mais frequentes.	66
6.1	Exemplo de uma arquitetura básica de uma rede neural convolucional para texto.	73
7.1	Arquitetura da rede neural proposta para a classificação de ironia.	97
7.2	Arquitetura da rede convolucional para o pré-processamento textual.	98
8.1	Distribuição de etiquetas no corpus anotado para classificação de emoções.	101
8.2	Matriz de confusão de classificação de emoções.	104
8.3	Distribuição dos traços no corpus.	109
8.4	Distribuição dos traços no corpus.	110
8.5	Distribuição dos traços por etiqueta.	112
8.6	Valor médio dos valores assumidos por cada traço por etiqueta.	114
8.7	Relevância dos traços manuais para a decisão do modelo.	116

8.8	Validação das representações de palavras em 10 rodadas. . . .	120
8.9	Validação das representações de palavras para a categoria de ironia.	121
8.10	Validação dos traços no desempenho do modelo.	123
8.11	Validação dos traços no desempenho do modelo para a categoria de ironia.	124
8.12	Comparação do desempenho geral dos modelos.	130
8.13	Exemplo 1 das ativações dos filtros de um texto irônico e seu contexto.	132
8.14	Exemplo 2 das ativações dos filtros de um texto irônico e seu contexto.	133
8.15	Matriz de confusão para a ConvContextual+traços em uma rodada aleatória.	140
A.1	Exemplo da tabela de anotação.	173
A.2	Exemplo de anotação em caso de dúvida.	174

Lista de Tabelas

5.1	Palavras-chave usadas na coleta.	55
5.2	Comparação entre a anotação manual e a anotação por <i>hashtag</i>	61
7.1	Exemplos de textos antes e após a tokenização.	77
7.2	Exemplos de tokenização de <i>hashtags</i>	83
7.3	Tabela de traduções para as emoções de Plutchik.	85
7.4	Amostra do corpus de emoções de emojis.	88
8.1	Avaliação da classificação de emoções.	102
8.2	Avaliação da classificação de emoções multi-labels.	104
8.3	Estatísticas para os traços manuais no corpus.	109
8.4	Desempenho da árvore de decisão treinada com os traços manuais.	116
8.5	Desempenho do modelo com os traços individuais e combinados.	118
8.6	Teste U para avaliar a significância dos traços.	126
8.7	Teste U aplicado sobre a precisão e a cobertura nos modelos com os traços manuais.	127
8.8	Comparação dos modelos avaliados para classificação de ironia.	128
8.9	Agrupamentos dos n-gramas gerado pelo método K-means.	135
8.10	Comparação da anotação de trecho irônico por um humano e pelo modelo.	137
B.1	Lista de abreviações e suas respectivas transcrições.	176

1 | Introdução

A ironia é um recurso discursivo recorrente em nossas interações cotidianas, podendo ser usada para diversos fins, como humor, reprovação de uma ideia ou atitude, deboche, estratégia de argumentação etc. Apesar disso, os mecanismos envolvidos na produção e na compreensão de uma ironia não são triviais, pois envolvem diferentes condições externas à língua, como o contexto conversacional, o conhecimento compartilhado entre os envolvidos, o conhecimento de mundo e as habilidades retórico-argumentativas.

Imagine-se uma situação em que dois amigos combinam de sair e um deles se atrasa, ao que o outro comenta “Você é muito pontual”, o sentido irônico só fica evidente por causa do conhecimento compartilhado entre os dois, isto é, o horário previamente combinado. Em uma conversa, o que foi dito no turno anterior pode ser o contexto conversacional para a compreensão de uma ironia. Um exemplo, um grupo de alunos está conversando a respeito de suas impressões sobre uma colega nova da turma em que um deles diz “Ela é legal”, recebendo como resposta de outro colega “Uma pessoa maravilhosa de boca fechada”. Nesse exemplo, a ironia revela a opinião de alguém que parece não gostar da pessoa em questão, sendo construída no próprio diálogo.

A ironia, se mal compreendida (se tomada por seu sentido literal, por exemplo), pode ser ofensiva e pôr em risco a imagem do ironista. Contudo, mesmo com toda a complexidade envolvida e riscos de má interpretação, as pessoas continuam sendo irônicas, o que chama ainda mais a atenção para o fenômeno.

Ao longo dos anos, várias áreas de pesquisa se interessaram em estudar a ironia, como a Retórica, a Linguística, a Psicologia e as Ciências Cognitivas, cada qual trazendo um ponto de vista próprio para analisá-la. Recentemente,

a área de Processamento de Língua Natural (PLN) mostrou interesse em tratar o fenômeno de ironia do ponto de vista da aplicação computacional. Isso se deve principalmente ao crescimento dos ambientes online de redes sociais, como Facebook e X (previamente Twitter), que fornecem um espaço para que os usuários compartilhem suas emoções, opiniões e pensamentos.

As redes sociais estão sendo muito exploradas para a análise linguística, seja de cunho manual ou computacional. Elas são um ambiente rico para a investigação de ironia, que aparece frequentemente nos diálogos online, principalmente em determinados assuntos, como Política e Humor. Os desafios para uma pesquisa sobre ironia em redes sociais divergem daqueles enfrentados em pesquisas teóricas sobre o tema, uma vez que a língua posta em prática apresenta suas próprias características a serem estudadas, ainda mais em redes sociais, em que o uso de linguagem informal e gírias é mais frequente.

Uma das dificuldades de classificação de ironia em redes sociais é a compreensão da mensagem, pois as referências e os pressupostos que a construíram podem não ser evidentes para o público geral por dependerem de conhecimentos sobre crenças e preferências do ironista ou eventos e pessoas desconhecidos. Em um diálogo cara-a-cara, o público do ironista é conhecido e restrito, mas em redes sociais a mensagem pode chegar a pessoas que não compartilham os mesmos conhecimentos com o locutor e, portanto, não compreendem o seu significado. Esse é um obstáculo tanto para a anotação de corpora quanto para a classificação por máquinas e não há uma resposta para resolvê-lo. Outra complexidade envolvida na tarefa é a associação do conteúdo do texto aos conhecimentos de mundo e de senso comum. Por exemplo, a interpretação do texto “Perdi o voo, que maravilha!” como irônica pressupõe que o modelo saiba que “perder o voo”, em geral, não é algo bom. No texto “Na Black Friday, os preços vão de 3.000,00 para 2.999,99, ótimas promoções!”, é preciso compreender que a diferença entre os preços citados é insignificante, o que não se encaixa no sentido de “promoção”. A inserção desse tipo de conhecimento aberto é muito difícil de codificar em um modelo computacional, envolvendo acesso a base de dados ou fontes externas de consulta e, mesmo assim, é improvável esperar que todos os conhecimentos de mundo estejam acessíveis. Por fim, as pesquisas em PLN analisam sumariamente a ironia pela língua

escrita e não falada, o que já é um desafio por si só, dado que muitas pistas do uso irônico são perdidas, entre elas as expressões faciais, gestos e entonação de voz que podem ajudar na detecção de ironia.

Alguns aspectos irônicos podem ser sinalizados em texto escrito através de palavras em caixa alta, aspas e emojis, por exemplo. Essas informações não estão relacionadas ao significado do texto em si, mas são mecanismos usados para expressar alegria, raiva, excitação, indignação, entre outros. Em uma abordagem computacional, essas informações podem ser úteis para a identificação de uma ironia. Todavia, isoladamente, elas são pistas muito superficiais. Uma análise mais completa envolveria dados a respeito do contexto conversacional do texto: onde ele foi postado, se há citação de fontes, se ele está inserido em uma conversa entre vários usuários etc. Portanto, tanto aspectos do texto quanto do contexto são relevantes para direcionar a investigação de ironia em redes sociais.

Nesta pesquisa, buscamos entender a dinâmica de utilização de ironia na rede social X a partir de uma abordagem linguístico-computacional baseada no contexto conversacional. Partimos do pressuposto de que o significado da ironia está implícito em seu contexto de produção (ATTARDO, 2000), portanto analisá-la envolve a compreensão do máximo de pistas e informações contextuais disponíveis. Como esse é um tema recente, fez-se um levantamento de características linguísticas, como os marcadores textuais de ironia, mais usadas por usuários de redes sociais a partir de um corpus linguístico de mensagens irônicas e não-irônicas coletadas do X. A investigação de traços nos levou a um conjunto de sete características (Pistas de ironia, Citação, Oposição dos Sujeitos, Impertinência externa, Impertinência interna, Conflito de sentimentos e Conflito de emoções) que foram validadas em termos de frequência e pertinência para a ironia.

Além do estudo linguístico, fez-se a avaliação de métodos computacionais promissores para o reconhecimento de textos irônicos em língua portuguesa, buscando por pistas de classificação no texto e no contexto interacional. Para a classificação de ironia, propomos uma rede neural convolucional contextual baseada em traços emotivos e manuais linguisticamente motivados. Esse

modelo foi treinado e testado no corpus desenvolvido e comparado a quatro abordagens computacionais.

1.1 Interesses de Pesquisa

A ironia, um fenômeno tipicamente analisado dentro de um contexto conversacional cara-a-cara, apresenta muitas características distintas quando colocada em análise dentro das redes sociais. Uma das primeiras diferenças notáveis é a presença de determinadas marcas que rotulam os textos como irônicos, como as famosas *hashtags*, que podem ser usadas pelos usuários quando se quer evidenciar a presença de ironia. Apesar de não ser obrigatória, essa auto-rotulagem foge do que é comum na produção de ironia em português. Quando alguém faz uma ironia, dificilmente a pessoa dirá algo como “estou sendo irônico”, exceto em situações em que ela tenha sido interpretada incorretamente e queira corrigir o erro.

Essa auto-rotulagem encontrada em redes sociais ajuda muito na coleta de dados para a criação de corpora de ironia, uma vez que é preciso apenas uma busca por textos em que *hashtags* irônicas estão contidas para saber a sua classificação. Contudo, Khodak, Saunshi e Vodrahalli (2018) já mostraram que a auto-rotulagem não é confiável e pode apresentar divergências quando comparada a uma revisão manual. Isso mostra que ou as *hashtags* estão sendo usadas incorretamente pelos usuários ou estão corretas mas adquirem outro significado de uso dentro da rede. Na primeira hipótese, os usuários pensariam que estão sendo irônicos quando não estão, o que indicaria que eles não sabem exatamente como produzir uma ironia. Na segunda, a *hashtag* seria sinalizadora de outros fenômenos além de ironia. Desse modo, um dos interesses desta pesquisa é analisar as *hashtags* irônicas usadas em português para a rede social X com o intuito de verificar se elas são marcas classificadoras de ironia confiáveis ou não.

Mesmo de posse de grandes corpora textuais, a tarefa de Detecção de Ironia está se mostrando desafiadora em PLN devido à dificuldade de recuperação de informações a respeito do contexto que ajudem a determinar a classificação do texto. De acordo com Wallace, Kertz, Charniak et al. (2014), anotadores

humanos mostraram a necessidade do contexto de produção para a anotação de um corpus irônico para cerca de 30% dos exemplos anotados. Os autores ainda identificaram uma correlação entre os exemplos em que os anotadores tiveram dificuldades e os erros cometidos pelo modelo computacional.

A codificação de contexto para a implementação de modelos computacionais se baseia sumariamente em dois eixos: comunicador e conversação. No contexto do comunicador estão inseridas opiniões, preferências, hobbies e crenças, por exemplo. Alguns desses dados pessoais podem ser fornecidos pelo próprio usuário em seu perfil ou inferidos a partir do seu histórico de postagens. Contudo, o perfil do X não é uma fonte confiável e consistente, pois cada usuário insere as informações que deseja. Ademais, é preciso considerar que esses são dados individualizados e complexos, portanto difíceis de trabalhar.

Nesse sentido, focamos em aspectos baseados na análise do texto em seu contexto conversacional. Um de nossos interesses em investigar o contexto de produção era avaliar quais pistas contextuais contribuem para a interpretação de uma ironia. Levantou-se a questão: será que sem o contexto a interpretação de ironia seria perdida ou ela estaria contida no próprio texto, sendo o contexto apenas uma forma de corroborá-la? Partimos da hipótese de que o contexto é relevante, principalmente quando as pistas de ironia textuais, como emojis, aspas e marcas de exagero, estão ausentes. Sendo assim, os tipos de ironia mais difíceis seriam aqueles embasados em conhecimentos do contexto do comunicador, em que não temos acesso às informações.

Outros interesses que nos guiaram a uma análise baseada em contexto foi a chance de investigar o posicionamento dos sujeitos envolvidos na construção da ironia. Tendo em vista que as redes sociais são ambientes muito polarizados, esperávamos que a ironia apareceria muito mais em contextos de conflito entre os sujeitos, ou seja, quando eles estavam em lados opostos, como uma forma de diminuir ou zombar do outro. Essa hipótese estaria alinhada à ideia de [Wilson e Sperber \(1992\)](#) de que a ironia demonstra uma atitude de desaprovação em relação ao que está sendo dito. Portanto, ao usar a ironia, o usuário estaria demonstrando o quanto despreza e se afasta de seu sentido literal e dos ideais defendidos pelo outro.

1.1.1 Objetivos

O objetivo principal desta pesquisa é investigar textos irônicos produzidos em ambiente online a fim de identificar aspectos textuais e contextuais associados à ironia. Nossa hipótese é que a ironia é marcada por incongruências que ajudam a identificá-la a partir de dois padrões: (1) a incongruência entre partes do texto ou entre o texto e o contexto; (2) o conflito de emoções entre partes do texto ou entre o texto e o contexto. Desse modo, pressupõe-se que a construção do texto irônico tem suas próprias particularidades que podem ser inferidas a partir do contexto interacional.

Outras pesquisas já investigaram formas de inserir o contexto conversacional em modelos de Detecção de Ironia (WALLACE; CHARNIAK et al., 2015; SRIVASTAVA et al., 2020; GHOSH; FABBRI; MURESAN, 2018), sendo esse um gancho de pesquisa que está apenas começando. Neste trabalho, classificaremos textos inseridos em um nicho conversacional, coletando a mensagem alvo e aquela que a antecede, semelhante ao que foi proposto por Ghosh, Fabbri e Muresan (2018), em que os autores propuseram um classificador que recebia como entrada o texto-alvo, a mensagem anterior e a seguinte. Porém, diferente do trabalho citado, esta pesquisa também investigará a inserção de traços manuais baseados em padrões linguísticos na tentativa de guiar o modelo e enriquecer o seu conhecimento. Portanto, uma das contribuições desta pesquisa será a apresentação de um modelo de classificação para ironia com base no contexto interacional e em padrões linguisticamente motivados para a língua portuguesa.

Além da inserção do contexto interacional, exploraremos elementos textuais e emojis para analisar as emoções transmitidas pelo texto e pelo contexto, como “raiva”, “tristeza” e “alegria”. Nesse cenário, os emojis funcionam como substitutos das expressões faciais. O papel das emoções é crucial na ironia, já que revela a disjunção entre o que é dito e como o usuário se sente em relação àquilo. A análise das emoções na produção de ironia será um aspecto essencial deste trabalho, tendo potencial de contribuir com pesquisas futuras interessadas tanto em ironia quanto em outros tipos de mineração de dados.

Pontualmente, os objetivos de pesquisa são:

- Levantar os aspectos textuais e contextuais marcadores de ironia.
- Elaborar um corpus baseado no contexto conversacional a partir do X.
- Testar métodos computacionais para a classificação de ironia.
- Investigar a influência do contexto para a interpretação de uma ironia.

1.2 Justificativa

A comunicação verbal face-a-face apresenta inúmeras diferenças quando comparada a interações virtuais. No caso da ironia, diversas pistas paralinguísticas e contextuais podem ser perdidas em textos escritos. A maioria das pesquisas em Linguística sobre ironia tem se voltado para o seu uso falado, portanto não se sabe ao certo o quanto a ausência de determinadas pistas pode afetar na compreensão da ironia pelo público. Pesquisas como esta são importantes para abrir espaço para investigações linguísticas em meios virtuais e fornecer uma discussão a respeito das estratégias utilizadas para suprir as pistas contextuais e paralinguísticas em construções irônicas escritas.

Do ponto de vista computacional, a Detecção de Ironia é uma parte essencial na área de Análise de Sentimentos¹, uma vez que a distinção entre comentários irônicos e sinceros é importante na determinação da opinião de um usuário. Segundo Wallace (2013), os textos irônicos são aqueles em que os sistemas de Análise de Sentimentos cometem mais erros, pois o sentimento implícito na ironia difere do sentimento superficial transmitido pelo texto.

Além disso, a ironia é muito usada em redes sociais para a disseminação de conteúdos de discurso de ódio e de notícias falsas. De acordo com Nikunen (2018), a ironia tem sido um dos principais meios de discurso político para atacar grupos raciais, feministas e minoritários. A autora aponta que uma das razões para isso é o fato do discurso irônico “não falar sério”, de modo que pode ser usado para evitar responsabilidade pelo que foi dito, o que tem sido adotado por diversas figuras políticas de extrema direita, como Donald Trump e Geert Wilders. Desse modo, ressalta-se a importância da identificação de

¹Área voltada para a mineração de opinião e sentimento em textos virtuais.

discursos irônicos em redes sociais como uma forma de auxiliar em tarefas de detecção de discurso de ódio.

As pesquisas a respeito de Detecção Automática de Ironia têm crescido e a disponibilidade de recursos computacionais, como corpora e modelos de linguagem pré-treinados, mostra-se ainda mais relevante para o impulsionamento da área. A escassez de corpora anotados em português para a tarefa é uma dificuldade de avanço nessa área. Assim sendo, esta pesquisa fornecerá materiais e uma nova ferramenta de análise para o desenvolvimento de pesquisas futuras nessa área.

1.3 Organização desta pesquisa

Nesta seção, apresenta-se a organização de capítulos do restante desta pesquisa. O Capítulo 2 é dedicado a uma discussão de propostas de definições de ironia partindo de diferentes vias teóricas da Linguística, da Retórica e da Filosofia. Nele também serão apresentadas uma perspectiva de análise em que a ironia é tomada como um fenômeno fortemente dependente de contexto para a sua interpretação e a proposta de definição de ironia aqui adotada. No Capítulo 3, discutem-se técnicas de implementação computacional para a Detecção de Ironia, começando pelas primeiras tentativas de modelagem da tarefa até as abordagens mais modernas e finalizando com uma revisão de métodos que visam a inserção de contexto aos modelos. O Capítulo 4 trata do papel das emoções na ironia, em que serão apresentados dois modelos de classificação de emoções: o de Robert Plutchik e o de Paul Ekman. Esse capítulo também traz uma revisão de materiais e métodos para a classificação de emoções e como esses podem ser úteis na Detecção de Ironia. O Capítulo 5 apresenta a metodologia adotada para a criação do corpus de ironia aqui desenvolvido, o procedimento de anotação manual de parte dos dados e as estatísticas gerais do corpus. No Capítulo 6, apresentam-se os embasamentos teóricos para dois modelos utilizados: as representações vetoriais *word embeddings* e as redes convolucionais. Por sua vez, o Capítulo 7 expõe os métodos de pré-processamento do corpus, a implementação do modelo para a classificação de emoções, os traços manuais e emotivos e a arquitetura do modelo de Detecção

de Ironia. A apresentação e a discussão de resultados vêm no Capítulo 8 e, por fim, seguem-se as conclusões finais e trabalhos futuros no Capítulo 9.

2 | A ironia

A ironia é um fenômeno complexo que se manifesta em formas e contextos variados para indiretamente expressar uma gama de sentimentos, atitudes e opiniões. Este capítulo visa à distinção da ironia de outros fenômenos correlacionados, delimitando o escopo desta pesquisa. Além disso, apresentam-se definições de ironia encontradas na literatura com análises do fenômeno do ponto de vista da Linguística, da Filosofia da Linguagem e da Retórica. O capítulo prossegue com uma análise da ironia como um fenômeno contextualizado, em que se apresentam argumentos em defesa de uma interpretação do sentido irônico a partir de pressuposições e conhecimentos que só podem ser acessados com alguma informação contextual. Por fim, dá-se a definição de ironia aqui proposta.

2.1 Delimitação do objeto de estudo

A literatura aponta a existência de mais de um tipo de ironia: a verbal e a situacional. De acordo com [Attardo \(2000\)](#), a ironia verbal é um fenômeno linguístico, enquanto a situacional é um estado do mundo que é percebido como irônico, tal como uma estação de bombeiros pegando fogo. Existem outras possibilidades de classificação, como entre ironia verbal, ironia do destino e ironia dramática apresentada por [Haverkate \(1990\)](#), mas todas consideram a existência da ironia verbal, aquela expressa por meio de uma língua natural. Nesta pesquisa, estamos interessados somente na ironia verbal, portanto os demais tipos não serão analisados.

Além disso, é preciso estabelecer os paralelos entre a ironia e outro fenômeno associado a ela, o sarcasmo. Não há consenso na literatura a respeito das distinções entre sarcasmo e ironia, sendo que alguns pesquisadores propõem que não há distinção significativa entre eles. Attardo (2000) postula que o sarcasmo é um tipo mais agressivo de ironia, com marcadores e alvo evidentes. Desse ponto de vista, o sarcasmo seria mais arriscado à imagem de quem o produz, com maiores chances de receber uma resposta negativa. Mesmo considerando esses apontamentos, não faremos uma separação entre ironia e sarcasmo, de modo que os dois serão abordados como um único fenômeno.

Uma das justificativas para essa escolha é o escopo desta pesquisa como uma análise de língua escrita em vez de falada. Em interações cara-a-cara, os aspectos do sarcasmo podem ser evidenciados com um tom de voz forçado, uma expressão de descaso etc. Porém, quando partimos para o texto escrito, muitos desses traços não são replicados. Isso faz com que a distinção entre sarcasmo e ironia seja ainda mais difícil de detectar. Dito isso, usaremos o termo “ironia” para referir ao fenômeno mais amplo da ironia verbal, englobando ironia e sarcasmo nesse universo.

2.2 Definições de ironia

Kaufer (1977) discute como na Antiguidade Clássica a ironia era vista como um tipo de figura de linguagem, assim como a metáfora e a metonímia, sumariamente um recurso de argumentação sofisticado. Ela era definida como uma oposição entre um sentido literal e um figurativo. A partir do final do século XVIII, essa perspectiva foi sendo repensada e o fenômeno da ironia adquiriu novos significados.

Um dos pensadores mais célebres a tratar da ironia na área de Filosofia da Linguagem foi o filósofo Paul Grice. Grice (1975) aborda a ironia no âmbito de implicaturas conversacionais, isto é, significados implícitos que necessitam de uma interpretação além do que foi dito. O autor propõe que as implicaturas são produzidas a partir da quebra de uma ou mais das quatro Máximas estabelecidas por ele: Qualidade, Quantidade, Relevância e Modo.

Em sua discussão sobre as Máximas, Grice fornece um exemplo de ironia em que o sujeito, ao ter a confiança traída por um amigo próximo, diria algo como “Ele é um bom amigo”, desencadeando a quebra da Máxima de Qualidade. De acordo com essa Máxima, é esperado que o falante diga algo em que acredita, portanto ela seria violada em declarações irônicas, já que o sentido literal delas não é aquele em que o falante acredita. Grice reforça que essa quebra seria evidente para a audiência e que o ironista saberia que todos estariam cientes disso.

Todavia, assumindo o Princípio de Cooperação¹, é necessário considerar que o falante quebra essa Máxima intencionalmente para implicar algo que não está contido no significado literal. Assim sendo, deve haver outra proposição relacionada à primeira que está sendo transmitida. Grice sugere que essa seria uma relação de contradição com o sentido literal da proposição dita. Portanto, a aparente quebra da Máxima de Qualidade na verdade dispararia uma implicatura conversacional desencadeada pelo contexto, gerando a interpretação de ironia.

A construção de ironias por meio da quebra das Máximas griceanas foi analisada por outros autores posteriormente. Attardo (2000) aponta que a quebra de qualquer uma das Máximas pode implicar uma ironia. Dada uma situação em que uma professora pede a um professor referências sobre um aluno para saber se deve aceitá-lo como monitor e o segundo responde: “Ele sabe fazer bolinhos de chuva muito bem”, tem-se uma quebra da Máxima de Relevância que desencadeia uma ironia com a interpretação de que esse não é um bom aluno. Dessa forma, a ironia não está restrita à quebra da Máxima de Qualidade.

Por sua vez, Dan Sperber e Deirdre Wilson (WILSON; SPERBER, 1992) argumentam que nem sempre uma ironia significa o oposto do que é dito. Imagine-se um cenário em que um aluno sempre tira notas boas e se gaba para os colegas. Em uma dessas ocasiões, um deles responde “Olha como ele é inteligente!”. Apesar de esse ser um comentário irônico, o contrário

¹O Princípio de Cooperação diz que é esperado que os interlocutores em um diálogo estejam engajados na conversa e contribuam de acordo com as exigências estabelecidas na troca conversacional (GRICE, 1975, p. 45).

de seu sentido literal não corresponde ao sentido implicitado na mensagem. Em outras palavras, não significa que o aluno não seja inteligente, mas uma desaprovação de sua atitude de se gabar para os colegas.

Com isso, Sperber e Wilson (1981) oferecem sua própria teoria a respeito da ironia, propondo que ela seja uma espécie de citação indireta, portanto, a menção de uma proposição. Mencionar é se referir a uma expressão, mas, diferente de uma citação direta, as palavras não precisam ser exatamente as mesmas, apenas devem se assemelhar ao conteúdo da proposição citada. Por causa disso, a teoria deles foi chamada de Teoria Ecóica (SPERBER; WILSON, 1981; WILSON; SPERBER, 1992).

Os autores argumentam que uma declaração irônica ecoa uma atitude de desaprovação do falante em relação ao que está sendo dito, ou seja, as declarações irônicas estão sempre aludindo a uma proposição real ou hipotética. Na Teoria Ecóica, o propósito da ironia é expressar determinada atitude em relação a uma proposição, criando certa impressão no ouvinte. Para lidar com os discursos reportados, tal qual “João disse que a Maria contou a ele que o Pedro saiu de casa”, Sperber e Wilson argumentam que eles se diferenciam da ironia pela atitude transmitida no discurso, o que é dado pelo contexto conversacional.

A Teoria Ecóica traz o aspecto da atitude do falante como ponto central da ironia, além de não pressupor uma necessidade de contradição entre o significado literal e o implicitado. Porém, os autores associam a ironia a uma atitude de desaprovação, o que nem sempre é verdade, uma vez que ela pode expressar um tom lisonjeiro ou piadista, deixando de ter uma característica negativa.

O linguista José Luiz Fiorin apresenta a ironia como uma atitude do enunciador, porém com um ponto de vista distinto de Sperber e Wilson, propondo que os sentidos criados por ela podem ser variados, abrangendo o humor, o desprezo, a zombaria etc. Fiorin define a ironia como “um tropo em que se estabelece uma compatibilidade predicativa por inversão, alargando a extensão sêmica dos pontos de vista coexistentes e aumentando sua intensidade” (FIORIN, 2014, p. 70). Para o autor, existem duas vozes em conflito na ironia em que uma expressa o inverso da outra. Sendo assim, a ironia é

vista como uma relação de oposição entre o que foi dito e que se pretende dizer, semelhante ao ponto de vista de Grice. Contudo, Fiorin engloba mais possibilidades de construções irônicas, pois a extensão de significados não é limitada à contradição ou à quebra de uma Máxima, podendo se dar de diferentes maneiras.

Por sua vez, Attardo (2000) fundamenta sua teoria nas ideias de Grice, ao mesmo tempo que traz pontos que se distanciam delas. O autor propõe que o sentido de uma ironia não está implicitado no texto, sendo parte de seu contexto conversacional em vez de uma contradição com o sentido literal de uma proposição. Attardo argumenta que uma ironia é percebida como uma violação da *adequação contextual*. A adequação contextual é definida como uma compatibilidade entre as pressuposições de uma sentença *u* e as pressuposições do contexto *C* em que ela foi produzida. Por conseguinte, a inadequação contextual ocorre quando uma declaração explícita ou implicitamente viola as condições apropriadas daquele contexto, ao mesmo tempo em que mantém a sua relevância dentro dele.

Attardo também ressalta que a ironia é geralmente utilizada para expressar um julgamento avaliativo sobre algum evento ou situação, mas que ela não é necessariamente negativa. Uma ressalva a ser feita a respeito da teoria de Attardo é que nem sempre uma ironia é inadequada. Pelo contrário, em determinadas situações ela é compatível com as pressuposições do contexto. Em uma apresentação de *stand-up*, por exemplo, o discurso irônico é adequado ao contexto, portanto nem sempre a inadequação é um critério para a ironia.

Já Wallace (2013) fala em incongruência no lugar de inadequação, propondo que a ironia é inferida quando alguém reconhece uma incongruência entre uma declaração e o que é conhecido (ou esperado) a respeito do transmissor da mensagem ou do ambiente, o que ele chama de *contexto pragmático*. O contexto pragmático inclui aquilo que está no conhecimento comum compartilhado entre os interlocutores, como crenças do falante e aspectos do ambiente.

O autor argumenta que somente receptores que compartilham informações suficientes desse contexto serão capazes de detectar a ironia, a não ser que o comunicador reforce outros sinais de alerta no discurso. Contudo, alguém pode

fazer um discurso incongruente com o que é esperado, por desconhecimento das normas sociais daquele contexto ou intencionalmente, sem estar sendo irônico, o que nos leva a crer que outras características são necessárias para uma definição de ironia.

Na área da Retórica, David Kaufer analisa a ironia a partir de sua relação com o seu público alvo. [Kaufer \(1977\)](#) postula que o discurso irônico evoca diferentes níveis de significados associados através de uma operação de negação. Para ele, tal negação pode ser lógica, remetendo a uma contradição de um fato ou a um absurdo no enunciado do falante, ou o que ele chama de *negação fraca*, referente a contradições de crenças ou atitudes esperadas de um falante. Seja como for, essa negação dispara incompatibilidades de significado.

A partir daí, ele identifica dois tipos de públicos potenciais do ironista: aquele que interpreta a ironia como tendo um sentido literal (as vítimas) e aquele que enxerga seu sentido irônico (os aliados), mas essa bifurcação de público não é necessária. Os aliados teriam um conhecimento compartilhado com o ironista que os permitiria detectar a ironia. Entretanto, isso não significa necessariamente uma concordância entre o ironista e seu público a respeito do que está sendo ironizado, isto é, a ironia pode (e é em muitos casos) usada para se contrapor ao que foi dito por outra pessoa. Assim, Kaufer aponta uma dissociação entre o ironista e o que ele diz, o que também faz com que ele se desassocie do público que interpreta a mensagem como literal.

2.3 A ironia como um fenômeno contextualizado

As teorias revisitadas diferem do ponto de vista da análise do fenômeno da ironia, contudo, a importância do contexto conversacional para a sua compreensão aparece em todas elas. A partir dos apontamentos levantados pelos autores, estabeleceremos de que maneira o contexto conversacional contribui para a interpretação de uma ironia com base em quatro aspectos: o

Princípio de Cooperação, as implicaturas conversacionais, as pistas de ironia e a intenção do sujeito.

Segundo Grice (1975), uma conversa é um esforço cooperativo no qual ambas as partes reconhecem um ou mais propósitos e direcionamentos que podem estar fixados desde o começo ou evoluir ao longo do diálogo. Tomando essa cooperação com um princípio conversacional, a aparente quebra de uma ou mais das quatro Máximas griceanas caracterizaria uma implicatura conversacional, isto é, ao enunciar *e*, o interlocutor na verdade quis dizer *e'*. Grice desenvolve o raciocínio que faz o sujeito chegar a tal conclusão a partir dos seguintes fatores: (1) o significado convencional das palavras, (2) a pressuposição de que o Princípio de Cooperação e as Máximas não foram abandonados, (3) o contexto linguístico, (4) o conhecimento prévio e (5) a suposição de que ambos os participantes possuem as informações relevantes para compreender a implicatura.

O processo lógico apresentado por Grice requer conhecimento linguístico (significado convencional das palavras) e não-linguístico (pressuposições dos sujeitos, contexto linguístico e conhecimento prévio). Isso quer dizer que as implicaturas conversacionais não dependem apenas do que é dito, mas do que é inferido sobre o que foi dito. A ideia de cooperação é um ponto de partida essencial para uma análise de ironia, uma vez que presume que os sujeitos envolvidos no diálogo não são receptores passivos das mensagens um do outro, mas estão o tempo todo construindo e descartando hipóteses a respeito de possíveis significados implícitos no diálogo. Desse modo, espera-se o mínimo de engajamento entre os participantes de uma interação para que o receptor seja capaz de perceber uma implicatura irônica.

Nesse sentido, uma implicatura também pode ser usada para avaliar se o seu interlocutor está de fato engajado na conversa. Diga-se que duas pessoas estão em um encontro, mas uma delas não está mostrando interesse na conversa e fica olhando no celular. A segunda pessoa poderia dizer algo como “Tudo bem, eu adoro falar com as paredes”, querendo com isso chamar a atenção da primeira e verificar se ela ao menos ouviu o que foi falado.

A cooperação entre os sujeitos muitas vezes aparece nas sinalizações verbais e não-verbais que fazemos durante um diálogo. Um exemplo da primeira é o

uso de palavras de concordância como “aham”, “sei” e “entendi” e da segunda é a articulação por gestos e expressões faciais. Gumperz (1992) se refere a essas pistas verbais e não-verbais como um processo de “contextualização”. Além de essas pistas indicarem o engajamento no discurso, Gumperz argumenta que elas também têm uma função no processo de inferência em um diálogo, indicando intenções dos participantes, mostrando direcionamentos da conversa, criando expectativas sobre o que vem a seguir e ajudando na desambiguação de significados. Para o autor, essas pistas são dependentes de contexto e seu significado é dado por relação ao que as acompanha.

Essas pistas podem ser de alguma forma canonizadas, como uma entonação exagerada ou a imitação da voz de outra pessoa. Brown e Levinson (1987, p. 222) apresentam um caso interessante de marcação irônica encontrado na língua indígena Tzeltal, em que a ironia é frequentemente indicada por uma partícula que evidencia que os sentimentos do sujeito são contrários ao que ele disse. Esse seria um exemplo de ironia auto-rotulada linguisticamente, mas muitas línguas não possuem marcadores linguísticos irônicos, apenas marcas socialmente convencionadas.

Na ironia, essas sinalizações verbais e não-verbais são uma forma do ironista evitar ser interpretado como literal, incentivando seu receptor a buscar outra interpretação para o que ele está dizendo. Para Brown e Levinson (1987, p. 212), a ironia, a metáfora e as perguntas retóricas são estratégias de preservação de face tipicamente indiretas que se tornam diretas por causa das pistas para a sua interpretação, que, para os autores, vão de entonação e prosódia até o conhecimento mútuo entre os participantes e as pistas derivadas da conversa em curso. Assim, as sinalizações são ainda mais relevantes na ironia, pois protegem a face do ironista, evitando embaraços e desentendimentos que possam ser indesejados.

Esse esforço em ser compreendido está relacionado à intenção do falante de transmitir a mensagem desejada e não outra possível dentro daquele contexto. Como argumentam Wilson e Sperber (1992), as intenções do interlocutor não podem ser codificadas, tendo de ser inferidas por meio de um processo de formulação e avaliação de hipóteses, com exceção de expressões explícitas de intenção por meio de palavras. Os autores reforçam que o processamento

de informações requer um esforço mental, que inclui atenção, memória e raciocínio, para se alcançar um efeito, que pode ser uma alteração nas crenças do falante, uma adição de informações contextuais etc. Seguindo essa lógica, o sentido de uma ironia não pode estar contido no texto, mas precisa ser interpretado por aquele que recebe a mensagem dentro do contexto em que foi produzido, não havendo garantias de que a intenção do sujeito chegará ao receptor.

Contudo, considerando o Princípio de Cooperação, não é possível dizer que há apenas uma das partes produzindo significados que são interpretados pela outra em uma troca de turnos. Espera-se um esforço mútuo que incentive uma busca por interpretações de sentido que correspondam ao que se sabe sobre aquela pessoa, sobre o contexto de produção, sobre as expectativas criadas ao longo da conversa, entre outros.

A ironia, enquanto implicatura conversacional, tem o seu significado implicitado a partir de todo esse esforço mútuo, que envolve desde a cooperação conversacional até a produção e a avaliação de pistas verbais e não-verbais e o processo de formulação e validação de hipóteses na tentativa de entender as intenções de seu interlocutor e proteger sua face. Com isso, é possível concluir que a interpretação de uma ironia tem de estar inserida dentro de um contexto.

É muito difícil levantar hipóteses a respeito do significado de um texto potencialmente irônico sem saber nada sobre o seu contexto. Na verdade, só é possível compreender uma ironia fora de contexto quando se tem referências sobre fatos e eventos que levaram àquela ironia, ou seja, nunca estamos desprovidos de contexto. Quando não estão baseadas no contexto conversacional, as pressuposições e inferências se baseiam em conhecimento de mundo, regras sociais e senso comum, o que se torna o contexto para a ironia. Assim sendo, a interpretação de uma ironia sempre envolve informações externas ao texto, de uma forma ou de outra ela tem de estar contextualizada.

2.4 Definição de ironia adotada nesta pesquisa

Nesta pesquisa, a ironia é definida como uma implicatura conversacional em que há uma incongruência de sentidos entre o que é dito e o que está implicado. Aqui, toma-se como *incongruência* uma incompatibilidade entre o significado literal de uma declaração e uma atitude do ironista em relação ao que foi dito.

Essa definição retoma a ideia de Sperber e Wilson (1981), porém nos distanciamos dos autores ao colocar a ironia como um discurso que não precisa evocar uma atitude negativa. Existe um tipo de ironia chamada de “elogio irônico”, em que a forma superficial da construção é negativa, mas a interpretação é positiva, como em “Mas você é um péssimo aluno, mesmo” usado para falar sobre alguém que gabaritou uma prova. Desse modo, como apontado por Fiorin (2014), a atitude expressa por uma ironia pode ser diversa, como desaprovação, provocação, humor etc.

Sendo uma implicatura, essa não apresenta um significado pré-estabelecido, tendo de ser inferido a partir das pistas contextuais disponíveis. Em alguns casos, é possível implicar que um texto é irônico com base em conhecimentos compartilhados de mundo e de senso comum. Exemplos são fornecidos a seguir.

1. A Maria é tão inteligente que ela errou quanto é $1+1$. (implicatura: Maria é burra.)
2. Acordei com sono e dor de cabeça, que dia perfeito. (implicatura: O dia está ruim.)
3. O governo está de parabéns pelo roubo de verbas da educação, um ótimo trabalho! (implicatura: O governo está fazendo um péssimo trabalho.)

Em (1), é possível implicar que o texto é irônico com base no senso comum de que somente pessoas burras não sabem somar $1+1$, portanto a interpretação mais plausível seria a de que não podemos tomar o texto como sincero. Da mesma forma, em (2) pressupõe-se que ninguém diria que teria

um dia perfeito estando com dor de cabeça e sono, que são associados a coisas ruins. Em (3), espera-se que um bom governo trabalhe honestamente, o que nos leva à conclusão de que roubar verbas da educação é algo que somente um governo ruim faria.

Mesmo esses casos que dependem de um conhecimento de mundo compartilhado nem sempre vão ser iguais para todos, uma vez que possuímos conhecimentos prévios individuais. Por exemplo, em uma sociedade em que a matemática como conhecemos não é utilizada, ironizar sobre a capacidade de saber somar de uma pessoa não faria sentido. Desse modo, os sentidos comuns e os conhecimentos de mundo também mudam e o que é irônico dentro de determinado grupo pode não ser para outro.

3 | Abordagens computacionais

A capacidade de linguagem dos seres humanos sempre foi um tema de interesse nas mais diversas sociedades, passadas ou presentes, sendo concebida diferentemente por cada uma delas. Para as teorias de cunho inatista, essa seria uma predisposição genética que nos permite adquirir uma língua natural, ou seja, uma característica da espécie humana. Por sua vez, uma língua natural é aquela que emergiu de maneira espontânea e não deliberada no curso da história humana, como o português, o alemão, o coreano, o árabe etc (AREAS, 2013, p. 12). Por meio de uma língua, são produzidas palavras, sentenças e discursos dotados de significação, sendo essa uma das formas mais eficientes de transmitir pensamentos, experiências e sentimentos.

Por anos, o homem sonha em criar máquinas capazes de se comunicar com humanos por intermédio de uma língua natural, o que tem sido estudado pelo Processamento de Língua Natural. Este capítulo apresentará um breve histórico dessa área de pesquisa, as propostas iniciais para a Detecção Automática de Ironia e as abordagens computacionais mais usadas atualmente, como os modelos baseados em regras e em aprendizado de máquina. Por fim, faz-se uma revisão de modelos que incluem informações contextuais e reforçam a importância do contexto para a tarefa.

3.1 Processamento de Língua Natural

O Processamento de Língua Natural (PLN) é uma área de pesquisa que trabalha na interdisciplinaridade entre a Ciência da Computação e a Linguística com objetivo de estudar e desenvolver computadores capazes de processar

e interpretar dados de língua humana. Muitas tecnologias que fazem parte do nosso dia-a-dia atualmente possuem mecanismos voltados para o processamento de língua natural, como os corretores de texto de celulares, os tradutores automáticos como o do Google, os sistemas de reconhecimento por voz e os assistentes virtuais, como a Siri e a Alexa.

As ideias iniciais para o surgimento do PLN vêm da década de 50. Os trabalhos de Alan Turing tiveram bastante influência no desenvolvimento de pesquisas em Inteligência Artificial (IA), como seu famoso experimento conhecido por “Teste de Turing” (TURING, 1950). Turing propõe um método empírico para avaliar se um computador seria capaz de se passar por um humano, o que seria uma prova de sua inteligência. No experimento, um interrogador humano precisa adivinhar qual dos dois participantes com quem ele está conversando é uma máquina. Esse teste foi importante para atrair o interesse e gerar discussões na área, mas foi muito criticado por sua falta de rigor, pois mesmo programas de computadores simples são capazes de enganar juízes no teste (JURAFSKY, Dan; MARTIN, 2009).

A Linguística também teve sua importância no desenvolvimento do PLN. Os trabalhos do linguista Noam Chomsky inspiraram a criação dos primeiros modelos formalistas em sintaxe computacional: as gramáticas livres de contexto (CHOMSKY, 1956). As gramáticas são modelos que geram representações sintáticas a partir de um conjunto de classes de palavras (verbo, substantivo, adjetivo etc) e regras de como combiná-las. Trazendo um paradigma diferente para a área, o linguista Zellig Harris contribuiu para o advento dos modelos de linguagem probabilísticos com sua teoria a respeito da distribuição linguística (HARRIS, 1954). A ideia proposta por ele foi a de que palavras que ocorrem em contextos em semelhantes tendem a ter um significado similar, o que é uma das premissas de base para análises de similaridade com representações vetoriais, como Word2Vec (MIKOLOV et al., 2013).

O PLN se ramifica em variadas vertentes de pesquisa que lidam com a geração e a compreensão de dados de língua escrita ou falada. Dada a complexidade envolvida no processamento linguístico, os modelos computacionais em geral são projetados para a resolução de tarefas específicas, como identificação de correferências em um texto, classificação semântica de palavras

e reconhecimento de nomes próprios, cada qual requerendo conhecimentos linguísticos específicos. As tarefas em PLN podem trabalhar dentro de uma ou mais subáreas da Linguística: Fonética, Fonologia, Morfologia, Sintaxe, Semântica, Pragmática e Discurso.

A Fonética e a Fonologia se ocupam, respectivamente, da produção e da representação de sons pertencentes a línguas humanas. A Morfologia lida com os componentes de uma palavra, como prefixos e sufixos. A Sintaxe analisa as relações de combinações entre as palavras para a formação de estruturas maiores. Já a Semântica se dedica ao significado de palavras e sentenças. Na pragmática, estuda-se o significado além do texto, como implicaturas e dêiticos. Por fim, o discurso analisa como um texto se relaciona com outro dentro de um contexto conversacional verificando, por exemplo, se eles são coerentes. Mesmo a análise individual desses aspectos linguísticos encontra dificuldades na aplicação em PLN, algumas tendo sido superadas e, outras, ainda não.

Os domínios da Pragmática e da Análise do Discurso são os mais desafiantes, pois envolvem conhecimentos de ordem não-linguística, entre os quais estão o contexto de produção do texto, a ordem de argumentos, o tempo de fala etc. Para citar um exemplo, é preciso entender que a entonação pode mudar o sentido de uma sentença: “Você não vai sair hoje?” busca uma confirmação do outro interlocutor, enquanto “Você não vai sair hoje!” é uma ordem. Outro caso, se uma pessoa diz “Fico feliz que você parou de fumar” para alguém que fumava, é um elogio, mas se for para alguém que está fumando, é uma crítica irônica.

Durante anos, os principais tópicos pragmático-discursivos em PLN foram a resolução de inferências, os atos de fala, a estrutura do discurso e as relações de coerência e raciocínio abduativo (JURAFSKY, 2006). O interesse na exploração de outros assuntos cresceu recentemente e a ironia, tema desta pesquisa, recebeu atenção da área. Compreender uma ironia exige um arcabouço de normas conversacionais, sociais e culturais, conhecimentos de mundo, aspectos lógicos e factuais e experiências que são adquiridas por humanos ao longo da vida. Para fins de processamento computacional, grande parte dessa complexidade foi abandonada da Detecção de Ironia para que

fossem dados os primeiros passos na tarefa. Porém, o contexto vem aos poucos aparecendo em frentes mais recentes de pesquisa, como será apresentado nas seções posteriores deste capítulo.

3.2 Primeiras formalizações em Detecção de Ironia

As primeiras tentativas de uma formalização computacional para a Detecção de Ironia foram de cunho lógico-formalista, cujos principais trabalhos são de Akira Utsumi (UTSUMI, 1996, 2000). Utsumi (2000) define a ironia como uma mensagem que está implícita em um ambiente irônico, isto é, a intenção irônica deve ser inferida a partir de um contexto apropriado. Sejam t_0 e t_1 dois espaços temporais que precedem o momento em que uma sentença é enunciada, um ambiente irônico é formalizado em três estágios:

1. O falante tem certas expectativas E no momento t_0 .
2. As expectativas E do falante falham, gerando um incongruência com a realidade no tempo t_1
3. O falante tem uma atitude negativa em relação à incongruência entre o que era esperado e a realidade.

Desse modo, a ironia seria disparada dentro de um ambiente irônico pela quebra de expectativas de um falante, resultando em uma reação negativa. Para Utsumi, a ironia é uma expressão indireta de uma atitude negativa que viola ao menos um princípio pragmático, como a polidez ou a sinceridade. O autor destaca pistas verbais que podem estar presentes para indicar uma atitude negativa indireta, como o uso de hipérbole, exagero, interjeições e expressões faciais.

Partindo dessas ideias, Utsumi propõe um modelo teórico que se baseia na similaridade entre uma sentença e um protótipo de ironia, calculada a partir dos critérios a seguir:

d_a : o grau de alusão de uma sentença – a coerência com as expectativas do falante.

d_i : o grau de insinceridade pragmática de uma sentença – a violação de princípios pragmáticos.

d_e : o grau de expressão indireta de uma atitude negativa – as pistas que acompanham a sentença.

d_d : a polaridade de uma sentença – quão positiva ela é.

d_m : o grau de manifestação da expectativa do falante – até que ponto a expectativa do falante foi manifestada para o ouvinte antes da interpretação da sentença.

Essas propriedades seriam medidas por escalas de 0 a 1, indicando quanto uma sentença se aproxima de um protótipo de ironia. Por exemplo, uma sentença com valor 1 de insinceridade revela uma pista que pode indicar ironia na hipótese do autor. Sendo assim, o modelo deveria ser capaz de representar as crenças de um falante para identificar quebras de expectativa.

O modelo de Utsumi é conceitualmente ideal, já que leva em consideração informações sobre o contexto, a expectativa do falante e a sinceridade para a Detecção de Ironia. Esses são aspectos que nós humanos utilizamos para perceber uma ironia. Contudo, computacionalmente, seria extremamente difícil implementar um modelo com esse nível de refinamento, ainda mais na época em que foi proposto (anos 2000).

Alguns dos critérios propostos por ele são mais fáceis de implementar e atualmente são aplicados nos modelos. Pistas linguístico-textuais, entre elas a presença de aspas, pontuação exagerada e determinadas figuras de linguagem, já foram adotadas em trabalhos na área (CARVALHO et al., 2009; FRENDÁ et al., 2016), provando-se úteis na tarefa. A valência do discurso também é um marcador pertinente à ironia, uma vez que o significado transmitido pelo ironista tem polaridade inversa a do significado literal do texto. A Análise de Sentimentos, tarefa em que um texto é etiquetado de acordo com a sua valência, geralmente dividida em “positiva” e “negativa”, é um tópico em alta

atualmente. Essa por si só não é uma tarefa simples, tornando-se mais difícil de resolver quando aplicada em corpora de texto informal, como as redes sociais (WANKHADE; RAO; KULKARNI, 2022). Além disso, como apontam Wankhade, Rao e Kulkarni (2022), situações ambíguas e ironia são duas dificuldades centrais em análise de sentimentos. Portanto, Detecção de Ironia e Análise de Sentimentos são tarefas correlatas que precisam ser estudadas conjuntamente.

Já critérios como a sinceridade e a expectativa do falante são mais complexas de medir e formalizar. Existe ampla literatura sobre os temas em Psicologia (TANNEN, 1993; MOXEY; SANFORD, 1993) e Pragmática (FISH; ROTHERMICH; PELL, 2017; BARR, 2008), mas essa é escassa em PLN. Alguns esforços nesse sentido têm sido feitos. Girlea e Girju (2018) implementam um modelo para medir a insinceridade a partir de transcrições de diálogos de fala. O corpus usado por eles está anotado com diversos aspectos extralinguísticos, como marcação de pausas e risadas, além de conter informações sobre os participantes do diálogo, como a intimidade e a amigabilidade entre eles. A sinceridade é medida por traços como repetições, pausas, risadas, palavras de juramento, polidez, entre outros. O melhor modelo avaliado alcançou 67,9% de acurácia. Liu, Wan e Su (2019) apresentam um modelo para a classificação das expectativas de clientes em caso de defeito de um produto. Os autores coletam textos de reclamações de clientes de um site de automóveis, classificando-os a partir de suas expectativas em: “resolução do problema”, “compensação financeira” e “compensação psicológica”. Para a classificação, foram testados traços *n*-gramas e *word embeddings*, com diferentes tipos de modelos. Entre as três categorias de expectativa, a mais difícil foi a de compensação psicológica.

Conclui-se que a aplicação dessas tarefas ainda é restrita a determinados ambientes com categorias fechadas e depende de dados anotados com informações específicas. Trabalhar individualmente com cada uma delas é custoso. Juntá-las em um único modelo capaz de analisar diversos aspectos linguísticos e extralinguísticos é uma das barreiras que o PLN precisa derrubar. As primeiras ideias de formalização para a Detecção de Ironia foram ambiciosas, imaginando agentes inteligentes dotados de raciocínio interpretativo e

avaliativo em relação às emoções e expectativas de uma pessoa. Os modelos de redes neurais avançaram em diversas tarefas na área, mas estão longe de fazer uma análise de ironia sofisticada como idealizou Utsumi.

3.3 Modelagem para Detecção de Ironia

Diante dos problemas encontrados na implementação de modelos simbólicos, as pesquisas em PLN se voltaram para métodos mais simples de análise automatizada de ironia. Atualmente, é mais comum que a tarefa de Detecção de Ironia seja tratada como um problema de classificação binária de texto, rotulando os exemplos em irônico e não-irônico. Tarefas de classificação são aquelas em que um documento é mapeado em um conjunto de classes. O objetivo é induzir uma função que mapeie representações de documentos em suas respectivas classes (WALLACE, 2013). As categorias variam a depender do objetivo e perspectiva de pesquisa. Por exemplo, além das categorias canônicas, Carvalho et al. (2009) permitem que um texto seja classificado em “indeterminado” – quando não há contexto suficiente para a decisão – e “ambíguo” – quando existe a possibilidade de mais de um fenômeno linguístico estar presente na frase. No trabalho de Reyes, Rosso e Veale (2013), a ironia é comparada com textos sobre humor, educação e política.

O interesse em Detecção de Ironia cresce cada dia mais em PLN. No ano de 2018, o SemEval (*International Workshop on Semantic Evaluation*) (VAN HEE; LEFEVER; HOSTE, 2018a) dedicou uma mesa para a discussão e a avaliação da tarefa, propondo desafios em classificação binária (ironia versus não-ironia) e multi-classes (ironia por contraste de polaridade, ironia situacional, outros tipos de ironia e não-ironia). Dois anos depois, o FigLang (*Workshop on Figurative Language Processing*) (GHOSH; VAJPAYEE; MURESAN, 2020), realizado pela *Association for Computational Linguistics* (ACL), promoveu uma mesa para a tarefa de detecção de ironia com enfoque em estudar o papel do contexto conversacional na tarefa, fornecendo dois corpora anotados compostos de conversas entre usuários. A visibilidade proporcionada por esses eventos ajuda a impulsionar o desenvolvimento e a avançar o estado-da-arte na tarefa. A maioria desses estudos é aplicado em textos do inglês.

Todavia, outras línguas estão presentes na literatura da tarefa, como o italiano (CIGNARELLA et al., 2018), o espanhol (ORTEGA-BUENO et al., 2019), o árabe (GHANEM et al., 2019), o chinês (JIA et al., 2019) e o português (CARVALHO et al., 2009).

As abordagens para a Detecção de Ironia são usualmente divididas em duas categorias: baseadas em regras e aprendizado de máquina. Nas próximas subseções serão apresentados modelos voltados para a classificação de ironia em cada uma dessas abordagens.

3.3.1 Modelos baseados em regras

Na abordagem baseada em regras, os modelos consultam um conjunto de instruções para a aplicação de regras que o auxiliam na identificação de ironia. Essas regras podem ser de cunho linguístico, extralinguístico, frequência de termos e outros. Com uma abordagem para Detecção de Ironia aplicada à língua portuguesa, Carvalho et al. (2009) criaram um corpus a partir de postagens de um site de jornal e implementaram uma gramática dependente de contexto (UGC) testada com diferentes padrões linguísticos textuais: interjeições, pontuação exagerada, diminutivo em nomes próprios, marcas de citação, morfologia verbal, além de emojis e onomatopeias de risos. Os autores reportam que o melhor resultado de seu modelo foi obtido com os padrões baseados em expressões de risos e emojis, alcançando uma precisão de 85,40% na identificação de ironia. Com isso, eles mostraram que aspectos extratextuais codificados em texto (como risadas e emoções) são indicativos relevantes de ironia.

Maynard e Greenwood (2014) investigam os efeitos do sarcasmo em Análise de Sentimentos. Eles propõem um modelo que verifica inversões de polaridade causadas por incongruência de sentimentos no texto, o que ocorre frequentemente em sarcasmo. Um dos pontos interessantes do trabalho é a análise de *hashtags* como possíveis indicadores de sarcasmo. Os autores desenvolvem um analisador morfossintático para separar as *hashtags* em palavras. A ironia é identificada quando há uma discordância de sentimentos, como uma polaridade positiva no texto e uma *hashtag* negativa. Os experimentos

evidenciaram uma melhora na análise de sentimentos quando a detecção de inversão de polaridade por sarcasmo foi considerada.

Baseados na premissa de que a quebra de expectativa é uma característica na ironia, [Veale e Hao \(2010\)](#) verificam ironias construídas a partir de símiles, como “ele é tão inteligente quanto um jegue”. O trabalho apresenta uma arquitetura composta de regras focadas na similaridade entre os dois objetos da construção para determinar se o texto é ou não irônico. Para exemplificar, a sentença “tão seguro quanto um trem desgovernado” seria irônica pela dissimilaridade entre “seguro” e “trem desgovernado”. A similaridade foi definida com base na WordNet e na ocorrência em buscas por termos na Web, obtendo 73% de medida-F na Detecção de Ironia.

3.3.2 Modelos de aprendizado de máquina

Os principais métodos de aprendizado de máquina são: supervisionado, semi-supervisionado e não-supervisionado ([YAGHOOBAN; ARABNIA; RASHEED, 2021](#)). O treinamento de um modelo de aprendizado supervisionado é feito em um corpus anotado, isto é, em que cada texto está associado a uma classe esperada. No aprendizado não-supervisionado, o corpus de treinamento não contém anotação e o modelo faz previsões às cegas. No semi-supervisionado temos uma combinação das duas técnicas anteriores. Na revisão a respeito da Detecção de Ironia apresentada por [Yaghoobian, Arabnia e Rasheed \(2021\)](#), os autores apontam que a maioria dos trabalhos usam modelos de aprendizado supervisionado, como *Support Vector Machine* (SVM), *Decision Tree* (DT), *Random Forest* (RT), *Naïve Bayes* (NB) e redes neurais (RN). É possível combinar mais de uma tipo de técnica, desenvolvendo um modelo híbrido.

Para classificar os textos, são extraídas informações relevantes chamadas de “traços”, do inglês *features*. Alguns traços usualmente testados em trabalhos em Detecção de Ironia são *bag-of-words* (BOW), que consiste na representação do texto pelas palavras que o compõem, padrões de pontuação, n-gramas, traços de ambiguidade semântica, padrões de similaridade e classificação morfossintática ([YAGHOOBAN; ARABNIA; RASHEED, 2021](#); [JOSHI; BHATTACHARYYA; CARMAN, 2017](#)). As representações vetoriais *word embed-*

dings, que serão discutidas em mais detalhes no Capítulo 6, também podem ser usadas como traços. Para citar um exemplo de aplicação, [Aditya Joshi \(2016\)](#) adotam medidas de similaridade entre pares de *word embeddings* como um traço para detectar incongruências entre informações contidas no texto. Por exemplo, em “uma mulher precisa de um homem assim como um peixe precisa de uma bicicleta”, a dissimilaridade entre “peixe” e “bicicleta” em oposição à similaridade entre “homem” e “mulher” indicaria uma incongruência que, segundo os autores, pode ser um marcador de ironia.

Utilizando um corpus de tweets, [Reyes, Rosso e Veale \(2013\)](#) implementam dois classificadores (NB e DT) para a Detecção de Ironia a partir de três temas: Política, Humor e Educação. Os autores avaliaram traços textuais (como a presença de pontuação e de advérbios), estilísticos (baseados na identificação de n-gramas, por exemplo), imprevisibilidade (obtida por medidas de similaridade da Wordnet) e emotivos (fornecidos por um léxico de emoções). Eles chegam à conclusão de que os traços emotivos são os mais efetivos para a Detecção de Ironia, indo na direção do resultado de [Carvalho et al. \(2009\)](#).

Por sua vez, [Gonçalves et al. \(2015\)](#) treinaram um modelo SVM para detectar ironia e sarcasmo em um corpus de *tweets* em português. Eles utilizam dois tipos de representação de palavras: BOW e atributos extraídos com a ferramenta LIWC ([BALAGE FILHO; PARDO; ALÚSIO, 2013](#)), como a polaridade (positiva ou negativa) e a classe morfossintática de uma palavra. A combinação dos dois traços obteve medida-F de 75,99% na identificação de ironia.

Já [Van Hee, Lefever e Hoste \(2018b\)](#) estão interessados na detecção de ironia construída a partir de sentimentos implícitos, isto é, aqueles que não estão em palavras emotivas (como “amar” e “odiar”), mas são interpretados por informações externas, como o conhecimento de mundo e o senso comum. Em uma primeira etapa, eles identificam o sentimento prototípico em expressões que contêm sentimentos implícitos em contextos não-irônicos. Por exemplo, “acordar cedo em um sábado”, “trabalhar no feriado” e “perder o voo” são geralmente situações negativas. A partir daí, busca-se por conflitos de sentimentos no texto (positivo e negativo), que podem ser entre dois sentimentos explícitos ou um explícito e um implícito. Implementa-se um modelo

que combina um SVM ao método de identificação de ironia por contraste (sentimento implícito e explícito), porém os resultados obtidos não superaram o do *baseline* testado.

As redes neurais têm apresentado resultados promissores para a classificação de ironia. As principais arquiteturas adotadas são as redes recorrentes (ILIĆ et al., 2018; WU et al., 2018), as redes convolucionais (RANGWANI; KULSHRESHTHA; SINGH, 2018) e as redes Transformer (POTAMIAS; SIOLAS; STAFYLOPATIS, 2020; SRIVASTAVA et al., 2020). No trabalho de Wu et al. (2018), aplica-se uma rede neural composta de várias *Long-short term memory* bidirecionais (BiLSTM) conectadas entre si. Para a representação textual, os autores adotam uma combinação de dois *word embeddings* pré-treinados, além de representações morfossintáticas e de sentimentos. Esse modelo alcançou o melhor desempenho na classificação de ironia binária no SemEval-2018 (VAN HEE; LEFEVER; HOSTE, 2018a), com 70,5% de medida-F.

Trazendo uma abordagem simples, Vu et al. (2018) aplicam uma rede neural multicamadas alimentada com traços linguísticos. São quatro tipos de traços: lexicais, sintáticos, semânticos e polaridade. Uma das representações semânticas adotadas é obtida pelo algoritmo Brown clustering (BROWN; DESOUSA et al., 1992) usado para concatenar palavras parecidas em conjuntos, gerando um vetor que computa quantas palavras de cada *cluster* estão contidas no texto. O modelo alcançou 64,8% de medida-F no SemEval-2018 na tarefa de classificação binária, provando que arquiteturas menos refinadas podem alcançar bons resultados na tarefa.

Combinando Análise de Sentimentos e Detecção de Ironia, Shiwei Zhang et al. (2019) propõem um modelo multi-tarefas que transfere o conhecimento aprendido de uma tarefa para a outra. A arquitetura possui duas redes neurais BiLSTMs com camadas de atenção, uma delas previamente treinada para a análise de sentimentos e mantida com os pesos congelados, enquanto a outra é treinada para a classificação de ironia. A ideia dos autores é que a primeira BiLSTM extraia informações de sentimentos conflitantes nos textos para identificar incongruências que indiquem ironia. Na discussão do artigo, eles fornecem exemplos de como o modelo foi capaz de focar em partes do texto que continham sentimentos opostos, mostrando que é proveitoso aplicar

transferência de conhecimento entre Análise de Sentimentos e Detecção de Ironia.

3.4 Inserção de conhecimento contextual

Desde os primeiros trabalhos em Detecção Automática de Ironia, havia ciência da relevância do contexto para a resolução da tarefa, mesmo que ele tenha sido deixado de lado para fins de aplicação. Contudo, esse cenário está mudando, abrindo espaço para a inserção de contexto na modelização da tarefa. Joshi, Bhattacharyya e Carman (2017) apontam três formas de contexto que aparecem incorporados na tarefa: o *contexto do autor*, o *contexto do tópico* e o *contexto conversacional*. O contexto do autor se refere às marcas textuais e às informações sobre o autor do texto. Nessa linha de pesquisa, Khattri et al. (2015) recuperam o histórico de postagens de um usuário para identificar incongruências entre o sentimento de um texto-alvo sobre determinada entidade e sentimentos prévios do autor sobre a mesma entidade como um traço de ironia, enquanto Amir et al. (2016) capturam padrões estilísticos de usuários para diferenciar textos irônicos de não-irônicos. Já o contexto do tópico se baseia na ideia de que alguns assuntos tendem a ser mais irônicos do que outros. Por fim, o contexto conversacional se refere ao diálogo em que o texto-alvo está inserido. É possível combinar mais de um tipo de contexto, como nos trabalhos de Wang et al. (2015) e de Bamman e Smith (2015). O restante da revisão será focada nos traços relacionados ao *contexto conversacional*, já que são de maior interesse para esta pesquisa.

Com um corpus de ironia extraído de comunidades do Reddit¹, Wallace, Charniak et al. (2015) introduzem um modelo SVM que considera como traços informações sobre as entidades mencionadas em um comentário-alvo, a comunidade em que o *reddit* foi postado e a polaridade do comentário, buscando por interações entre esses três aspectos. Para eles, um comentário positivo sobre o Barack Obama postado em uma comunidade conservadora

¹<https://www.reddit.com/>

teria grande chance de ser irônico. O modelo obtém resultados superiores ao BOW testado como *baseline*.

Trazendo uma abordagem de redes neurais, [Srivastava et al. \(2020\)](#) representam o contexto conversacional através de uma camada de sumarização de contexto. Eles avaliam dois corpora: um do Twitter e outro do Reddit, ambos compostos de um texto-alvo e todos os comentários que o precedem em uma conversa entre usuários. Para a classificação, é usada uma complexa rede hierárquica que combina representações textuais do BERT ([DEVLIN, 2018](#)), camadas recorrentes e camadas convolucionais. A princípio, cada texto do contexto conversacional é representado por vetores do BERT, que passam por uma camada de sumarização de contexto, formada por uma rede convolucional, em que a informação contida nos textos é sumarizada. Os resultados da rede ficaram em 74% de medida-F no corpus do Twitter e 63,9% no Reddit, superando os *baselines* comparados.

O trabalho de [Ghosh, Fabbri e Muresan \(2018\)](#) propõe um modelo de Detecção de Ironia que considera turnos, sendo eles: o turno atual (texto-alvo), o turno anterior e o turno posterior (quando presente). Para o treinamento e a avaliação, são considerados dois tipos de corpora: um extraído do Twitter (textos curtos anotados automaticamente) e dois de fóruns da internet (textos mais longos), um deles anotado manualmente e o outro automaticamente. Os autores avaliam um modelo *baseline* (SVM com traços motivados linguisticamente) e variações de LSTM (com e sem camada de atenção) recebem como entrada o turno atual, o anterior e o posterior. Comparando o desempenho do modelo com e sem a informação contextual, o trabalho aponta para o benefício de considerar o contexto, já que os modelos de rede neural com contexto obtiveram um aumento estatisticamente relevante na performance.

4 | O papel das emoções para a ironia

As emoções estão presentes em praticamente todos os aspectos de nossas vidas, principalmente em relações interpessoais. No dia-a-dia, palavras relacionadas a emoções são utilizadas para se referir a dezenas de cenários, como a cena de maior tensão em um filme, o nascimento de uma criança, a discussão sobre a sua comida favorita etc. O Dicionário de Psicologia define emoção como:

Reação intensa acompanhada de manifestações fisiológicas e psicológicas. O senso comum e a maior parte das teorias psicológicas que explicam as emoções, afirmam que as expressões corporais (por exemplo, contrações faciais) se seguem às emoções (medo, alegria, etc.) (MESQUITA; DUARTE, 1996).

Além da linguagem corporal, a língua, sendo um dos principais meios de comunicação humana, está intimamente ligada à transmissão de sentimentos como forma de externalizar o que é agradável ou desagradável. Na ironia, as emoções são fortes indícios para a percepção de que há algo incongruente no discurso, pois são o que sinalizam a existência de uma atitude implícita do interlocutor por trás de suas palavras. Neste capítulo, será inicialmente apresentada a distinção entre as áreas de Análise de Sentimentos e Análise de Emoções, seguida de uma breve discussão de dois modelos de emoções predominantes advindos da psicologia evolucionista: o de Robert Plutchik e o de Paul Ekman. A partir daí, segue-se uma listagem de técnicas para a análise computacional de emoções e de emojis, finalizando com um debate sobre a importância das emoções para a ironia.

4.1 Análise de Emoção Textual

A Análise de Emoção Textual (AET), do inglês *Textual Emotion Analysis*, é uma tarefa que busca identificar e classificar estados emocionais em textos (PENG et al., 2022). Na literatura, há uma distinção entre o que é chamado de Análise de Sentimentos (AS) e a Análise de Emoção Textual: a primeira avalia a polaridade de um texto, classificando-o em “positivo” e “negativo”, podendo incluir “neutro”, enquanto a segunda avalia a emoção de um texto, como por exemplo “raiva”, “alegria” e “tristeza” (PENG et al., 2022; NANDWANI; VERMA, 2021).

Essa tarefa possui diversas aplicações dentro do Processamento de Língua Natural. Entre elas estão a avaliação de saúde mental com base em discussões de redes sociais, o desenvolvimento de modelos de recomendações personalizadas de produtos para usuários e a inferência do grau de satisfação de clientes a partir de *feedbacks* de produtos. Por exemplo, Garcia e Berton (2021) analisam textos do português e do inglês coletados da rede social X com tópicos relacionados à pandemia para classificar emoções de usuários sobre o assunto e ver como isso atingiu a população.

Em se tratando de um campo de pesquisa que envolve uma análise de natureza subjetiva, não existe uma única forma de organizar e rotular as emoções humanas. Cada língua apresenta um conjunto distinto de palavras emotivas, que varia no grau de diversificação e de distinção. No inglês, “*amazed*” e “*astonished*” possuem a mesma tradução no português como “admirado, assombrado” de acordo com o Dicionário de Cambridge¹, mas “*astonished*” é mais intenso do que “*amazed*”. Em uma mesma língua, certas palavras se associam a mais de uma emoção, a exemplo de “aborrecimento” para indicar raiva, aversão e desgosto². A expressão de emoções através da língua é imprecisa, ambígua e complexa, o que as torna difíceis de medir (PLUTCHIK, 1980).

¹<https://dictionary.cambridge.org/pt/dicionario/>

²<https://michaelis.uol.com.br/moderno-portugues/busca/portugues-brasileiro/aborrecimento>

Os modelos de classificação de emoções tendem a considerar aspectos não-linguísticos para classificá-las. Eles podem ser divididos com base em dois critérios: categoria e dimensão. O primeiro tipo estabelece categorias discretas para as emoções, como “alegria” e “medo”. Já o segundo é uma representação em que cada emoção ocupa uma posição em um espaço que pode ser bidimensional ou tridimensional. De acordo com [Hakak et al. \(2017\)](#), a maioria dos modelos dimensionais representa a valência, indicando o quanto uma emoção é prazerosa, e a excitação, que estabelece um limiar entre ativação e desativação de estados. Uma terceira dimensão que pode aparecer é a dominância, usada para representar se o sujeito se sente no controle da situação ou não.

Os modelos de emoções se desenvolveram principalmente na Psicologia e, posteriormente, foram adotados na Análise de Emoções Textual. Na subseção seguinte, serão apresentadas duas das propostas de classificação de emoções mais conhecidas na literatura.

4.1.1 Modelos de emoções

Na década de 90, as pesquisas dedicadas às emoções ganharam força na área de Psicologia, em que diversas correntes teóricas desenvolveram suas análises sobre o tema. As mais influentes na época foram as teorias de cunho Psicoevolucionista. Essas teorias se embasaram nas ideias de Charles Darwin desenvolvidas no livro “*The Expression of the Emotions in Man and Animals*” ([DARWIN, 1998](#)), em que o biólogo associa determinados movimentos musculares faciais presentes em humanos e primatas a certas emoções. Com isso, as teorias Psicoevolutivas investigam o surgimento das emoções em razão da evolução e sua importância para o processo evolutivo. Dois dos principais representantes dessa linha de corrente são Robert Plutchik e Paul Ekman.

O psicólogo Robert Plutchik foi um dos fundadores da corrente Psicoevolutiva, formulando uma teoria para expor as vantagens adaptativas de emoções para a sobrevivência. Para Plutchik, uma emoção não é apenas um “estado emotivo”, mas “uma corrente complexa de eventos vagamente conectados que começa com um estímulo e inclui sentimentos, mudanças psicológicas,

impulsos para ação e comportamento específico com objetivo direcionado” (PLUTCHIK, 2001).

Plutchik (2001) analisa a emoção como uma cadeia de eventos desencadeada por um estímulo que tem como início a cognição, passa por um estado emotivo, um comportamento de resposta e um efeito. Essa cadeia não é linear, mas um processo de *feedback*, em que cada estágio pode ser influenciado por eventos ocorrendo posteriormente na cadeia. Assim, sentimentos e comportamentos podem afetar a cognição e vice-versa. O autor argumenta que a função da emoção é restaurar um equilíbrio anterior ao evento que causou o distúrbio, por isso sua importância no processo evolutivo. Um exemplo prototípico dessa cadeia oferecido pelo autor é a perda de um objeto de valor, que é processada pela cognição como abandono, desencadeando um sentimento de tristeza cuja resposta é o choro, gerando o efeito de reconexão com o objeto perdido.

O autor destaca a função da emoção na socialização pela troca de sinais expressivos, como acenos, sorrisos e contato visual. Do ponto de vista da comunicação animal, o processo de regulação social serve como forma de sobrevivência, já que sinais de comunicação podem alertar os demais animais de um bando a fugirem ou intimidar predadores. Portanto, as emoções são parte do processo de regulação social e valiosas do ponto de vista adaptativo.

O modelo proposto por Plutchik, chamado de Roda de Emoções, é representado por um cone tridimensional, que quando visualizado como um modelo bidimensional se assemelha a uma flor de oito pétalas fatiadas em subpartes que indicam a intensidade da emoção. As pétalas de emoções são posicionadas por similaridade de modo que as opostas estão a 180° graus de distância. Plutchik define oito emoções básicas organizadas em pares opostos: *joy* (alegria) e *sadness* (tristeza), *trust* (confiança) e *disgust* (nojo), *anticipation* (antecipação) e *surprise* (surpresa) e *fear* (medo) e *anger* (raiva). A Figura 4.1 traz uma representação do modelo de Plutchik.

Na Roda de Emoções, as cores refletem a intensidade da emoção: quanto mais escura (próxima ao núcleo), mais intensa, e quanto mais clara (próxima à ponta), menos intensa. Dessa forma, na pétala de alegria, tem-se “serenidade” como menos intensa e “êxtase” como mais intensa. Além das emoções nas pétalas, Plutchik identifica possibilidades de combinações entre emoções para




Figura 4.1: Representação da Roda de emoções de Plutchik.

criar novas, representadas pelas palavras entre pétalas. Para ele, “amor” é a combinação de “alegria” e “confiança”. As combinações na flor são apenas exemplos, mas o modelo de Plutchik admite outras a partir da junção de duas ou mais emoções em diversos níveis de intensidade, similarmente ao que é feito com as cores primárias para obter-se as secundárias. Por fim, a similaridade permite que sejam encontradas famílias de emoções, como apontado por Plutchik, o que explicaria o número de palavras emotivas muito maior do que o número de emoções, já que algumas seriam pertencentes a uma das famílias existentes.

O trabalho de Plutchik foi muito difundido por apresentar uma faceta prática, ganhando visibilidade fora da área de Psicologia. O próprio autor

mostra como a Roda de Emoções pode ser aplicada para estudos de personalidade e psicopatologias. Em PLN, há várias formas de aplicá-lo para análise de emoções. O fator de similaridade, por exemplo, pode ser calculado a partir de vetores que representam cada uma das emoções. A intensidade é mais difícil de representar, mas não impossível, podendo ser ativada a partir de algum limiar pré-estabelecido. Desse modo, além de apresentar um número de emoções consideradas básicas, Plutchik também propõe uma representação gráfica que pode ser útil para fins de aplicação em diversas áreas.

Por sua vez, o interesse do psicólogo Paul Ekman pelas emoções foi movido por uma pesquisa inicial desenvolvida por ele e colegas (EKMAN, 1984; EKMAN et al., 1987) a respeito da universalidade das expressões faciais de medo, raiva, alegria, tristeza e nojo. Para Ekman (1992), as emoções surgiram como parte do processo da evolução humana por seus valores em tarefas fundamentais do dia-a-dia. Exemplos de tarefas fundamentais seriam o enfrentamento de perigo iminente e a experiência de uma perda, em que as emoções seriam uma forma de resposta diante de um evento, uma forma de mobilizar o indivíduo para lidar rapidamente com esse acontecimento.

Diferente do modelo de Plutchik, o de Ekman é de cunho categórico, reconhecendo as emoções como categorias discretas com características próprias. Nele, as emoções se organizam em famílias, em que cada família contém um tema e variações. O tema é composto das características únicas daquela família e as variações são produto de aprendizado, experiências individuais, fisionomia e contexto de ocorrência da emoção. Em sua teoria, o autor reconhece seis emoções básicas (raiva, medo, alegria, tristeza, surpresa e nojo), distintas por nove características, como a presença de emoções em outros animais, as ativações nervosas relacionados às emoções, a coerência de respostas frente a estímulos semelhantes, a resposta rápida e a duração breve.

Ekman identifica um problema em classificar as emoções positivas já que, diferente das negativas, elas não apresentam um sinal distintivo, ou seja, possuem muitos traços semelhantes, a exemplo do sorriso que é comum a diferentes emoções positivas. A hipótese levantada pelo autor para explicar isso é a de que não era relevante para a sobrevivência distinguir qual emoção estava sendo transmitida, apenas que era positiva e não medo, tristeza, raiva

ou nojo. Ekman propõe que as emoções positivas podem todas ser parte da mesma família de alegria, portanto uma única família positiva contra cinco negativas.

Diferente de Plutchik, sentimentos como “amor” e “ódio” não representam emoções para Ekman, mas “atitudes emotivas”. Ele também distingue emoções do que chama de “traços emotivos”, como hostilidade e melancolia, e “distúrbios emotivos”, por exemplo ansiedade e depressão. Para ele, todos esses termos envolvem emoções, mais de uma muitas vezes, mas diferem das emoções pelo tempo de duração e outros aspectos. Por fim, ele categoriza o “enredo emocional”, que engloba o luto e o ciúmes, chamados assim por envolverem um enredo mais ou menos pré-estabelecido. Ekman assume a possibilidade de misturas, isto é, termos que incluem duas ou mais emoções distintas, como escárnio ou desdém, que combinam alegria e desprezo.

O modelo categórico de Ekman discute diversos desdobramentos interessantes dentro da pesquisa de emoções, como a dificuldade de distinção entre determinadas emoções, a separação das emoções de outros fenômenos emotivos e a caracterização de emoções por aspectos fisiológicos e físicos. Apesar de sua abordagem evolucionista, ele reconhece a influência da cultura e do meio social na classificação das emoções como parte das variações. Desse modo, nem tudo pode ser explicado por universalidades. Existiriam aspectos não-evolutivos envolvidos nas emoções.

4.2 Técnicas de análise de emoções

As técnicas de Análise de Emoção variam entre baseadas em léxico e em aprendizado de máquina. As primeiras utilizam dicionários de emoções para classificar palavras no texto-alvo e calculam a emoção textual por métricas de frequência. Alguns corpora de emoções populares são o LIWC ([TAUSCZIK; PENNEBAKER, 2010](#)), que está anotado para diversas categorias psicológicas incluindo algumas emoções, a WordNet-Affect ([STRAPPARAVA, 2004](#)), uma extensão da WordNet para emoções, o NCR ([MOHAMMAD; TURNEY, 2013](#)), anotado com as oito emoções básicas de Plutchik e a SenticNet ([CAMBRIA et al., 2010](#)), que propõe um modelo vetorial baseado na Roda de Emoções,

nomeado “Ampulheta das Emoções”. Em relação a materiais multilíngues, o NCR e a SentiNet foram traduzidos automaticamente para diversas línguas, incluindo o português, e o LIWC foi traduzido para o português, gerando o LIWC-BR³ (BALAGE FILHO; PARDO; ALÚSIO, 2013).

As abordagens de aprendizado de máquina são das mais variadas, desde os modelos de aprendizado de máquina clássico até as redes neurais. Os modelos de aprendizado supervisionado, como *Support Vector Machine* (SVM), *Naïve Bayes* (NB) e *Decision Tree* (DT) são escolhas comuns para a tarefa. Jain, Kumar e Fernandes (2017) propõem um modelo de classificação de emoções para redes sociais com base no modelo de Ekman (1992) para três domínios: Saúde, Política e Esporte. Os autores avaliam um método SVM e um NB com traços extraídos de dicionários de emoções, concluindo que o modelo SVM se saiu melhor na tarefa. Incluindo intensidade como um aspecto para a classificação de emoção, Gupta e Yang (2018) implementam um modelo SVM para quatro emoções (alegria, medo, raiva e tristeza) usando traços emotivos e não-emotivos, entre eles n-gramas, análise morfossintática e representações de palavras. Nos traços emotivos, eles consideram a contagem de palavras emotivas positivas e negativas e sua intensidade, computados a partir de corpora de emoções. O modelo é testado no corpus do SemEval-2018 (MOHAMMAD; BRAVO-MARQUEZ et al., 2018), que é anotado de acordo com a intensidade da emoção no texto.

Dada a popularização e a acessibilidade a modelos de redes neurais que vemos nos últimos anos, diversos trabalhos avaliaram o desempenho desse método para a classificação de emoções. Com o crescente interesse na tarefa, surgiram junto aos modelos neurais as representações vetoriais afetivas, cujo intuito é capturar informações sobre emoções em palavras e textos. Exemplos de vetores afetivos são o Emo2Vec (XU et al., 2018), um modelo que gera *word embeddings* a partir de um treinamento simultâneo em múltiplas tarefas, incluindo análise de sentimentos, análise de emoções e detecção de sarcasmo; o DeepMoji (FELBO et al., 2017), treinado a partir da associação entre textos e emojis; e o EWE (AGRAWAL; AN; PAPAGELIS, 2018), que modeliza emoções dado o contexto de ocorrência da palavra.

³<http://143.107.183.175:21380/portlex/index.php/en/liwc>

Modelos usualmente testados em AET são as redes neurais recorrentes e convolucionais. Batbaatar, Li e Ryu (2019) apresentam uma rede neural que combina duas arquiteturas: uma rede BiLSTM para a codificação de informações semânticas e uma convolucional para as emoções. Os vetores das redes são concatenados e passados por uma camada *feedforward* seguida por uma *softmax*. As seis emoções de Ekman servem de base para a anotação de corpora em diferentes domínios. Os autores avaliaram três representações *word embeddings* textuais combinados a uma representação emotiva (EWE), concluindo que o modelo que combina as duas redes neurais superou os demais modelos com os quais foi comparado. Por sua vez, Mohammadi, Amini e Kosseim (2019) implementam uma arquitetura que combina uma neural recorrente com camada de atenção e um classificador de saída SVM. Eles avaliam dois *embeddings* para representação textual: GloVe (PENNINGTON; SOCHER; MANNING, 2014) e ELMo (PETERS et al., 2018), concatenados a um vetor *one-hot* representando a categoria morfosintática da palavra. Os resultados mostraram que o modelo com o ELMo se saiu melhor, o que eles atribuem ao fato dele ser um vetor contextualizado.

4.3 Análise de emoções em emojis

Os meios de comunicação digitais trouxeram consigo os emojis, que atualmente fazem parte das interações cotidianas em redes sociais. Os primeiros emojis surgiram no Japão em 1999 criados por Shigetaka Kurita. Ele desenhou e implementou 176 emojis em forma de pequenas imagens em píxeis para representar informações simples e alguns sentimentos. Em 2010, os emojis foram padronizados para a codificação Unicode 6, consistindo de um conjunto de 722 caracteres, que foram popularizados pela empresa Apple através do iPhone (KRALJ NOVAK et al., 2015). O número de emojis cresce a cada atualização da codificação Unicode. De acordo com as estatísticas da Emojipedia⁴ existem 3790 emojis no Unicode 16.0⁵, disponibilizado em Setembro de 2024.

⁴<https://emojipedia.org/stats>

⁵<https://unicode.org/versions/Unicode16.0.0/>

De acordo com Kralj Novak et al. (2015), um emoji é um símbolo gráfico que representa não apenas expressões faciais, como também conceitos e ideias, tempo, veículos e construções, comida e bebida, animais e plantas, emoções, sentimentos e atividades. Portanto, um emoji não é necessariamente emotivo, podendo ser usado apenas para substituir uma palavra, representar uma ação e até mesmo enfeitar um texto.

Nas redes sociais, o uso de emojis tem crescido cada vez mais. Em 2015, o Oxford Dictionaries⁶ identificou o “Rosto Chorando De Rir” (😂) como a Palavra do Ano (SHOEB; MELO, 2020). Uma pesquisa realizada pela Emojipedia⁷ revelou que 21,5% de todos os tweets enviados em Dezembro de 2021 contém ao menos um emoji. A plataforma Discord⁸ mostrou dados relevantes sobre o uso de emojis por seus usuários com a pesquisa “Talk Emoji to me”⁹, em que 63% dos usuários da pesquisa indicaram que os emojis os ajudaram a se sentir mais conectados com a comunidade e mais de 60% dos usuários da geração Z e Millenials conseguem expressar melhor seus sentimentos por emojis do que por mensagens escritas.

O uso dos emojis, contudo, não é óbvio, pois eles têm interpretações e significados variados dependentes de contexto conversacional, costumes sócio-culturais, faixa etária, entre outros fatores. Segundo Paiva (2016), o emoji “Mãos juntas” (🙏) foi criado para representar um cumprimento de mão, o *highfive*. Contudo, no Japão ele tem representado um agradecimento e no Brasil é usado como prece. Muitos emojis variam entre um significado literal e um figurado, por exemplo, o emoji de berinjela (🍆) pode ser usado para representar o legume correspondente ou para se referir ao órgão sexual masculino. O contexto de ocorrência também faz muita diferença no possível significado de um emoji. Um emoji aparentemente positivo como o “Rosto mandando um beijo” (😘) pode ser usado de forma carinhosa ou assumir um significado irônico para demonstrar um tipo de indiferença ou desprezo.

Ademais, não há uma relação um-para-um entre emoji e emoção. Um único emoji tem o potencial de transmitir inúmeras emoções, algumas nem

⁶<https://www.oxfordlearnersdictionaries.com/>

⁷<https://blog.emojipedia.org/top-emoji-trends-of-2021/>

⁸<https://discord.com/>

⁹<https://discord.com/blog/talk-emoji-to-me-survey-the-science-behind-emojis>

sempre evidentes. Determinadas emoções são mais fáceis de se confundir, como medo e surpresa, o que é relatado até mesmo para expressões faciais humanas. No estudo de Ekman (1984), os entrevistados distinguiram a expressão facial de surpresa de raiva, nojo e felicidade, mas apenas em um contexto ela foi distinta de medo. Portanto, a análise de emoções de emojis não é tão simples quanto parece à primeira vista.

Mesmo assim, várias pesquisas se propuseram a classificar os emojis de acordo com suas emoções. Uma dessas fontes é a Emojipedia¹⁰, um site que oferece os significados de todos os emojis que constam no Unicode até a versão atual (17.0), com definições propostas por lexicógrafos pesquisadores responsáveis pelo site. Os significados contêm descrições que caracterizam o emoji e fornecem informações sobre o seu uso e possíveis sentimentos associados a eles. Uma vantagem da Emojipedia é que ela não é um recurso estático, pois é atualizada a cada lançamento de novos emojis. A Figura 4.2 traz alguns exemplos de definições da Emojipedia.

As emoções classificadas na Emojipedia não são padronizadas, isto é, não estão embasadas em nenhum modelo de classificação e nem todas as definições apresentam algum tipo de emoção, o que indica que nem todos os emojis são claramente emotivos. Apesar de não indicar o grau de intensidade da emoção sistematicamente, a Emojipedia traz comparações de emojis com outros semelhantes, indicando qual deles é mais intenso e apontando diferenças sutis de significado entre eles. Outra informação que pode aparecer nas definições é o tom expresso por aquele emoji, por exemplo “irônico”, “bobo”, “orgulhoso” etc.

O trabalho de Shoeb e Melo (2020) explora as oito emoções básicas de Plutchik (2001) para classificar 150 emojis, criando o corpus EmoTag1200. O corpus foi anotado por nove anotadores humanos com base em uma escala de 0 a 4 que pontua o grau de associação entre o emoji e cada uma das oito emoções. A métrica de concordância para a anotação foi dada pela correlação de Pearson. Em sua pesquisa, os autores relatam um alto grau de concordância dos anotadores para as emoções “tristeza”, “alegria” e “medo”, enquanto “surpresa”, “confiança” e “antecipação” geraram mais discrepâncias.

¹⁰<https://emojipedia.org/>

 	Beaming Face with Smiling Eyes  Appearance historically differs greatly cross-platform. Use with caution. A yellow face with smiling eyes and full-toothed grin, as if saying <i>Cheese!</i> for the camera. Teeth may be smoothed-over or crosshatched. Often expresses a radiant, gratified happiness. Tone varies, including warm, silly, amused, or proud. Prior to 2017, Apple's design resembled its  Grimacing Face.
 	Face Vomiting A yellow face with scrunched, X-shaped eyes spewing bright-green vomit. May represent physical illness or disgust, more intensely so than  Nauseated Face. <i>Face Vomiting</i> was approved as part of Unicode 10.0 in 2017 under the name "Face with Open Mouth Vomiting" and added to Emoji 5.0 in 2017.
 	Rolling on the Floor Laughing A yellow face with a big grin and scrunched, X-shaped eyes, tilted on its side as if rolling on the floor laughing (the internet acronym <i>ROFL</i>). Sheds two tears and tilts right on most platforms. Often conveys hysterical laughter more intense than  Face With Tears of Joy. Using shown tilted leftwards, though WhatsApp's design tilts to the right. Microsoft's design previously featured a smiley with hands and feet.
 	Love-You Gesture The gesture for "I love you" in American Sign Language, shown as a raised pinky (little) finger, index finger, and an extended thumb. <i>Love-You Gesture</i> was approved as part of Unicode 10.0 in 2017 under the name "I Love You Hand Sign" and added to Emoji 5.0 in 2017.

Figura 4.2: Exemplo de definições extraídas da Emojipedia.

Para avaliar o método, eles calculam o grau de concordância entre o seu corpus e a classificação por modelos computacionais, verificando que há alta correlação entre a etiquetagem por humanos e máquinas.

Pesquisas recentes treinaram vetores para representar as emoções expressas por emojis, semelhantes aos *embeddings* afetivos, mas voltados para emojis. Essas representações são geradas pelo treinamento de um modelo para identificar associações entre um texto e emojis. O texto pode ser uma definição do emoji, palavras associadas a ele ou seu contexto de ocorrência. Nessa linha de pesquisa, Barry, Jameel e Raza (2021) propõem o Emojional, um corpus de *embeddings* pré-treinados para a representação de emoções de emojis. Para treiná-los, os autores utilizam definições extraídas da Emojipedia e da EmojiWiki¹¹ a cerca de 1816 emojis, criando um corpus com três tipos de

¹¹<https://emojis.wiki/>

conteúdos: a descrição visual e física do emoji (por exemplo, “rosto sorrindo” e “mãos para cima”), expressões emotivas (como “resistência”, “alegria” e “apreciação”) e informações de cunho contextual ou social, como o uso do emoji.

4.4 As relações entre emoções e ironia

A interpretação de uma ironia envolve aspectos externos ao texto e a emoção que o locutor quer transmitir ao seu público é um deles. A compreensão das emoções subjetivas em um discurso pressupõe identificar sua sinceridade ou insinceridade, portanto a tarefa de Detecção de Ironia é relevante para a resolução da Análise de Sentimentos e de Emoções (YAGHOUBIAN; ARABNIA; RASHEED, 2021). Por outro lado, o jogo de emoções expresso em uma ironia são cruciais para a sua classificação, já que vemos um conflito de vozes em que uma emoção implícita é mascarada por uma superficial.

Akimoto et al. (2014) argumentam que “a ironia verbal implica uma atitude emocional subjacente que difere do significado do que foi dito”. Para os autores, os aspectos afetivos são importantes, pois estão envolvidos no processamento de pistas emocionais interpretativas, como expressões faciais, e estão relacionados à função social da ironia, que pode ter como objetivo expressar uma atitude negativa do falante, causar um efeito humorístico, condenar o ouvinte etc.

Nas interações cara-a-cara, a *atitude emocional subjacente* se concretiza nas pistas extralinguísticas, entre os quais estão a expressão facial, o tom de voz, a ênfase de determinadas palavras etc. Bromberek-Dyzman (2012) propõe que essas pistas são sinais afetivos, mas não são exclusivos da ironia, portanto são insuficientes para distinguir ironia de não-ironia. Para a autora, o contexto é a chave para a identificação da ironia e as emoções implícitas se qualificam como essenciais ao contexto irônico, apesar de essa relação ter sido pouco explorada na literatura.

Katarzyna diferencia duas camadas interpretativas em uma ironia, uma proposicional e outra não-proposicional carregada de conteúdos afetivos. Ela sugere que a emoção é relevante para o reconhecimento de uma ironia por seu

conteúdo modal implícito, compreendido como a carga de atitudes críticas ou elogiosas que estão fora do nível proposicional. Argumenta que em interações comunicativas as pessoas querem saber os sentimentos transmitidos por outrem, que são avaliados por uma distinção entre bom e ruim. Essa ideia de valência (positiva ou negativa) é considerada uma forma básica de avaliação de atitude para a autora, além de uma propriedade elemental das emoções.

Com base nessas considerações, pode-se dizer que o texto irônico é dotado de uma carga emocional implícita que não condiz com o conteúdo expresso pelo texto e é avaliada como uma atitude positiva ou negativa. Essa avaliação é dependente de contexto e não existem pistas pré-definidas para a ironia, apesar de fatores extra-linguísticos poderem ajudar a identificá-la.

Nas redes sociais, em que a maioria do conteúdo linguístico produzido é escrito, variados artifícios foram pensados para tentar substituir as formas de expressão extra-linguísticas que dispomos em interações não-virtuais, entre eles os emojis, as figurinhas, os GIFs, as imagens e os vídeos, além das hashtags que, mesmo sendo textuais, funcionam de uma maneira diferente de textos comuns. Esses são muito úteis para a Detecção de Ironia, pois além de fornecerem informações contextuais, podem estar associados aos sentimentos subjacentes que o usuário quer explicitar. Um exemplo do uso de emoji e de hashtag em textos irônicos é dado na Figura 4.3.




Figura 4.3: Exemplo do uso de emoji em um texto irônico.

O texto do exemplo possui uma emoção intensamente positiva, que é corroborada pelo emoji de coração (❤️) que o segue. Em contraste, a hashtag utilizada (#ironia) junto ao emoji “Rosto com olhos revirados” (🙄) compõem uma carga negativa que não condiz com o texto. A hashtag explicitamente confirma que o texto anterior é irônico, mas o emoji deixa implícita uma emoção que o usuário na verdade sente, representando o que poderia ser uma expressão facial em uma conversa em pessoa.

Analizando textos irônicos, vê-se uma tendência de que a valência do texto irônico seja oposta à valência implícita. Em uma crítica irônica, por exemplo, a emoção aparentemente positiva da declaração esconde uma negativa que o locutor da ironia tinha a intenção de expressar. Quando alguém diz ironicamente “Você é tão inteligente”, querendo dizer “Você é burro”, há uma emoção positiva na sentença que tem sua polaridade invertida na interpretação. Não foram encontradas pesquisas indicando se isso é uma regra, ou seja, se sempre haverá uma inversão, mas esse aspecto pode ser explorado para a identificação de incongruências em ironias.

Pesquisas em Detecção de Ironia já exploraram a inclusão de representações de sentimentos (JOSHI; SHARMA; BHATTACHARYYA, 2015; WALLACE; CHARNIAK et al., 2015; BARBIERI; SAGGION; RONZANO, 2014) e de emoções, pela inserção de traços baseados em dicionários (REYES; ROSSO; VEALE, 2013; CALVO; GAMBINO; GARCÍA MENDOZA, 2020; FARÍAS; PATTI; ROSSO, 2016) e de *embeddings* afetivos (BABANEJAD et al., 2020; AGRAWAL; AN, 2018; AGRAWAL; AN; PAPAGELIS, 2020), com resultados que indicam o benefício da combinação entre detecção de ironia e análise afetiva. Agrawal, An e Papagelis (2020) reportam melhores resultados para modelos treinados a partir de representações de emoções do que de sentimentos, sugerindo que distinguir entre emoções é mais vantajoso para detecção de ironia. Outra vantagem da análise de emoções é que ela traz mais informações do que a de sentimentos, podendo ser usada para explorar os contextos de produção de uma ironia. Para exemplificar, nem todos os contextos com uma polaridade negativa são propícios para a produção de uma ironia: a tristeza é negativa, porém tende a ser menos caracterizadora de uma ironia do que a raiva.

Nesta pesquisa, examinar-se-á como a identificação de emoções contidas no nível textual e não-textual se combinam para compor uma pista contextual de uma ironia. Bromberek-Dyzman (2012) traça uma relação entre o contexto, a emoção e a ironia que privilegia o papel das emoções para o entendimento de um contexto como irônico por demonstrar uma atitude do locutor, percebida como positiva ou negativa, que difere do seu conteúdo proposicional. Na Roda de Emoções de Plutchik (1962), o psicólogo organiza as oito emoções básicas em pares de oposição. Esta pesquisa explora o modelo de emoções

de Plutchik como pista contextual para o reconhecimento de incongruências entre o que é dito e o que é interpretado. A hipótese levantada é a de que emoções opostas ocorrendo no mesmo texto ou entre o texto e o contexto podem indicar incongruências relacionadas à ironia, como no exemplo da Figura 4.3, em que o texto transmite uma emoção de alegria e confiança e o emoji indica desprezo.

5 | Elaboração de um corpus de ironia

Sardinha (2004, p. 3) define corpus como “um conjunto de dados linguísticos textuais coletados criteriosamente, com o propósito de servirem para a pesquisa de uma língua ou uma variedade linguística”. Desse modo, a criação de um corpus pressupõe um objetivo e envolve a tomada de decisões sobre aspectos tipológicos, como o tipo de documento (escrito ou falado), o conteúdo (especializado, regional ou multilíngue), o tempo (sincrônico, diacrônico, contemporâneo ou histórico) e a representatividade, ou seja, o número de sentidos que uma forma pode assumir (SARDINHA, 2004).

Um corpus é um material indispensável na área de Processamento de Língua Natural, é o objeto que servirá para o levantamento e o teste de hipóteses e para a avaliação de modelos computacionais, portanto é o ponto de partida de uma pesquisa. Neste capítulo, serão apresentados os procedimentos adotados para a criação de um corpus de ironia para o português, começando por uma breve discussão de conceitos gerais sobre os tipos de corpora usados na tarefa e materiais disponíveis para o português. Em seguida, relata-se o método de coleta dos dados, incluindo a delimitação temporal e temática e as diretrizes para a etapa de anotação manual de parte do material. O capítulo finaliza com uma descrição estatística do corpus.

5.1 Conceitos gerais de corpora de ironia

A Detecção Automática de Ironia é usualmente aplicada em documentos de língua escrita, que se diferencia em vários aspectos da língua falada, considerando que a expressão facial e o tom de voz são mais difíceis de representar. Esses documentos são organizados em um corpus digital, isto é, um conjunto de textos escritos armazenados em um formato interpretável por um computador. É comum que os corpora possuam anotação, o que significa que eles são “enriquecidos com informações linguísticas e outras, inserida por humanos ou máquinas (podendo ser uma combinação de ambos) em via de um objetivo teórico ou prático” (HOVY; LAVID, 2010, p. 1). Para a Detecção de Ironia, a informação relevante na anotação é se um texto é irônico ou não, mas outros aspectos também podem ser anotados, a depender dos objetivos do trabalho.

Existem duas estratégias principais para a anotação de corpora de ironia: manual e auto-rotulação (do inglês, *self-annotation*) ou anotação por *hashtag*. A primeira é feita por humanos, geralmente especialistas na área, e a segunda é quando o próprio usuário sinaliza que está sendo irônico por meio de *hashtags* ou outro tipo de sinalização compartilhada entre os usuários de uma rede. Joshi, Bhattacharyya e Carman (2017) apontam algumas vantagens da anotação por *hashtag*, como o fato de que o próprio usuário está indicando que está sendo irônico e a possibilidade de criação de corpora maiores.

Entretanto, esse método pode conter muitos erros de anotação que não passariam em uma verificação manual, o que é prejudicial ao desempenho do modelo. Um primeiro tipo de erro ocorre quando um exemplo que não contém nenhuma marcação irônica é irônico. Khodak, Saunshi e Vodrahalli (2018) anotaram manualmente parte de um corpus anotado por meio de auto-rotulação e identificaram que cerca de 3% dos textos inicialmente considerados não-irônicos na verdade eram ironias. O segundo erro surge quando textos que apresentam uma *hashtag* irônica não são irônicos, sendo alguns exemplos o uso metalinguístico da *hashtag* (“Eu amo uma #ironia”, por exemplo), a expressão de uma ironia não-verbal (como em “O corpo de bombeiros estava

pegando fogo, que #ironia) e a aparição de outro tipo de figura de linguagem em lugar de uma ironia.

A literatura divide os corpora para Detecção de Ironia em duas grandes categorias de acordo com o texto: curtos e longos (YAGHOOBAN; ARABNIA; RASHEED, 2021; JOSHI; BHATTACHARYYA; CARMAN, 2017). Os textos curtos são aqueles com limitação em tamanho estabelecido pela plataforma, caracterizados por textos de redes sociais. São dados chamados de “ruidosos”, pois contêm linguagem informal carregada de abreviações, gírias, falta de pontuação, emojis etc. Textos longos não contêm limitação de caracteres, podendo ser discussões em fóruns, artigos e revisões de livros e filmes. Yaghoobian, Arabnia e Rasheed (2021) também ressaltam que existem corpora transcritos e diálogos, mas esses são mais incomuns.

As redes sociais têm sido uma das principais fontes para a criação de corpora de ironia (JOSHI; SHARMA; BHATTACHARYYA, 2015), sendo as principais fontes o X e o Reddit. Uma consequência disso é o crescimento de corpora para Detecção de Ironia, já que muitos autores produzem seu próprio corpus para um trabalho específico, mas nem todos são disponibilizados por questões de privacidade de dados. Os corpora abertos, como o do SemEval-2018 (VAN HEE; LEFEVER; HOSTE, 2018a)¹, são em sua maioria compostos de textos em inglês. O português possui alguns corpora para Detecção de Ironia que serão detalhados na subseção seguinte.

5.1.1 Corpora de ironia em português

Dois corpora de ironia em português foram utilizados no IDT² (*Irony Detection in Portuguese*), uma das tarefas proposta como parte do IberLEF-2021 (CORRÊA et al., 2021). Os corpora foram disponibilizados, porém para acessá-los é preciso preencher um formulário solicitando a senha aos organizadores do evento.

O primeiro corpus, criado por Marten e Freitas (2021), é composto de textos longos extraídos de quatro sites de notícias: Nexo Jornal, HuffPost

¹<https://github.com/Cyvhee/SemEval2018-Task3/tree/master>

²<https://sites.google.com/inf.ufpel.edu.br/idpt2021/home?authuser=0>

Brasil, The Piauí Herald e Sensacionalista. Os dois primeiros publicam notícias reais e os dois últimos são de notícias humorísticas. A classificação dos textos foi baseada na fonte da qual o artigo havia sido coletado, considerando “não-irônicos” os dos sites de notícias reais e “irônicos” os dos humorísticos. Portanto, o corpus não possui anotação manual e sua classificação se baseia no texto completo e não em partes, como frases ou parágrafos. No total, o corpus possui 18003 notícias, 7229 irônicas e 10774 não-irônicas, coletadas ao longo de 2020.

O segundo corpus foi desenvolvido por Da Silva (2018) como parte de seu trabalho final de conclusão de curso (TCC). Ele é composto de 15400 tweets anotados por auto-rotulação, sendo 12700 irônicos e 2700 não-irônicos. As *hashtags* usadas para identificar ironia foram “#ironia” e “#sarcasmo”. Para os não-irônicos, foram buscados textos sobre economia, política e educação que não contivessem as *hashtags* citadas. Os dados foram coletados entre 2014 e 2017 e não foram revisados manualmente.

Esses materiais serviram de dados de treinamento e teste no IDT, de modo que foram considerados um parâmetro para a comparação do estado-da-arte em Detecção de Ironia para o português, trazendo visibilidade para a tarefa. A iniciativa fortaleceu a importância da disponibilidade de corpora para a validação de desempenho de modelos. Todavia, nesta pesquisa, optou-se por criar um corpus de ironia próprio, pois assim seria possível controlar o tipo de texto e os materiais que seriam interessantes para a nossa pesquisa. Um dos pontos que consideramos em nosso corpus foi a inserção do texto em um contexto conversacional, semelhante ao que foi feito em Srivastava et al. (2020) e Ghosh, Fabbri e Muresan (2018), a fim de recuperar pistas contextuais que são valiosas para a percepção de uma ironia.

5.2 Coleta de dados para o corpus

Para a construção do corpus, coletaram-se textos públicos da rede social X³. A raspagem dos dados foi executada pela API da plataforma⁴ a partir de

³<https://x.com/home>

⁴<https://developer.x.com/en>

uma conta de desenvolvedor que permite acessar e extrair tweets, além de determinados dados, como o número de seguidores do usuário e curtidas da publicação. A conta de desenvolvedor usada era de pesquisador, que possui um limite de 10.000.000 de tweets por mês e permite buscas em qualquer data, especificada por dia, mês e ano. A escolha da ferramenta oficial em vez de outras bibliotecas de raspagem foi um meio de evitar problemas com os termos de serviço do site.

Restringiu-se o escopo de busca a três temáticas (Política, Saúde e Entretenimento) com uma janela temporal entre os anos de 2020 e 2021. As coletas foram mensais, limitadas a cem resultados por mês. As buscas se basearam em 50 palavras-chave por tema, listadas na Tabela 5.1, e em três *hashtags* (#ironia, #sarcasmo e #sqn) para capturar tweets potencialmente irônicos. As palavras-chave podem ser compostas de uma ou mais palavras. A *hashtag* “#sqn”, abreviação de “só que não”, é muito utilizada em contextos em que o usuário quer desmentir o que disse anteriormente, o que inclui contextos irônicos. Cabe ressaltar que foram feitas buscas separadas por tema, assim não haveria o risco de desbalanceamento do corpus.

Vários testes foram necessários para a seleção das palavras-chave, inicialmente compostas de um conjunto pequeno de termos de busca que se expandiu conforme novas palavras relevantes foram identificadas. Os temas englobam conceitos gerais e específicos, motivados pelo interesse de capturar assuntos que estavam em alta na época. Entre 2020 e 2021, a pandemia da Covid-19 foi um dos assuntos predominantes na rede social, portanto buscou-se por termos como “gripezinha”, “isolamento social” e “vacina”, além de nomes de ministros da Saúde atuando no período, como “Queiroga”, de Marcelo Queiroga, e “Mandetta”, de Luiz Henrique Mandetta. As eleições presidenciais de 2022 também foram um tópico muito discutido, o que justifica palavras como “eleições”, “voto impresso” e “impeachment”. O nome do ex-presidente Jair Bolsonaro e de alguns de seus ministros retornaram muitos resultados de busca, mostrando-se termos relevantes. Para Entretenimento, selecionaram-se palavras principalmente relacionadas ao programa de televisão Big Brother Brasil (BBB), que costuma gerar muita comoção entre os usuários, e às plataformas de *stream*, como Netflix, Disney, Prime Video e HBO.

Tema	Palavras-chave
Saúde	covid, coronavírus, covid19, quarentena, pandemia, hospital, hospitais, vírus, ansiedade, depressão, vacina, vacinas, vacinação, sus, saúde, doença, doenças, saudável, saudáveis, doente, doentes, gripe, resfriado, virose, remédio, remédios, oms, gripezinha, cloroquina, ivermectina, lockdown, mandetta, teich, pazuello, queiroga, coronavac, pfizer, astazeneca, covaxin, ômicron, “isolamento social”, aglomeração, anvisa, “distanciamento social”, antivax, antivacina, imunizante, imunização, “tratamento precoce”, UTI
Entretenimento	filme, filmes, festa, festas, jogo, jogos, videogame, música, músicas, cinema, quadrinho, quadrinhos, livro, livros, novela, novelas, netflix, futebol, spotify, twitch, oscar, carnaval, carnavais, bbb, bbb20, bbb21, libertadores, tiktok, f1, live, afazenda, afazenda12, afazenda13, masterchef, nolimite, copa, hbo, “prime video”, “disney plus”, youtube, olimpíadas, basquete, vôlei, podcast, campeonato, karaoke, grammy, globoplay, meme, memes
Política	governo, governos, corrupção, anticorrupção, democracia, ministro, ministra, ministros, senador, senadora, senadores, deputado, deputada, deputados, governador, governadora, prefeito, prefeita, presidente, política, políticas, ditadura, mamata, bolsonaro, trump, biden, “sérgio moro”, “rodrigo maia”, weintraub, “fabrício queiroz”, “paulo guedes”, witzel, rachadinha, eleição, eleições, cpmi, cpi, “lava jato”, “auxílio emergencial”, impeachment, “voto impresso”, manifestações, “urna eletrônica”, “pedalada fiscal”, patriotismo, desgoverno, antidemocrático, antidemocráticos, político, políticos

Tabela 5.1: Palavras-chave usadas na coleta.

Realizaram-se raspagens separadas para os textos irônicos e não-irônicos. Na busca pelos irônicos, o texto-alvo deveria incluir ao menos uma das *hashtags* de ironia e uma palavra-chave. Já no caso de não-ironia, o texto precisava conter ao menos uma das palavras-chave e não apresentar nenhuma das *hashtags* de ironia. Sendo assim, todos os dados coletados estão relacionados a uma das temáticas.

Outros parâmetros de coleta estabeleceram que o texto deveria estar em português, não poderia ser um retweet e nem conter mídias (imagens, GIFs ou vídeos) e tinha de ser uma resposta. A especificação do último parâmetro significa que o tweet coletado é precedido por um ou mais tweets. No X, isso se chama *thread*: uma sequência de tweets que se organiza semelhantemente aos turnos em uma conversa. Esse aspecto da rede social foi usado para que o tweet-alvo fosse analisado dentro de seu contexto conversacional. Desse modo, além de coletar o tweet-alvo, extraiu-se o tweet que o antecede, isto é, aquele ao qual o usuário estava respondendo, seguindo o exemplo na Figura 5.1.




Figura 5.1: Exemplo de uma *thread* extraída do X.

Por questões de capacidade de armazenamento e simplificação da tarefa, coletamos apenas o tweet antecedente ao tweet-alvo em vez de coletar a *thread* inteira, tendo em vista que ela pode conter vários níveis de camadas para analisar. Ademais, a resposta imediatamente anterior tende a ser mais informativa para a compreensão da seguinte do que um longo histórico. Em um diálogo, é pouco provável alguém fazer uma ironia sobre algo dito dez turnos atrás, até mesmo por limitações de memória e para evitar uma quebra na conversa, a não ser que o tópico volte para a discussão ou seja uma piada

interna entre os envolvidos. Dito isso, para fins desta pesquisa, consideramos como contexto conversacional do corpus apenas o turno precedente ao texto em análise.

Ao fim da coleta, obtivemos 11656 exemplos, sendo 5816 de 2020 e 5829 de 2021. Os exemplos contêm um tweet-precedente (contexto), um tweet-alvo (texto) e informações fornecidas pela plataforma, como o número de identificação do tweet e a data de publicação. Com o intuito de limpar o corpus, filtraram-se textos que contivessem menos do que dez palavras alfanuméricas para excluir aqueles compostos unicamente de emojis, *hashtags* ou menções. Os textos duplicados foram retirados, mantendo-se apenas sua primeira ocorrência, mas os contextos duplicados foram mantidos. Isto é, o mesmo contexto pode ter diferentes respostas-alvo, pois estavam na mesma *thread*. Em alguns casos, o contexto estava vazio, o que ocorre quando uma conta não existe mais ou é protegida, portanto esses foram excluídos. Após a limpeza, restaram 5373 exemplos somando os anos de 2020 e 2021.

5.3 Anotação manual do corpus

Como discutido na Seção 5.1, um corpus baseado somente na anotação por *hashtag* está sujeito a erros de classificação que podem induzir o modelo a previsões ruins. Por essa razão, uma amostra aleatória do corpus contendo 1200 exemplos foi separada para uma anotação manual feita por mim e três anotadores voluntários da USP, sendo um aluno de graduação e dois de pós-graduação, todos formados em Letras e falantes nativos do português. O objetivo dessa etapa era ter uma classificação feita por anotadores humanos para obter um corpus mais confiável e poder calcular a taxa de erro da anotação por *hashtag*.

A tarefa dos anotadores era ler o texto e o contexto para atribuir uma classificação de “irônico” ou “não-irônico” ao exemplo, em que o contexto fornecia pistas para ajudar na classificação do texto, mas ele próprio não deveria ser classificado. As instruções fornecidas aos anotadores estão no “Manual de Anotação” anexado no Apêndice A. Esse material apresenta definições da tarefa, instruções e exemplos para a anotação do corpus.

Antes do processo de anotação, todos os links do corpus foram substituídos por um símbolo especial “<URL>” com a finalidade de evitar que os anotadores tivessem acesso a informações externas ao texto. Não excluimos as *hashtags* marcadoras de ironia (#ironia, #sarcasmo e #sqn) por diversas razões, estando cientes de que elas poderiam influenciar na classificação dos anotadores. Primeiro porque determinados exemplos só podem ser identificados como irônicos se forem indicados pelo próprio usuário, seja por serem ambíguos, por contexto insuficiente ou falta de conhecimento sobre hábitos e gostos do autor do tweet. Segundo, como apontado por Joshi, Bhattacharyya e Carman (2017), a *hashtag* é um alerta explícito de ironia fornecido pelo usuário, portanto desconsiderá-la seria ignorar a intenção de que aquele texto seja interpretado como irônico. Desse modo, os anotadores foram instruídos a considerar as *hashtags* para a classificação, podendo discordar delas nos casos em que seu uso parecesse inapropriado.

O corpus para anotação foi organizado em uma planilha no Google Sheets contendo cinco colunas: “ID”, “Turno 1”, “Turno 2”, “Classificação” e “Observação”. A primeira se refere ao número de identificação do tweet, os Turnos 1 e 2 são, respectivamente, contexto e texto. A coluna de classificação foi deixada em branco para que os anotadores inserissem a etiqueta correspondente, enquanto a última coluna servia para que eles deixassem comentários que considerassem relevantes, dificuldades e dúvidas. A Figura 5.2 traz um exemplo do corpus de anotação.

A	B	C	D	E
ID	Turno 1	Turno 2	Classificação	Observação
136473477923350338	"Fundamentalmente, é para evitar eventos, aglomerações. Quando as pessoas bebem e perdem o controle, perdem a capacidade de usar suas máscaras, expõem o vírus, multiplicam a contaminação e ampliam a possibilidade de óbitos". João Doria Não é. Hoje é o último jogo do São Paulo na Era Leco. • 5 anos • 9 treinadores • Mais de 200 milhões em reforços • 16 eliminações • 0 títulos • Dívidas aumentaram em quase 300 milhões	QUE BELEZA, #sqn Aqui no Paraná a justificativa foi essa - das mortes e acidentes violentos. Citaram os nº, demanda de atendimento de emergência, as vagas de UTI, stress dos médicos, etc. Depois de um tempo verificaram queda significativa. Bem interessante.		
1344432937681510406	Até nunca mais. <URL>	Se eu fosse presidente, a primeira coisa que faria seria zerar essa dívida, depois que zerar a dívida, TUDO é lucro. Da pra fazer tudo sem pensar em guardar dinheiro pra pagar dívida		
1306275189957824513	Sargento da PM condenado por chefear milícia é solto pela Justiça e apresenta candidatura a vereador <URL> <URL> GIZELLY É DO MAL, UMA MULHER AMARGURADA!!! "AINDA BEM QUE O PRIOR SAIU" "FLAY VAI SAIR AGORA"	Criminosos entrando na política, que novidade... #SQN! Este o 'normal' neste paiseco de 7o mundo! A Gizelly tá em um JOGO + não pode torcer q NÃO ganhe quem indica ela p/ o paredão? Não pode ficar aliviada se quem a indica saiu da prova? Realmente, pecado terrível a Gi		

Figura 5.2: Fragmento da planilha do corpus usada para anotação.

Cada um dos três anotadores voluntários recebeu uma planilha contendo 100 exemplos, enquanto 900 foram anotados por mim. As amostras eram constituídas por conjuntos de exemplos distintos, portanto, cada um deles foi classificado uma única vez por apenas um anotador. O cenário ideal para garantir a credibilidade de um corpus é ao menos dois anotadores independentes anotando o mesmo conjunto de dados de modo que as classificações de ambos possam ser comparadas e seja estabelecida uma taxa de concordância entre anotadores (HOVY; LAVID, 2010). Entretanto, a falta de tempo e de disponibilidade de pessoal, considerando que os anotadores eram voluntários, não nos permitiu fazer essa anotação mais rigorosa.

Em uma tentativa de contornar essa dificuldade, foi solicitado aos anotadores voluntários que os casos que suscitasse dúvidas sobre a classificação fossem marcados, seguindo as instruções do manual. De 1200 exemplos, 177 causaram dúvidas nos anotadores, correspondente a 14,7% do corpus. Esses exemplos foram revistos e discutidos entre os anotadores ou entre eu e meu orientador. A maioria desses eram casos difíceis, em que o contexto para a interpretação estava ausente, o texto era muito confuso ou a ironia se mesclava com piadas e provocações. Alguns exemplos são dados a seguir, em que (T1) e (T2) significam, respectivamente, Turno 1 e Turno 2.

I-(T1) O Senado acabou de aprovar uma renda básica emergencial de R\$ 600 para trabalhadores autônomos e R\$ 1.200 para mães responsáveis pelo sustento da família. Agora só falta Bolsonaro sancionar! #Paga-LogoBolsonaro <URL>

I-(T2) esse governo bolsonaro ta de fazer inveja pra qualquer recalcado petista ... enquanto o lula dava bolsa miseria o bozo bota pra fude 600tão ... agora que ele nao sai mais da presidencia....

No Exemplo I, T1 traz uma notícia sobre a aprovação do auxílio emergencial pelo Senado, ao que o usuário em T2 aparentemente defende o governo Bolsonaro, comparando com o “bolsa miséria” (Bolsa Família) do governo Lula. Esse texto gerou discussão, pois é difícil saber se o usuário está sendo sincero ou irônico, já que ele parece ironizar o valor do auxílio ao optar

pela expressão “bota pra fude 600tão” e utilizar reticências que geram um prolongamento no texto, como se o usuário deixasse algo implícito nessas pausas. Esse é um exemplo em que seria necessário saber mais sobre o autor do texto para compreender suas convicções e seu posicionamento político e confirmar se se trata de uma ironia ou não.

II-(T1) Diretor do Butantan acusa Anvisa de atrasar importação de matéria-prima para vacina <URL>

II-(T2) Que coisa. O tempo revela tudo mesmo. O calça apertada deve ter prometido fechar o “forecast” de vendas dos chineses de 2020, #sqn. Por isso deve ter ficado desesperado por fechar questão com o governo quando viu que a coisa não andava na Anvisa. Que cara que não dá para confiar!

O Exemplo II também foi considerado difícil, pois o usuário sinaliza uma possível ironia (#sqn) que não foi capturada em nenhuma leitura feita por nós. Se ela está presente, foi bem específica e sutil. Para esse caso, considerou-se a necessidade de mais dados do contexto a que o texto se refere para a classificação do exemplo.

III-(T1) Bolsonaro mostra exatamente o que é diariamente. O problema é que a mídia não leva a sério, a elite brasileira acha que Bolsonaro e esses ao redor dele são loucos, enquanto um golpe militar vem sendo cozinhado desde 2018; basta você olhar pro genocídio de hoje pra ter a resposta!

III-(T2) Estamos esperando a ditadura prometida pela esquerda delirante desde 2018 mesmo. Olha só de onde ela veio. 😏 <URL>

No Exemplo III, temos um contexto em que o usuário acusa o ex-presidente de estar preparando um golpe militar e o segundo parece caçoar da acusação ao dizer “Estamos esperando a ditadura prometida pela esquerda delirante”, mas essa possível ironia não está evidente no texto. Esse exemplo é acompanhado de um *link*, que poderia conter a informação para desambiguá-lo. Por uma

questão prática, não disponibilizamos os *links* aos anotadores, pois essa informação não foi utilizada pelo modelo de detecção de ironia. O pressuposto em que nos baseamos é que se não fosse possível para um humano classificar o texto sem a informação da URL, o mesmo valeria para o modelo.

Dos casos que geraram dúvidas de classificação nos anotadores, excluíram-se 14 do corpus por falta de consenso a respeito de sua classificação, restando 1186 exemplos na versão final anotada.

O corpus anotado manualmente foi comparado ao anotado por *hashtag*, em que um exemplo foi considerado irônico se contivesse uma *hashtag* irônica (#sarcasmo, #ironia e #sqn) e não-irônico, caso contrário. A Tabela 5.2 traz uma matriz de confusão comparando os dois métodos e uma taxa de discordância d por categoria, dada por $d = \sum (m^{(i)} \neq h^{(i)})/t$, em que m é a etiqueta da classificação manual na posição i , h é a etiqueta da classificação por *hashtag* na posição i e t é o total de exemplos no corpus de anotação por *hashtag*. Aplicamos esse cálculo a cada uma das categorias (ironia e não-ironia). Ao todo, 100 exemplos foram classificados distintamente pelos métodos, correspondente a 8,4% do corpus.

		Anotação por <i>hashtag</i>	
		Ironia	Não ironia
Anotação manual	Ironia	502	39
	Não ironia	61	584
Discordância		0,10	0,06

Tabela 5.2: Comparação entre a anotação manual e a anotação por *hashtag*.

As discordâncias encontradas são de dois tipos: os falsos positivos – exemplos que tinham uma *hashtag* de ironia, mas não eram irônicos – e os falsos negativos – que não possuíam *hashtag* de ironia, mas eram irônicos. Houve maior discordância sobre o que era ironia (61) do que sobre não-ironia (39), ou seja, um número maior de falsos positivos. Analisando os dados para compreender o motivo dessa discordância, verificou-se que a *hashtag* #sqn tinha mais de um uso, que pode ser irônico ou não-irônico, como mostra o Exemplo IV.

IV-(T1) Jair Bolsonaro ficará marcado para sempre como o presidente que não cuidou nem da saúde nem da economia durante a pandemia.

IV-(T2) 🤔🤔🤔🤔🤔 vcs são idiotas achando q estão falando com idiotas. #sqn Bolsonaro. Melhor remédio contra esquerdopatas.

Nesse exemplo, o usuário em T2 rebate a crítica do primeiro afirmando que eles pensam estar falando com idiotas, mas que eles não são idiotas. Assim, a *hashtag* #sqn não desmente o que foi dito anteriormente, ela indica uma sentença opositiva implícita em que “só que não” funciona como “mas”. Veja que a interpretação da sentença não é “Vocês não acham que estão falando com idiotas” ou “Vocês não são idiotas”, de modo que não há nenhum indicativo de ironia no texto, nenhuma possível incongruência de significado. Portanto, conclui-se que não se trata de uma ironia. Desse modo, essa *hashtag* não pode ser usada com 100% de confiança para a classificação de ironia em português.

Por sua vez, os falsos negativos equivalem a 6% dos não-irônicos, uma taxa maior em comparação à pesquisa de Khodak, Saunshi e Vodrahalli (2018), cujos autores verificaram que 3% dos exemplos que não apresentavam *hashtag* na verdade eram irônicos. O corpus dos autores foi extraído do Reddit, em que o uso de marcador de ironia é mais frequente do que no Twitter, como eles próprios ressaltam no artigo, o que explicaria a diferença. Sendo assim, para um corpus do Twitter, em que a auto-rotulação parece ser menos usual, é ainda mais relevante fazer uma revisão manual.

Além disso, os falsos negativos são mais difíceis de detectar considerando que nem sempre há uma pista marcante para a ironia. Orientaram-se os anotadores a não considerar um texto inicialmente não-irônico como ironia se não houvesse nenhuma pista que a evidenciasse, seja pelo texto ou contexto, por emoji ou *hashtag*. Quando não havia certeza sobre a presença de ironia, optou-se por manter a classificação como “não-ironia”. Esse problema se torna ainda pior quando a ironia é construída com base em opiniões pessoais, hábitos e posicionamento político. Por exemplo, dado um contexto muito negativo em que alguém está criticando o governo de Bolsonaro, outro poderia responder com “Bolsonaro é o melhor presidente de todos”, o que poderia ser

uma ironia ou algum defensor do ex-presidente. Sem nenhuma pista irônica seria impossível desambiguar o texto.

Já quando havia pistas reforçando a ironia, a classificação foi alterada, como no exemplo seguinte.

V-(T1) Para o bem da saúde e o combate à corrupção a #DireitaQuerImpeachment do 🐭Bolsonaro🐭...

V-(T2) Se preocupem não, eu soube que bolsonaro vai sair SÓ QUE NO FINAL DE 2026 kkkkkkkkkk

No exemplo, o usuário em T2 introduz o texto ironicamente com “se preocupem não” e depois anuncia que Bolsonaro sairá apenas em 2026, frustrando a expectativa dada inicialmente em uma zombaria ao pedido de impeachment de T1. Essa ironia é reforçada pelo uso de letras maiúsculas no trecho “SÓ QUE NO FINAL DE 2026” e pela expressão de risos. A contradição interna no texto, portanto, mostra que se trata de uma ironia, mesmo que não haja nenhuma *hashtag* sinalizando-a.

VI-(T1) O Brasil colapsou em seu sistema público e privado de saúde. O governo federal não faz nada. Será que vamos permitir em silêncio a morte coletiva de milhões de brasileiros? Interditar Bolsonaro é uma questão de VIDA! Não podemos aceitar mais isso! #ForaBolsonaroGenocida

VI-(T2) Ele faz sim trabalha inepteuruptamente para encher hospitais e ver se dão conta mesmo!

O Exemplo VI é irônico por uma incongruência interna entre “ele faz sim trabalha ininterruptamente” e “encher hospitais”, quebrando a expectativa construída a fim de gerar uma interpretação de ironia. Assim como no caso anterior, o usuário faz o leitor crer em algo que ao final do texto se mostra uma inverdade, isto é, que ele acredita que Bolsonaro trabalha.

A etapa de anotação ajudou na compreensão das dificuldades encontradas na classificação de ironia até mesmo por anotadores humanos. Foi possível analisar o emprego das *hashtags* pelos usuários no X e sua importância para

a identificação de ironia, uma vez que sem ela é mais difícil detectá-la mesmo tendo o contexto, com exceção de exemplos claramente irônicos. Esses em geral apresentam uma contradição interna ou com o contexto, idealizam cenários absurdos ou usam marcações textuais, tais como aspas e caixa alta, emojis e *hashtags*. Também foi possível verificar que as *hashtags* não são tão confiáveis e podem ter mais de um significado, como o caso de #sqn. Isso reforça a ideia de que as pistas de ironia são dependentes de contexto de produção, portanto uma análise humana é essencial para desambiguar tais ocorrências.

5.4 Estatísticas do corpus

O corpus anotado e revisado final contém 1186 exemplos constituídos de um contexto (T1) e um texto (T2) classificado em “ironia” ou “não ironia”. A Figura 5.3 fornece a distribuição do corpus por Tópico, Ano, Etiqueta e Hashtag.




Figura 5.3: Distribuições gerais do corpus.

A distribuição por Tópico está balanceada, com Saúde e Política sendo os mais frequentes, com 416 e 403 exemplos, e Entretenimento um pouco abaixo,

com 367. Vale ressaltar que os tópicos muitas vezes estão mesclados um ao outro, isto é, as categorias não são exclusivas: vê-se textos que tratam sobre política e saúde, política e entretenimento, saúde e entretenimento e assim por diante. Isso aconteceu particularmente para Saúde e Política, dado o cenário da pandemia, pois os assuntos estavam ainda mais próximos. A divisão em tópicos serviu para a delimitação de assuntos de interesse para construção do corpus, mas ela não é precisa. O Ano, segundo critério relacionado à coleta, também tem um número equilibrado de exemplos entre 2020 e 2021, o que corrobora que as palavras-chave buscadas foram relevantes nos dois anos.

Para a Classificação, os exemplos não-irônicos (645) foram mais frequentes do que os irônicos (541), o que está relacionado ao método de busca adotado. Em cada busca, cada tópico recebia um parâmetro de limite máximo de resultados (100) por mês, porém para os tweets irônicos, nem sempre a busca retornava o valor máximo de resultados, enquanto os não-irônicos eram mais fáceis de capturar. Isso aconteceu porque determinados tópicos não retornaram tantos exemplos irônicos quanto não-irônicos. No entanto, as duas categorias estão balanceadas considerando que a diferença entre elas é pequena (cerca de 100 exemplos).

A distribuição das *hashtags* usadas para coleta (*#sarcasmo*, *#ironia* e *#sqn*) mostra que *#sqn* é a mais usada entre as três para a marcação de ironia no X (456), seguida de *#ironia* (106). Julgamos esse resultado intrigante, já que a expressão “só que não” que derivou a *hashtag* parece ter sido normalizada entre a comunidade brasileira na rede social, tendo como uma de suas funções expressar uma ironia. Os usuários mostraram preferência pela *hashtag* *#sqn* em vez de *#ironia*, que é explicitamente irônica. Uma possível explicação para isso é que a primeira é menos direta, mais exclusiva e mais divertida do que a segunda. É preciso estar dentro das redes sociais para saber o seu significado e dominar seu uso, além dela se assemelhar mais ao discurso oral. Não sendo tão restrita, o usuário nem mesmo precisa ter consciência de que aquilo se trata de uma ironia, mesmo que seja o que ele quer transmitir.

Além dos aspectos gerais do corpus, estatísticas textuais são úteis para avaliar as informações de conteúdo. A Figura 5.4 apresenta as quinze *hashtags*, menções, palavras e emojis mais frequentes no corpus. Descartaram-se as três

irônicas (presentes na Figura 5.3) e as palavras consideradas *stopwords*. Os dados nos quatro gráficos representam uma somatória das contagens no texto e no contexto.




Figura 5.4: Estatísticas de palavras, hashtags, emojis e menções mais frequentes.

As *hashtags*, os emojis e as menções não têm muitas ocorrências no corpus, sendo no total são 413 *hashtags*, 672 emojis e 281 menções. Entre as *hashtags* mais comuns temos algumas relacionadas a Política (#forabolsonaro, #forabolsonarourgente e #bolsonaro2022), a Saúde (#covid19 e #coronavirus) e a Entretenimento (#bbb21, #bbb20 e #redesbb) que reforçam a relação dos textos com os tópicos selecionados. Sobre as menções, o usuário mais citado nos textos foi o ex-presidente Jair Bolsonaro (@jairbolsonaro), com uma grande diferença para o segundo lugar pertencente ao grupo de k-pop sul-coreano BTS (@BTS_twt). As palavras mais frequentes incluem termos da busca, entre elas “presidente”, “bolsonaro”, “pandemia” e “covid”, assim como abreviações comuns usadas em redes sociais, como “tá” de “está” e “pra” de “para”. Nos emojis mais frequentes estão o “Rosto Chorando de Rir” (😂) e o “Rolando No Chão De Rir” (🤔), ambos associados a emoções alegres,

mas que também são muitos usados para zombar de alguém, principalmente o segundo. O “Rosto Com Olhos Revirados” (🙄), muito usado para expressar desprezo ou indiferença, também é forte indicativo de uma ironia a depender do contexto.

O corpus anotado se mostrou bastante balanceado nos dois critérios de busca (Tópico e Ano) e na classificação (ironia e não-ironia), o que diminui a possibilidade de viés do modelo por alguma especificidade em algum desses. Esse corpus serviu para o desenvolvimento e a avaliação do modelo de ironia implementado e, posteriormente, será disponibilizado abertamente para que outros interessados possam usá-lo.

6 | Arcabouço teórico dos modelos computacionais

A modelagem computacional é uma área que lida com a aplicação de modelos matemáticos para a análise, a compreensão e o estudo de problemas de áreas como Engenharia, Biomedicina e Linguística. Um modelo é um produto voltado para a aplicação, contudo, é importante compreender os fundamentos que o originaram para aprender como ele funciona e ser capaz de propor modificações em via de melhorá-lo. Na Linguística Computacional, diversos modelos se inspiraram em teorias e análises advindas da Linguística. Outros, por sua vez, foram desenvolvidos para outras áreas de aplicação, mas adaptados para o Processamento de Língua Natural. Neste capítulo, serão apresentados dois modelos computacionais que serão utilizados nesta pesquisa: as representações vetoriais de palavras e as redes neurais convolucionais.

6.1 Representações vetoriais de palavras

Um dos objetivos da Linguística Computacional (LC) é investigar técnicas para representar aspectos de línguas naturais para a manipulação e o processamento por computadores. Todavia, para um computador uma palavra não significa nada, na verdade, ela é só uma sequência de bytes. Ao longo da história da LC, diversos métodos de representação de palavras foram propostos, mas as representações vetoriais foram as que mais tiveram sucesso na área, principalmente com o impulsionamento dos modelos de redes neurais.

As representações vetoriais se baseiam na Hipótese Distribucional, originada das ideias apresentadas nos trabalhos de Harris (1954) e de Firth (1957). De acordo com a hipótese, palavras com significados próximos tendem a ter uma distribuição contextual semelhante. Assim, dado o contexto “Ele escreveu...”, algumas possibilidades de continuação prováveis da sentença seriam: “o livro”, “o artigo científico”, “um comentário no Facebook”, enquanto “a mexerica” seria menos provável. Na Hipótese Distribucional, as análises de significado são feitas pela comparação de uma palavra com outras em uma busca por elementos com distribuições contextuais semelhantes em oposição àquelas que são dessemelhantes. Deve-se esclarecer que a concepção de *semelhança* na teoria não significa *sinônimo*. Ao contrário, do ponto de vista distribucional, antônimos como “vida” e “morte” são semelhantes por compartilhar determinados contextos de ocorrência.

Computacionalmente, a distribuição contextual é representada como um vetor associado a uma palavra pertencente a um vocabulário. Uma representação vetorial permite comparar a similaridade entre palavras por métricas como a distância euclidiana, além de serem eficientes do ponto de vista de implementação computacional e capazes de generalizar padrões de ocorrência (LEVY, 2022, p. 334). Existem dois tipos de vetores de palavras: os esparsos, como o TF-IDF (SPARCK JONES, 1972), chamados assim por conterem muitos zeros, e os densos, como os *word embeddings*, que contêm poucos valores em zero. Além disso, o número de dimensões dos vetores esparsos costuma ser muito elevado em comparação ao dos vetores densos.

Os *word embeddings* são uma forma de representar uma palavra como um ponto em um espaço semântico multidimensional que é derivado da distribuição das palavras vizinhas, sendo geralmente treinados por redes neurais (JURAFSKY, Daniel; MARTIN, 2024, p. 105). Há dois tipos de *embeddings*, os não-contextuais e os contextuais. Os *word embeddings* não-contextuais, que incluem o Word2Vec (MIKOLOV et al., 2013), o GloVe (PENNINGTON; SOCHER; MANNING, 2014) e o FastText (JOULIN et al., 2016), são treinados a partir de um grande corpus usando probabilidades de co-ocorrência para capturar informações semânticas e sintáticas do texto. Essas probabilidades são extraídas das palavras vizinhas à palavra-alvo com uma

janela de tamanho n . Esses vetores são estáticos, isto é, eles não consideram a variação de sentidos que uma palavra pode sofrer devido ao contexto, aprendendo um único vetor por palavra. Por sua vez, os modelos contextuais incorporam informações sobre as palavras ocorrendo no contexto para gerar sua representação, sendo os principais representantes dessa categoria os modelos que derivam de redes Transformer (VASWANI, 2017), como BERT (DEVLIN, 2018), RoBERTa (LIU, 2019) e XLNet (YANG, 2019).

6.2 Rede neural convolucional

As redes neurais convolucionais foram originalmente desenvolvidas para tarefas de Visão Computacional de classificação e identificação de objetos em imagens. Recentemente, essas redes têm sido aplicadas no PLN para a classificação em tarefas como o Reconhecimento de Entidades Nomeadas (ZHU; WANG; KARLSSON, 2020; ZHANG, R. et al., 2022) e a Análise de Sentimentos (XU et al., 2018; KALCHBRENNER; GREFFENSTETTE; BLUNSOM, 2014; JAN et al., 2016) e para modelagem de texto na representação de vetores de caracteres (ZHANG; ZHAO; LECUN, 2015; XING et al., 2019).

6.2.1 Breve histórico das redes convolucionais

As redes neurais convolucionais foram inspiradas no córtex visual de vertebrados (HUBEL; WIESEL, 1968), em que neurônios corticais individuais respondem a estímulos apenas em áreas específicas do campo receptivo visual (a área de resposta do estímulo). Isso mostra que a posição exata do objeto não é tão importante quanto a identificação dele, propriedade chamada de *invariância transacional*, o que garante que um objeto permaneça consistente, mesmo que mude de posição (GORACH, 2018). Similarmente, as redes neurais convolucionais buscam por um objeto em uma imagem independente da posição em que ele esteja: espera-se que o modelo identifique um gato mesmo que ele esteja sentado, deitado, virado de lado ou de ponta-cabeça.

A primeira rede neural convolucional foi a Lenet-5, proposta em 1998 por LeCun et al. (1998). A aplicação inicial do modelo foi o reconhecimento de

dígitos escritos a mão em imagens. O modelo recebia como entrada uma imagem de tamanho 32x32 pixels e devolvia a classificação correspondente. Sua arquitetura contém sete camadas escondidas que realizam operações de convolução e *pooling*, com a última sendo uma camada *feedforward*. A estrutura da rede Lenet-5 representa o núcleo básico do que são as redes neurais convolucionais até hoje.

Com o passar dos anos, as arquiteturas dessas redes se tornaram mais complexas, tendo um número maior de camadas escondidas e mais diversidade nas combinações e conexões internas entre os blocos. A GoogLeNet (SZEGEDY et al., 2015) é um exemplo de uma rede convolucional profunda, com 22 camadas escondidas, mas sem camadas *feedforward*, o que reduziu o número de parâmetros da rede em comparação a outras menos profundas. A ResNet (HE et al., 2016) também marcou a história das redes convolucionais ao introduzir blocos residuais que ajudam a evitar problemas de descendência do gradiente que podem surgir com o aumento no número de camadas.

6.2.2 Estrutura da rede convolucional

A estrutura básica de uma rede convolucional se assemelha ao de uma *feed-forward*: uma camada de entrada, camadas escondidas e uma camada de saída. Uma das principais diferenças entre elas está na camada escondida, que possui camadas ausentes na primeira: as de convolução e as de *pooling*. As camadas convolucionais são o núcleo desse tipo de rede, responsáveis por aprender padrões através de pequenas matrizes, chamadas de filtros, que percorrem a entrada. É uma camada linear que calcula o produto escalar entre o filtro e uma região da entrada determinada por uma janela. É comum a camada de convolução ser seguida de uma ativação não linear, como ReLU, sigmoide e tanh. O intuito dessa ativação é tornar o modelo capaz de capturar traços em fenômenos complexos não identificados por operações lineares (KRICHEN, 2023).

Assumindo-se que k é o tamanho da janela de convolução, d é o tamanho do canal de entrada, m é o tamanho do canal de saída, u_i é a concatenação

dos vetores $(x_i, \dots, x_{i+k})$ do passo i até o tamanho da janela k e W é uma matriz de tamanho $k \cdot d$ por m , a operação de convolução é dada por:

$$F_i = u_i \cdot W \quad (6.1)$$

No passo i , essa operação gera um vetor de traços de tamanho m , que equivale ao número de filtros. Cada filtro individualmente extrai um traço para aquela janela, mas em geral é desejável mais do que isso, portanto múltiplos filtros são aplicados por janela.

Já a camada de *pooling* é responsável por reduzir o tamanho da entrada e o número de parâmetros a serem aprendidos. Ela costuma vir logo em seguida da camada de convolução com o objetivo de diminuir o número de traços selecionados pelo filtro. O *max pooling* é uma das estratégias mais comuns para isso: ela seleciona o traço com maior valor para cada filtro. O *max pooling* pode ser local ou global. O primeiro é aplicado aos filtros para cada janela e o segundo à entrada inteira. Uma variação desse método é o *k-max pooling*, que seleciona os k traços mais altos de cada filtro.

Quando aplicadas em tarefas de Processamento de Língua Natural, as redes convolucionais geralmente recebem como entrada os *word embeddings* que representam as palavras do texto. A arquitetura básica de uma rede neural convolucional aplicada a um texto é dada por uma camada de entrada, uma camada de convolução, uma camada de *pooling*, uma camada densa e uma camada de saída para a classificação na tarefa, como apresentada na Figura 6.1.

6.2.3 Parâmetros da rede convolucional

Tendo visto a arquitetura básica de uma rede neural convolucional, apresentam-se alguns parâmetros que precisam ser ajustados em seu treinamento: janela, passo, filtro e o tipo de *padding*.




Figura 6.1: Exemplo de uma arquitetura básica de uma rede neural convolucional para texto.

Janela

O tamanho da janela é um parâmetro da camada de convolução que determina o número de vetores de entrada que a rede vai analisar a cada passo. Na aplicação em um texto, isso equivale ao tamanho do n-grama que será analisado a cada passo. Esse número costuma ser entre dois e cinco, já que o tamanho da janela não pode ser muito grande para que o modelo possa generalizar padrões.

Passo

O passo indica o quanto o filtro vai se mover a cada iteração. Por exemplo, se o passo for igual a 2, o filtro vai pular do primeiro vetor da entrada para o terceiro, seguindo para o quinto e assim por diante. O valor padrão do passo é 1, portanto o filtro percorre a entrada sem pular nenhum vetor. O ajuste do passo deve levar em consideração o tamanho da janela, já que se o passo for maior do que a janela, o filtro perderá informações de elementos da entrada.

Assim, se o tamanho da janela for igual a 3, mas o passo for 5, o filtro pulará uma palavra da entrada a cada passo.

Filtro

A quantidade de filtros é um parâmetro importante a ser testado, pois vai determinar a complexidade de traços que o modelo vai capturar. Filtros maiores são capazes de aprender traços mais complexos, mas também podem gerar *overfitting* (KRICHEN, 2023).

Padding

O *padding* é a adição zeros ao redor da matriz de entrada antes da aplicação do filtro, o que é feito para preservar informação de espacialidade e prevenir que informações nas bordas se percam no processo de convolução. É comum usar um *padding* igual a 1, adicionando zeros à esquerda e à direita da entrada.

6.2.4 Redes convolucionais em PLN

Assim como no processamento de imagens, em tarefas textuais a rede convolucional percorre partes do texto buscando por padrões que a ajudem na resolução da tarefa. Dois dos pontos fortes das redes neurais convolucionais são a sua capacidade de extração de traços relevantes e a sua interpretabilidade, isto é, a verificação do que o modelo aprendeu e como chegou àquele resultado. Em Visão Computacional, existem inúmeras técnicas para recuperar o que uma rede convolucional aprendeu em cada camada (ZEILER; FERGUS, 2014; MAHENDRAN; VEDALDI, 2016), mas essas técnicas não funcionam tão bem para o PLN, cuja entrada é sequencial, diferente das imagens.

Isso não quer dizer que não se saiba nada sobre o que essas redes aprendem em relação ao texto. Pesquisas já mostraram que as redes convolucionais aprendem n-gramas ocorrendo nos dados de treinamento. Jacovi, Shalom e Goldberg (2018) realizaram uma investigação com o objetivo de verificar quais n-gramas selecionados pelos filtros das camadas de convolução são mais informativos. Avaliando uma rede convolucional para a Análise de Sentimentos, os autores mostram que os n-gramas com a pontuação mais alta

em cada filtro têm importância para a tarefa, sendo aqueles que carregam palavras emotivas como “ainda funciona perfeitamente”, “absolutamente belo” e “merece quatro estrelas”. Além disso, eles mostram que cada filtro parece se especializar em determinadas categorias semânticas ativadas por padrões próprios.

Por sua vez, um dos fracos desses modelos para tarefas de Processamento de Língua Natural é que eles não são sequenciais, o que quer dizer que não levam em conta a ordem dos elementos de entrada. Para tarefas em que a ordem é essencial, como etiquetagem morfosintática e sintática, eles são menos indicados. Algumas pesquisas, todavia, exploram a aplicação dessas redes para tarefas sequenciais, como a rede neural para modelagem de língua proposta por [Collobert et al. \(2011\)](#).

7 | Implementação de um modelo para detecção de ironia

Com o corpus anotado e revisado em mãos, a etapa seguinte da pesquisa foi a produção de um modelo computacional para a classificação de ironia. Este capítulo descreve o passo-a-passo do desenvolvimento do modelo proposto, desde o pré-processamento dos dados, a representação de palavras, os traços linguísticos selecionados para a tarefa até a arquitetura do modelo.

7.1 Pré-processamento do corpus

Uma etapa essencial antes da aplicação de um modelo computacional é o pré-processamento do texto, que tem por objetivo separar e normalizar as palavras, além de retirar informações desnecessárias para a tarefa. Tanto o texto quanto o contexto passaram por pré-processamento, que consistiu em: limpeza, tokenização, separação de categorias, tratamento de abreviações, substituição de marcas de riso, correção de palavras, remoção de termos desconhecidos e tratamento de *hashtags*.

7.1.1 Limpeza dos dados

O primeiro passo do pré-processamento foi a limpeza de elementos que podem atrapalhar no desempenho dos modelos computacionais. Com o intuito de evitar viés no texto, retiramos as três *hashtags* irônicas utilizadas para a coleta (*#ironia*, *#sqn* e *#sarcasmo*), mantendo as demais *hashtags* do corpus. As menções, iniciadas com o símbolo arroba (@), são um recurso para marcar

outras pessoas em seu tweet através do nome de usuário delas. Optamos por extraí-las do corpus, pois essas não trazem muitas informações úteis para a Detecção de Ironia e geram ruídos nos dados, já que não são reconhecidas como palavras do português. Além disso, retiramos todos os links, e-mails e sites, identificados pelos padrões “http”, “https”, “www.” e “.com”.

7.1.2 Tokenização do texto

A tokenização é a etapa de segmentação de um texto em palavras e pontuações. Para línguas cujas palavras são segmentadas por espaço em branco, como é o caso do português, a tokenização é relativamente simples, executada por métodos baseados em expressões regulares (MIKHEEV, 2022). Porém, as redes sociais contêm recursos que requerem um tratamento especial, como *hashtags* e *emoticons*, de forma que um tokenizador para textos comuns não é o ideal. Dessa forma, utilizamos o TweetTokenizer da biblioteca NLTK¹ que reconhece essas unidades como tokens, como exemplificado na Tabela 7.1.

Texto	Tokens
Muito feliz que vc conseguiu :) #vacina #covid #sus	“Muito”, “feliz”, “que”, “vc”, “conseguiu”, “:”, “#vacina”, “#covid”, “#sus”
Pronto, agora o GADO já pode vim aqui MUGI! 😂 BABACAS KKK #BolsonaroTeEnganou	“Pronto”, “,”, “agora”, “o”, “GADO”, “já”, “pode”, “vim”, “aqui”, “MUGI”, “😂”, “BABACAS”, “KKK”, “#BolsonaroTeEnganou”
O presidente da CPI da Covid, @OmarAzizSenador, disse nesta terça-feira (29) que o a comissão já conta com 31 assinaturas para prorrogar os trabalhos.	“O”, “presidente”, “da”, “CPI”, “da”, “Covid”, “@OmarAzizSenador”, “,”, “disse”, “nesta”, “terça-feira”, “(”, “29”, “)”, “que”, “o”, “a”, “comissão”, “já”, “conta”, “com”, “31”, “assinaturas”, “para”, “prorrogar”, “os”, “trabalhos”, “.”

Tabela 7.1: Exemplos de textos antes e após a tokenização.

¹<https://www.nltk.org/api/nltk.tokenize.casual.html>

Assim como a maioria dos tokenizadores baseados em expressões regulares, o TweetTokenizer identifica os tokens por espaçamento e separa palavras de pontuações. O seu diferencial é que ele mantém como um único token *hashtags*, *emoticons*, emojis e menções, que são comumente segmentados por outros tokenizadores. É importante ressaltar que não convertamos os tokens para letras minúsculas durante a tokenização, pois a diferença entre maiúsculas e minúsculas foi considerada relevante para a tarefa, já que pode expressar o entusiasmo ou a irritação do usuário.

7.1.3 Separação do exemplo em categorias

Após a tokenização, os tokens foram separados em três partes: texto, emojis e *hashtags*. As *hashtags* foram categorizadas a partir da cerquilha (#), enquanto a biblioteca emoji² identificou os emojis. Os demais tokens foram deixados como texto. Fez-se essa separação porque o pré-processamento em cada uma dessas partes foi distinto. Nas subseções seguintes, o tratamento de abreviações, a substituição de marcas de riso, a correção de palavras e a remoção de palavras desconhecidas foram aplicados no texto. Por sua vez, as *hashtags* receberam um tratamento para segmentá-las em palavras. Os emojis não foram pré-processados inicialmente, pois foram mapeados em suas respectivas emoções na etapa de extração de traços.

7.1.4 Tratamento de abreviações

Textos em redes sociais costumam apresentar uma linguagem informal com abreviações de palavras. Transcrever as abreviações em sua forma por extenso na etapa de pré-processamento evita problemas nas etapas seguintes, uma vez que a forma abreviada de uma palavra se distingue de sua forma por extenso (por exemplo “você” e “vc”), o que cria uma falsa variabilidade e pode interferir negativamente no desempenho. Além disso, as abreviações geralmente não estão presentes no vocabulário dos modelos pré-treinados de representações *word embeddings*. Isso significa que é preciso gerar vetores

²<https://pypi.org/project/emoji/>

inicializados com valores aleatórios para representá-las, o que não é o ideal, pois esses não estão treinados.

Por essas razões, elaboramos uma lista de abreviações e suas respectivas transcrições por extenso. Algumas delas são transcritas em apenas uma palavra, enquanto outras são expressões completas. Nos casos em que a palavra varia em gênero, optou-se por transcrevê-la no masculino. Por exemplo “amg” é transcrito como “amigo”. Determinadas palavras possuem mais de uma abreviação possível, tal qual “também”, que é abreviada como “tb” ou “tbm”. A lista contém 88 entradas apresentadas na Tabela B.1 em anexo. No pré-processamento, todas as abreviações presentes no corpus foram substituídas por sua respectiva palavra por extenso.

7.1.5 Substituição de marcas de riso

Encontram-se diferentes formas de transcrever risadas em texto, como “kkkk” e “haha”, o que também varia no número de caracteres que são usados. O riso pode ser uma marca forte de ironia, mas toda a diversidade em sua expressão escrita dificulta seu reconhecimento pelos modelos de aprendizado de máquina. Desse modo, identificamos um conjunto de padrões comuns de transcrição de risadas e substituímos essas palavras pelo termo “risos”.

Consideraram-se como padrões de riso sequências de duas ou mais repetições de: “k”, “ks”, “ka”, “rs”, “ha”, “he” e “hi”. Estamos cientes de que esses padrões não cobrem todas as possibilidades de expressão de risadas, uma vez que elas podem ser imprevisíveis, como “sksaksaskask’ e “aushaushausha-sahsu’, que não serão capturadas. Contudo, optamos por manter apenas padrões comuns para evitar converter palavras que não são marcas de riso.

7.1.6 Correção de palavras

Aplicamos um corretor ortográfico para corrigir dois tipos de erros: acentuação e alongamento de vogais. A acentuação diz respeito às palavras em que era esperado um acento, mas ele estava ausente, como “voce” em vez de “você”. O alongamento de vogais, por exemplo “Eu amooooooooo esse livro”, é um recurso da escrita que tenta replicar o alongamento na fala, usado comumente

para expressar entusiasmo e exagero. Assim como no caso das abreviações, esses dois erros criam palavras que não estão no vocabulário e podem criar problemas para a representação em modelos de linguagem.

Os erros de acentuação foram corrigidos com um dicionário de palavras acentuadas extraídas do próprio corpus que tem como entrada uma palavra com a acentuação removida (por exemplo, “portugues”) e como valor a mesma palavra acentuada (“português”). No pré-processamento, ao encontrar uma palavra que pertence a esse dicionário, uma função a substitui por sua versão acentuada.

Para evitar substituir palavras idênticas em que uma tem acento e a outra não (como “esta” e “está”), utilizou-se um corretor ortográfico que verifica se a palavra sem acentuação existe no português, caso em que ela é mantida sem alteração. Essa verificação foi feita com base no corretor ortográfico Hunspell³ para o português brasileiro, disponível na biblioteca Phunspell⁴ de Python.

No caso do alongamento de vogais, uma função busca por padrões de repetição da mesma vogal duas ou mais vezes em uma palavra e a devolve sem repetições. Se a nova versão for uma palavra reconhecida pelo Hunspell, a função substitui a antiga pela nova.

Focamos nesses dois erros porque os corretores ortográficos não são bons no reconhecimento de erros em textos compostos de muitas palavras desconhecidas, como é o caso das redes sociais. Dois dos principais problemas encontrados foram as Entidades Nomeadas, que incluem nomes próprios, e as palavras estrangeiras. Um exemplo, o nome “Bolsonaro” não é reconhecido pelo Hunspell, que sugere como correções “Bolasterona”, “Blassonar” e “Blasonar”. Para evitar substituições sem sentido, optou-se por corrigir apenas esses dois tipos de erros que são mais tratáveis.

7.1.7 Remoção de palavras desconhecidas

A última etapa do pré-processamento textual foi a remoção de termos desconhecidos, motivada pela tentativa de retirar palavras com erros ortográficos,

³<https://hunspell.github.io/>

⁴<https://pypi.org/project/phunspell/>

nomes próprios raros e palavras estrangeiras. Desse modo, após a substituição de abreviações e correções ortográficas realizadas, o restante de tokens não reconhecidos pelo Hunspell foi extraído do texto.

7.1.8 Tratamento de *hashtags*

As *hashtags* são iniciadas pelo caractere # (chamado de “cerquilha”), podendo ser compostas de letras, números e sublinhados sem espaçamento entre eles. Elas têm usos especiais no X: categorizam e identificam assuntos e discussões na rede social, o que as torna úteis para situar o contexto do texto. Outro ponto pertinente é que elas podem fornecer pistas de ironia ao desencadearem uma contradição com texto, como no exemplo “Bolsonaro melhor presidente #ForaBolsonaro”. Para serem reconhecidas como palavras do português, as *hashtags* foram tokenizadas e verificadas.

A tokenização das *hashtags* foi feita com base em duas etapas: (1) a identificação de letras maiúsculas indicando início de palavra e (2) a identificação de palavras em dicionários. Na primeira, a *hashtag* foi fatiada pela busca de três padrões: uma sequência iniciada por uma letra maiúscula seguida de letras minúsculas, uma sequência de números e uma sequência de letras minúsculas. Na segunda etapa, as palavras identificadas anteriormente eram verificadas por um dicionário e, caso não estivessem no vocabulário, eram fatiadas novamente por uma busca de palavras. A segunda busca percorre o texto e verifica se a sequência obtida até o momento é uma palavra válida. A função de separação de palavras é dada no Algoritmo 2, em que *d1* e *d2* são dicionários.

A função percorre subsequências em um texto, concatenando letra a letra a cada iteração, e verifica se essa está presente em um dos dicionários fornecidos. Se uma subsequência válida for encontrada, ela é considerada uma palavra. A busca continua até que o texto todo tenha sido percorrido, retornando a palavra mais longa encontrada na sequência, isto é, se o texto for apenas uma palavra, a busca termina. Se uma palavra for encontrada, mas o texto não tiver sido esgotado, a função é chamada recursivamente até não haver mais letras sobrando. Foram usados dois dicionários para a verificação, um é uma

Algoritmo 2 Algoritmo para a separação de palavras em *hashtags*.

```

1: função SEPARAPALAVRAS(texto, d1, d2, palavras)
2:   indice  $\leftarrow$  0
3:   palavra  $\leftarrow$   $\emptyset$ 
4:   subsequencia  $\leftarrow$   $\emptyset$ 
5:   para cada letra  $\in$  texto faça
6:     subsequencia  $\leftarrow$  subsequencia + letra
7:     se letras  $\in$  d1  $\vee$  letras  $\in$  d2 então
8:       palavra  $\leftarrow$  subsequencia
9:       indice  $\leftarrow$  indice + 1
10:    fim se
11:  fim para
12:  palavras  $\leftarrow$  palavra
13:  se indice < len (texto) então
14:    return SeparaPalavras(texto[indice :], d1, d2, palavras)
15:  senão
16:    return palavras
17:  fim se
18: fim função

```

lista de palavras extraídas do próprio corpus e o outro é o dicionário Hunspell. Para o dicionário do corpus, selecionaram-se todas as palavras alfabéticas de duas ou mais letras, excluindo-se as abreviações, totalizando 8.982 entradas. O objetivo desse dicionário era evitar que nomes próprios, não reconhecidos pelo Hunspell, fossem desconsiderados como palavras.

Na Tabela 7.2 estão exemplos de *hashtags* e a sua forma textual após tokenizada.

As *hashtags* em que as palavras eram identificadas por letra maiúscula, como #ForaBolsonaroUrgente e #EmDefesaDoSUS, já apresentavam uma separação válida na primeira etapa da busca. Porém, mesmo essas podem ser divididas de forma incorreta, como #JornaldaBand, que separaria a *hashtag* como “Jornalda” e “Band”. Por isso essas *hashtags* também passam pela segunda etapa, na tentativa de subdividir palavras que possam estar juntas. Essa etapa pode levar a erros, o que aconteceu com #BolsonaroTemRazao, em que “razão” foi dividida em três partes porque “razao” não foi encontrada no vocabulário de nenhum dos dicionários por falta de acentuação.

Hashtag	Texto
#ForaBolsonaroUrgente	Fora Bolsonaro Urgente
#EmDefesaDoSUS	Em Defesa Do SUS
#dia23ImpeachmentJa	dia 23 Impeachment Ja
#BolsonaroTemRazao	Bolsonaro Tem Ra z ao
#JornaldaBand	Jornal da Band
#vacinacovid19fiocruz	vacina covid 19 fiocruz
#forçasarmadas	forças armadas
#vivaosus	viva o sus
#fechadocombolsonaro	fechado combo l sonar o

Tabela 7.2: Exemplos de tokenização de *hashtags*.

As *hashtags* sem distinção entre maiúsculo e minúsculo foram divididas em palavras apenas na segunda etapa pela verificação no dicionário. O método mostrou bons resultados, separando a maioria das palavras corretamente, por exemplo “forças armadas” e “vacina covid 19 fiocruz”. Em “#fechadocombolsonaro”, o algoritmo selecionou “combo” em vez de “com”, portanto o restante das palavras ficou incorreto. Isso ocorreu porque a busca seleciona a cada etapa a maior palavra possível na sequência e ela nem sempre é a escolha esperada.

7.2 Análise de Emoções

A Análise de Emoções teve um papel relevante dentro do modelo proposto para Detecção de Ironia, servindo para a identificação de incongruências entre emoções no texto que podem caracterizar a ironia. Foram adotados dois métodos de análise emotiva: um para a classificação de textos e outro para os emojis. As próximas seções discutem em detalhes cada um desses métodos.

7.2.1 Modelo de Análise de Emoções textual

A técnica de Análise de Emoções proposta está embasada nas oito emoções básicas de Plutchik: “*anger*”, “*fear*”, “*sadness*”, “*joy*”, “*disgust*”, “*trust*”, “*anticipation*” e “*surprise*”. Optamos por adotar uma abordagem simples

baseada na similaridade entre o vetor de um texto e os vetores de palavras de cada uma dessas emoções.

Nesta pesquisa, escolhemos um modelo de *word embeddings* contextual para a representação dos textos. As representações foram geradas com a biblioteca Sentence Transformers⁵, que converte um texto em sua representação de sentença. A biblioteca fornece diversos modelos pré-treinados multilíngues voltados para diversas tarefas.

Entre os modelos multilíngues disponíveis, o Sentence-BERT (REIMERS; GUREVYCH, 2019) foi o que se saiu melhor. Ele é um modelo otimizado do BERT treinado pelo método de redes neurais siamesas para a tarefa de Inferência em Linguagem Natural. São duas redes BERT com pesos compartilhados, uma voltada para a classificação de inferência entre duas sentenças e outra para computar a similaridade entre os pares. Segundo os autores, os *embeddings* produzidos pelo Sentence-BERT são mais adequados para tarefas de comparação de similaridade, clusterização e recuperação de informações do que o modelo BERT clássico. Estamos usando a versão multilíngue treinada por Reimers e Gurevych (2020), que é uma expansão do Sentence-BERT em inglês obtida por transferência de conhecimento obtido pela associação entre sentenças de uma língua fonte para línguas alvo.

Antes de transformar os textos em representações vetoriais, as emoções de Plutchik foram traduzidas do inglês para o português, assim a comparação de similaridade entre o texto e a emoção será dentro do mesmo modelo. Como se trata de conceitos na teoria de emoções de Plutchik, a tradução literal dos termos pode não ser a melhor correspondência no português. Portanto, quatro dicionários online inglês-português foram selecionados para a avaliação da tradução de cada conceito: o Linguee⁶, o Cambridge Dictionary⁷, o Collins Dictionary⁸ e o Michaelis Moderno Dicionário Inglês & Português⁹.

O Linguee é um dicionário baseado em uma ferramenta de busca que acessa frases traduzidas em que os usuários avaliam as traduções forneci-

⁵<https://sbnet.net/>

⁶<https://www.linguee.com.br/>

⁷<https://dictionary.cambridge.org/pt/dicionario/ingles-portugues/>

⁸<https://www.collinsdictionary.com/pt/dictionary/english-portuguese>

⁹<https://michaelis.uol.com.br/moderno-ingles/>

das. Ele fornece a classe gramatical da palavra, opções de tradução mais frequentes e menos frequentes e exemplos de uso. O dicionário online Collins Português-Inglês foi escrito por especialistas na compilação e tradução de português e inglês, possuindo mais de 250.000 verbetes de entrada com transcrição fonética e classe gramatical. O Michaelis Moderno Dicionário Inglês & Português possui mais de 167.000 verbetes que apresentam divisão silábica, classe gramatical, área de conhecimento, várias acepções, expressões e exemplos. Já o Cambridge Dictionary inglês-português foi criado com base no Cambridge English Corpus oferecendo traduções para mais de 41.000 palavras com classificação gramatical, transcrição fonética e exemplos.

A partir das traduções fornecidas pelos dicionários, selecionou-se entre alternativas que correspondiam a uma emoção em português e cuja acepção se assemelhasse a do inglês. As traduções completas fornecidas pelos dicionários estão no Apêndice C e a Tabela 7.3 traz as traduções das oito emoções de Plutchik.

Emoção	Termos selecionados	Tradução final
anger	raiva, ira, cólera, fúria	raiva
anticipation	expectativa, ansiedade	expectativa
disgust	repugnância, asco, nojo, aversão, repulsa	asco
fear	medo, temor, pavor, terror	medo
joy	alegria, júbilo, felicidade	alegria
sadness	tristeza	tristeza
surprise	surpresa, perplexidade	surpresa
trust	confiança, esperança	confiança

Tabela 7.3: Tabela de traduções para as emoções de Plutchik.

Algumas das traduções oferecidas pelos dicionários estão na mesma pétala da emoção associada, mas em níveis diferentes. Um exemplo, “ira” e “cólera” são emoções de raiva elevada, correspondente a “*rage*” na Roda de Emoções, assim “aversão” se associa ao nível mais alto de asco (“*loathing*”). Para as emoções de raiva, medo, tristeza, alegria, surpresa e confiança, a tradução literal foi aquela que se adequou ao conceito emotivo em português.

A tradução de “*disgust*” foi aquela que gerou mais discussões, pois existem vários termos possíveis com significados próximos para expressá-la. Por exemplo, “nojo” pode ser uma tradução direta para “*disgust*”, mas apareceu em apenas dois dos dicionários consultados. Além disso, o nojo no português está muito associado à náusea, o que nem sempre é o sentido referido da emoção. O termo “repugnância” foi o mais frequente, aparecendo nos quatro dicionários, enquanto “asco” apareceu em três. A seleção entre esses dois foi feita com base em testes de similaridade utilizando os *embeddings* do Sentence-BERT, em que o *embedding* de asco apresentou maior correlação com os exemplos expressando a emoção.

A tradução de “*anticipation*” também não é óbvia, uma vez que a tradução direta “antecipação” não é uma emoção em português, estando associada com uma predição, preparação ou recebimento de um pagamento adiantado. As opções mais adequadas foram “expectativa”, que ocorreu nos quatro dicionários, e “ansiedade”, aparecendo em dois. Optamos pela primeira por ela ser mais neutra, já que “ansiedade” pode se associar ao transtorno de ansiedade.

Tendo os conceitos emotivos traduzidos, o modelo de classificação recebe como entrada o vetor de um texto e calcula sua similaridade com os vetores correspondentes de cada emoção, devolvendo como saída um vetor de oito posições indicando a similaridade do texto com as emoções. A métrica de similaridade utilizada foi a de cossenos, dada pelo produto escalar normalizado entre dois vetores. Uma normalização euclidiana é aplicada no vetor final para obter valores mais próximos, dada por $norm = (x_1, x_2, \dots, x_8) / \sqrt{(x_1^2 + x_2^2, \dots, x_8^2)}$. A classificação final corresponde a emoção com maior similaridade com o texto.

Considerando que determinados tipos de textos, como os jornalísticos e os científicos, são menos emotivos, estabeleceu-se um limiar de 0,5 para a identificação de uma emoção. Isto quer dizer que se a emoção mais similar alcançar menos de 0,5 de semelhança com o texto, ele é classificado como “neutro”. Esse modelo foi utilizado na implementação de traços para obter as emoções dos exemplos do corpus.

7.2.2 Corpus de emoções de emojis

Como discutido no Capítulo 4, os emojis são um mecanismo importante para a transmissão de emoções em redes sociais. Pensando nisso, criamos um corpus de 159 emojis anotados manualmente em relação às oito emoções de Plutchik (alegria, tristeza, medo, raiva, asco, confiança, surpresa e expectativa). Selecionou-se sumariamente emojis faciais, que são os mais emotivos, mas também aceitamos alguns gestos de mãos, corações e pictogramas.

Consideramos que um emoji pode estar associado a mais de uma emoção, de modo que alguns contam com duas ou mais etiquetas. As descrições de emojis fornecidas pelo site Emojipedia serviram como dicionário de significados para a etiquetagem dos emojis. Alguns exemplos são fornecidos na Tabela 7.4, em que as expressões emotivas se destacam em negrito.

O processo de anotação envolveu um nível de interpretação pessoal, já que as emoções descritas na Emojipedia são diferentes das de Plutchik. Por essa razão, considerou-se a similaridade, a sinonímia e a correlação das palavras emotivas usadas nas descrições com as emoções de Plutchik. Muitas vezes, as emoções contidas na descrição foram aglutinadas em uma única por similaridade com a categoria, o que ocorre com os emojis “Rosto Piscando e com a Língua de Fora” (😜) e “Rosto Preocupado” (😟).

Além disso, não incluímos todas as emoções apresentadas na descrição, apenas as que consideramos primárias ou mais evidentes. No emoji “Rosto Gritando de Medo” (😱), há indicação de “*intense excitement*” (empolgação intensa, em tradução livre) como uma das emoções expressas por ele, o que poderia ser convertido em “expectativa”, mas não a incluímos na classificação por considerá-la ambígua e secundária na representação do emoji.

A análise de significados considerou todos os níveis emotivos da Roda de Emoções, desde os menos intensos até os mais intensos. Contudo, não houve distinção entre eles na anotação, que foram agrupados a sua emoção primária. Exemplificando, o emoji “Rosto Inexpressivo” (😐) fornece “*annoyance*” (tradução: “irritação”) em sua descrição, que é o primeiro estágio de “*anger*” pelo modelo de Plutchik, portanto ele foi classificado como “raiva”.

Emoji	Descrição	Emoções
	A yellow face screaming in fear , depicted by wide, white eyes, a long, open mouth, hands pressed on cheeks, and a pale blue forehead, as if it has lost its color. Its expression evokes Edvard Munch's iconic painting The Scream. While intended to represent horror and fright , it commonly conveys such feelings as shock , awe , disbelief , and intense excitement , as a screaming fan.	medo, surpresa
	A yellow face sticking out its tongue and making a zany wink, usually shown with its right eye closed and left wide open. Often conveys a sense of fun , excitement , wackiness , buffoonery , or joking .	alegria
	A yellow face with open eyes, raised or furrowed eyebrows, and a broad frown. May convey a variety of moderately sad or tense emotions, including concern , anxiety , alarm , disappointment , and unhappiness .	tristeza
	A yellow face with flat, closed eyes and mouth. May convey a sense of frustration or annoyance more intense than suggested by  Neutral Face, as if taking a moment to collect itself.	raiva
	Two hands raised in the air, celebrating success or another joyous event .	alegria
	A red symbol found in Anime/Manga and used to represent the veins popping on a very angry person .	raiva
	A classic red love heart emoji. The red heart ideograph is traditionally used for expressions of love and romance across many cultures, with this being amongst the most frequency use cases for this emoji.	alegria

Tabela 7.4: Amostra do corpus de emoções de emojis.

Já no caso das emoções secundárias, aquelas geradas pela combinação de duas primárias, optamos por inseri-las em uma das categorias possíveis em vez de separá-las em duas emoções distintas. De acordo com o modelo de Plutchik, “amor” é a combinação de “alegria” e “confiança”, portanto, uma emoção secundária. Essas emoções não estão no nosso modelo, mas não queríamos perder emojis que contivessem uma delas. A solução encontrada foi agrupá-las a uma das emoções primárias que a combinam. No caso de “amor”, que aparece no emoji de coração (❤️), o categorizamos como “alegria” em todos os casos em que essa emoção apareceu nos emojis.

7.3 Traços do modelo de classificação de ironia

O modelo proposto nesta pesquisa utiliza três tipos de traços: textuais, manuais e emotivos, que podem ser uma matriz ou um vetor que mapeia características consideradas relevantes para a resolução da tarefa.

7.3.1 Vetor textual

O vetor textual é usado para representar as palavras do texto e do contexto do corpus. Avaliou-se quatro modelos de *word embeddings*: o BERTimbau base (SOUZA; NOGUEIRA; LOTUFO, 2020), o XLM-RoBERTa base multilíngue do Facebook (CONNEAU et al., 2019) e os modelos pré-treinados em português do GloVe e do FastText com 100 dimensões (HARTMANN et al., 2017), ambos disponíveis no repositório de *word embeddings* do NILC¹⁰. Os dois primeiros são *embeddings* contextuais, enquanto os últimos são não-contextuais. Os vetores de palavras ausentes no vocabulário dos modelos não-contextuais foram inicializados aleatoriamente com uma distribuição uniforme.

7.3.2 Vetor de traços manuais

O vetor de traços manuais possui sete posições, cada qual correspondente a um traço medido a partir do texto ou da relação entre o texto e o contexto. São

¹⁰<http://nilc.icmc.usp.br/nilc/index.php/repositorio-de-word-embeddings-do-nilc>

esses: Pistas de ironia, Citação, Oposição dos sujeitos, Conflito de emoções, Conflito de sentimentos, Impertinência externa e Impertinência interna.

Pistas de ironia

Como já apontado por Bromberek-Dyzman (2012), é difícil estabelecer pistas exclusivas de ironia, pois essas devem estar acompanhadas de aspectos contextuais para a sua interpretação. Todavia, existem características canonicamente estabelecidas na construção de uma ironia, entre elas está o exagero em relação ao que está sendo dito, que pode aumentar ou diminuir o objeto-alvo. Por exemplo, “O presidente é tão inteligente, ele sabe somar um mais um”. O advérbio “tão” reforça a característica de inteligência, que é posteriormente diminuída pela frase “ele sabe somar um mais um”.

Para tentar capturar esse tipo de pistas, selecionamos um conjunto de palavras intensificadoras que incluem advérbios de intensidade (“bastante”, “tanto” e “pouco” são alguns exemplos), adjetivos que indicam grandezas (como “grande”, “pequeno” e “gigante”), palavras no diminutivo e no aumentativo e com prolongamento de vogais, como em “ele é muitooooooooo legal”. O traço retorna a razão entre o número de pistas encontradas no texto e o total de palavras.

Citação

A Teoria Ecóica de Sperber e Wilson (1981) dita que a ironia é uma menção indireta do discurso de outrem para expressar uma atitude negativa em relação ao que é dito. Em textos escritos, o uso de aspas pode marcar uma citação direta como também pode sinalizar que determinadas partes do texto tem um significado diferente do literal, como em “Sabemos o quanto o Bolsonaro se ‘preocupa’ com a população”, em que a palavra entre aspas demonstra que o autor do discurso não acredita que Bolsonaro se preocupa com a população.

A citação é medida por dois métodos: (1) o número de palavras entre aspas no texto; (2) o número de sequências composta de três palavras no texto exatamente iguais ao do contexto, ou seja, uma repetição parcial do

conteúdo do contexto. O resultado é a razão entre o número de palavras citadas e o total de palavras do texto.

Oposição dos sujeitos

Muitas vezes a ironia ocorre em um contexto de oposição cuja intenção é criticar, zombar ou demonstrar desaprovação da atitude de outro. Entretanto, essa oposição entre os sujeitos ainda é uma área pouco explorada na análise de ironia. [Kaufer \(1977\)](#) discute a relação do ironista com o público, dividindo-o em vítimas e aliados, sendo os primeiros aqueles que não interpretam o sentido irônico e os segundos aqueles que o fazem, mas o autor não discorre se a relação entre o público e o ironista é de alinhamento de ideias ou de oposição.

Pensando nisso, propomos um traço que busca verificar se os sujeitos do contexto e do texto estão em oposição com base na valência (positiva e negativa) das emoções expressas por cada um deles. É comum que, dado um contexto negativo, a ironia apareça como uma resposta aparentemente positiva, como no exemplo a seguir.

Turno 1: O “favorito” é humilhado. O que tava caindo, tá classificado!
Pensando bem, TODOS merecem uma demissão mesmo. Do presidente, ao treinador, dos diretores aos jogadores. Até mesmo o cara do totem. Vão todos para a PQP!

Turno 2: Nada, po até o treinador? aquele deus do futebol, jamais. A história respalda o trabalho do grandioso Diniz, não, pera..

No Turno 1, o usuário está irritado com a classificação do time, pedindo que todos sejam demitidos, ao que o segundo traz um comentário irônico que expressa uma falsa positividade em relação ao treinador do time. O segundo usuário poderia estar sendo sincero, saindo em defesa do treinador, mas, além do trecho final que o entrega (“não, pera”), o exagero na positividade (“aquele deus do futebol” e “o trabalho do grandioso Diniz”) também é um indicativo da ironia tendo em vista o contexto negativo precedente. Desse modo, esse traço foi pensado como uma forma de detectar conflitos emotivos entre os

sujeitos como uma possível pista de quebra de expectativa que pode estar associada à ironia.

O procedimento para a implementação desse traço consiste na divisão do texto e do contexto em sentenças, que são combinadas em pares de uma sentença do texto com uma do contexto, de modo que todas as sentenças do texto sejam comparadas às do contexto. Após o pareamento, verifica-se se a opositividade entre os pares, isto é, se as emoções expressas por eles possuem polaridades opostas.

Considerou-se como emoções positivas “alegria”, “surpresa” e “confiança”, enquanto “raiva”, “asco”, “medo” e “expectativa” foram consideradas negativas. As polaridades foram definidas com base na opositividade da Roda de Emoções, porém o número de positivas e negativas não é igual, uma vez que a oposição entre emoções não significa que uma emoção é positiva e a outra negativa, como mostra o par “raiva” e “medo”, ambas negativas. O traço é medido pela razão entre o número de pares opositivos pelo total de pares.

Conflito de sentimentos

No Capítulo 4 apresentamos ideias que defendem a presença de uma carga ou atitude emotiva subjacente em textos irônicos (AKIMOTO et al., 2014; BROMBEREK-DYZMAN, 2012). Essa carga subjacente costuma ser oposta àquela expressa pelo sentido literal do texto. Propomos identificar essa emoção subjacente como um conflito entre sentimentos presentes no texto, como nos exemplos a seguir.

1. Esse governador é um cínico. Pq não cancelou o carnaval? (\$\$\$\$)
Agora esse inferno. Parabéns Governador! #sqn
2. Vcs são campeões inteligentes #sqn!! Óbvio que com o andar da vacinação, o número de internados com menos idade aumentará!!! Os idosos já estão imunizados. Dessa faixa abaixo de 70, provavelmente não tomaram a 2ª dose ainda, ou não criaram imunidade suficiente. Pensar faz bem...

3. Quanta elegância. #sqn Rigor científico é eufemismo para BURROcracia. Trabalhar muito é diferente de trabalhar certo pela vida. Pesquisa T20 da BOLD e vai ver que a Anvisa deixou pessoas morrerem asfixiadas só por conta de normas burras.

O Exemplo 1 apresenta uma emoção predominantemente negativa, que pode ser classificada como “raiva”. Todavia, a parte final em que ele parabeniza o governador é superficialmente positiva, portanto com uma valência oposta à do texto. Já Exemplo 2 começa com uma positividade que é quebrada logo a seguir com uma crítica negativa, que é reforçada na parte final “Pensar faz bem..”, completamente oposta ao começo do texto. O mesmo ocorre com o último exemplo, cuja primeira sentença é superficialmente positiva, mas o restante do texto é negativo.

A ideia é identificar o sentimento subjacente como uma oposição ao sentimento geral do texto. Para a sua implementação, o texto foi dividido em partes (sentenças, sintagmas, hashtags e emojis) que foram classificadas de acordo com sua emoção. Os sintagmas podem ser nominais, verbais e adjetivais, extraídos do texto com o auxílio da ferramenta de análise linguística spaCy¹¹. Os textos (sentenças, sintagmas e hashtags) foram classificados com o modelo de emoções aqui proposto (Subseção 7.2.1) e os emojis etiquetados pelo corpus descrito na Subseção 7.2.2. Caso alguma emoção de polaridade oposta à do texto seja encontrada, o traço soma 1. O valor final é dado pela razão entre o número de partes em oposição ao texto e o total de partes. Portanto, se o exemplo tem cinco partes e três delas apresentam uma emoção oposta ao texto, o valor do traço é 0,6.

Esse traço é semelhante ao de incongruência explícita proposto por Joshi, Sharma e Bhattacharyya (2015). Porém, em vez do contraste entre palavras, estamos considerando sentenças, sintagmas e *hashtags*. Outro diferencial é que nosso traço também considera a emoção de emojis, que pode ser considerada não-textual. Por fim, esse traço está associado ao de Oposição de Sujeitos, mas em vez de avaliar a relação entre o texto e o contexto, foca-se apenas nas oposições contidas no texto.

¹¹<https://spacy.io/usage>

Conflito de emoções

O Conflito de emoções é idêntico ao Conflito de sentimentos, com a única diferença sendo que ele avalia as oposições de emoções de Plutchik: alegria e tristeza, raiva e medo, surpresa e expectativa e asco e confiança. Esse traço está parcialmente contido no anterior, sendo mais específico. Escolhemos avaliá-lo para testar se as inversões opostas de emoções propostas por Plutchik são recorrentes na ironia, ou seja, a utilização de uma sentença que indica uma emoção para expressar a emoção oposta. Um exemplo seria alguém dizer “Fico tão triste em saber dessa notícia” quando na verdade quer expressar alegria.

Impertinência externa

Grice (1975) propõe que a ironia se dá pela quebra da Máxima de Qualidade. Contudo, outros autores já mostraram que a quebra de outras Máximas pode desencadear uma ironia. Em diversas ocasiões, o discurso irônico é construído pela apresentação de uma informação que parece irrelevante ao contexto para desencadear uma implicatura irônica, como no exemplo a seguir.

Turno 1: Leila Pereira está bem chateada com a forma que os jogadores têm se portado em campo nos últimos jogos. A chance de uma reformulação enorme no elenco, caso o Palmeiras não ganhe a Libertadores, é gigante.
@jorgenicola

Turno 2: Não entendo essa reformulação... William Bigode é um ótimo pai, Eu sou MT grato ao Jailson, LA fez um gol lindo contra o River, Luan falha mas tem uma ótima saída de bola, Marcos Rocha falha mas cresce em jogo grande #Ironia

O Turno 2 traz uma informação que parece impertinente ao contexto ao se referir a William Bigode como “um ótimo pai”. Esse tipo de exemplo se associa à Máxima de Relevância de Grice, que está baseada na pertinência de sua contribuição para o objetivo conversacional. Ao quebrar essa Máxima, o usuário pode estar querendo implicar algo que não está sendo dito. Em

nossa análise, esse tipo de quebra de Relevância é uma forma do sujeito chamar a atenção de seu receptor para mostrar que não acredita no que disse.

O traço de Impertinência externa tenta capturar esse tipo de quebra de relevância através da busca por similaridades entre o texto e o contexto. Primeiro, o texto e o contexto são divididos em sentenças, que por sua vez são convertidas em *embeddings* com a biblioteca Sentence-BERT. Os *embeddings* são pareados de modo que cada sentença do texto seja comparada a todas as do contexto. Calcula-se a similaridade de cossenos entre cada par e, se ela for menor do que um limiar de 0,1, soma-se 1. O valor final é dado pela soma de pares desiguais pelo total de pares.

Impertinência interna

A detecção de impertinência interna foi inspirada no traço proposto por [Aditya Joshi \(2016\)](#) para a avaliação de disparidade entre partes do texto, isto é, partes com pouca associação sintático-semântica, como no exemplo a seguir.

Turno 1: Amanhã, 31/12, panelaço no pronunciamento do Presidente às 20h30 em comemoração aos 3 anos sem corrupção no Brasil. Esquerda está convidada também a bater panelas, devem estar em abstinência, ajuda a desopilar o fígado...

Turno 2: Opa, pessoal do Centrão, Valdemar da Costa Neto, Queiroz e muito suco de laranja. Estaremos juntos com uma bela picanha e leite condensado. Vamos vibrar com a chuva comunista que está matando o povo baiano. E viva a Cloroquina que salvou o povo. Foda-se a ciência. #sqn

O texto do Turno 2 traz alguns elementos que inicialmente parecem desconexos entre si. Tem-se de um lado expressões como “suco de laranja”, “leite condensado” e “bela picanha”, semelhantes entre si, e do outro “chuva comunista”, “matando o povo baiano” e “foda-se a ciência”. Sem um conhecimento de mundo para compreender o significado de “leite condensado”, referindo-se à compra de leite condensando durante o governo Bolsonaro, ou

de “laranja”, para se referir a uma pessoa envolvida com corrupção, a menção a esses termos parece estranha no texto.

O intuito desse traço é verificar se características de estranheza e absurdidade dadas pela desconexão entre as partes do texto são um indicativo de ironia. Diferente da Impertinência externa, que é aplicada em sentenças, esse traço é aplicado em sintagmas (verbais, nominais e adjetivais), identificados a partir do analisador morfossintático do spaCy. Muitos textos são constituídos de uma única sentença, o que justifica a utilização de estruturas menores dentro da sentença. Além disso, as dissimilaridades estão comumente contidas em pequenos trechos, não em uma sentença completa. Esse também é um diferencial do nosso traço daquele proposto por [Aditya Joshi \(2016\)](#), que busca por dissimilaridades entre palavras.

Para implementar o traço, obtivemos os *embeddings* dos sintagmas com o Sentence-BERT. Esses foram combinados em pares e calculou-se a similaridade entre eles. Caso a similaridade seja menor do que um limiar de 0,1, soma-se 1. O valor final é dado pela razão entre o número sintagmas dissimilares pelo total de sintagmas.

7.3.3 Vetor de traços emotivos

O vetor de traços emotivos é um vetor de oito posições que correspondem às similaridades do texto com cada uma das emoções classificadas (alegria, tristeza, asco, expectativa, surpresa, confiança, raiva e medo). O objetivo desse traço é inserir diretamente informações sobre a emotividade do texto para que o modelo seja capaz de fazer associações entre emoções e a presença de ironia durante o treinamento.

7.4 Arquitetura do modelo

Propomos um modelo de rede neural híbrida que classifica os exemplos em “ironia” e “não-ironia”. Ele recebe como entrada vetores de palavras e vetores de traços pré-estabelecidos, realizando o processamento inicial das entradas

por redes neurais distintas e depois concatenando as saídas de cada modelo para a classificação, como apresentado na Figura 7.1.




Figura 7.1: Arquitetura da rede neural proposta para a classificação de ironia.

Pode-se dividir o modelo em três sub-redes: a rede convolucional que recebe o texto e o contexto, a rede *feedforward* que recebe os traços manuais e os emotivos e a rede *feedforward* que recebe as saídas das redes anteriores e atribui sua etiqueta. As próximas seções apresentarão cada uma das partes da arquitetura do modelo.

7.4.1 Rede convolucional

A rede convolucional que faz o pré-processamento textual recebe como entradas o texto e o contexto, que inicialmente são pré-processados separadamente por camadas convolucionais distintas. A justificativa para isso é que cada rede selecionará os traços mais relevantes para o texto e para o contexto separadamente antes de juntá-los.

Baseados na ideia proposta no trabalho de [Kim \(2014\)](#), cada entrada é processada por duas redes convolucionais com filtros de janelas de tamanhos diferentes, uma igual a 3 e a outra igual a 4. Com filtros de variados tamanhos, capturam-se n-gramas que mapeiam diferentes segmentos da entrada que podem representar aspectos relevantes para a tarefa.

Logo em seguida das camadas de convolução vem uma camada de *max pooling* global para selecionar os traços com o maior valor de cada filtro. As saídas do *max pooling* são concatenadas resultando em dois vetores de traços, um para o texto e outro para o contexto. Por fim, os vetores de traços são concatenados em um único vetor que une as informações do contexto com o texto, como apresentado na Figura 7.2. Cada camada de convolução contém 64 filtros, ativação ReLU, *padding* à esquerda e à direita da entrada e passo igual a 1.




Figura 7.2: Arquitetura da rede convolucional para o pré-processamento textual.

7.4.2 Rede de traços

A rede que recebe os traços manuais e os emotivos é composta de uma camada de normalização seguida de uma camada densa. Em uma primeira etapa, os

vetores emotivo e manual são concatenados, passando por uma camada de normalização para deixar os valores em uma mesma escala. Aqui, usamos a normalização de camada descrita por Ba, Kiros e Hinton (2016). A seguir, o vetor normalizado passa por uma camada densa com ativação ReLU, contendo 64 neurônios.

7.4.3 Rede de classificação

A rede de classificação recebe as saídas das redes convolucional e de traços concatenadas, sendo composta por duas camadas densas, uma camada de *dropout* e uma camada de saída. A primeira camada densa contém 564 neurônios e a segunda 128, ambas com ativação ReLU. A camada *dropout* é aplicada logo após a primeira densa, com um valor de 0,5. A camada de saída contém dois neurônios e uma ativação *softmax* para gerar a distribuição das classes.

7.4.4 Parâmetros de treinamento do modelo

O modelo foi implementado com auxílio da biblioteca Keras¹² da linguagem de programação Python. Para calcular a taxa de erro entre as etiquetas preditas e as esperadas, utilizou-se a função de perda de entropia cruzada multi-classes otimizada pelo algoritmo AdamW (LOSHCHILOV; HUTTER, 2019). A rede foi treinada por 15 épocas, com uma taxa de aprendizado de 0,0005 e tamanho do batch igual a 8.

¹²<https://keras.io/>

8 | Discussões dos resultados

Este capítulo apresenta os resultados obtidos ao longo desta pesquisa. Primeiro, apresentar-se-ão as discussões a respeito do modelo de classificação de emoções proposto e seu desempenho em uma amostra do corpus. A seguir, fornece-se uma breve análise estatística a respeito dos traços manuais implementados para validar sua ocorrência e pertinência na identificação de ironias. Na seção seguinte, serão apresentados os resultados com as representações vetoriais de palavras na arquitetura do modelo, com uma comparação entre os métodos contextuais e não-contextuais. A próxima seção trata de uma comparação de desempenho do modelo com os vetores de traços emotivos e manuais e sem eles com o objetivo de discutir o impacto dos traços na arquitetura e, logo em seguida, vem a discussão de resultados em que o modelo aqui proposto será comparado a outras arquiteturas. As duas últimas seções serão voltadas, respectivamente, para um debate sobre o que foi aprendido pelo modelo neural em comparação às intuições linguísticas de um humano e para uma discussão dos principais tipos de erros cometidos pelo modelo.

8.1 Avaliação do modelo de emoções

Como forma de testar a validade do método de classificação de emoções, uma amostra contendo 168 exemplos extraídos do corpus foram anotados manualmente de acordo com as emoções de Plutchik. A amostra selecionada não estava no corpus de ironia revisado e nela estão presentes somente textos não-irônicos. É possível que mais de uma emoção esteja expressa em um texto, de modo que alguns exemplos possuem mais de uma etiqueta. Nesses casos,

a ordem das etiquetas representa a sua importância no exemplo. Portanto, a primeira da lista seria a mais relevante no texto (emoção primária). A Figura 8.1 traz uma distribuição das etiquetas do corpus considerando as emoções primárias.




Figura 8.1: Distribuição de etiquetas no corpus anotado para classificação de emoções.

As classes não estão distribuídas igualmente, apesar de termos buscado por exemplos para representar cada uma delas. Isso é justificado pela distribuição das emoções no próprio corpus, uma vez que algumas são muito mais frequentes. A “raiva” foi a principal entre as oito, com 53 exemplos. Essa predominância de raiva reflete um comportamento comum encontrado entre os usuários de rede sociais que usam essas plataformas para espalhar ódio, como apontado por [Nikunen \(2018\)](#), ainda mais considerando que um dos temas selecionados na coleta do corpus foi Política, um assunto que costuma ser muito polarizado e em que a raiva é uma emoção extravasada. Outras emoções foram mais difíceis de se encontrar, entre elas estão “asco” (8) e “medo” (11). O “asco” muitas vezes apareceu misturado à “raiva”, principalmente pelo uso de xingamentos repulsivos direcionados à alguém, como “porco”, “merda” e “lixo”. Já o “medo” ocorreu muito com a “expectativa”, sendo difícil separá-las em alguns casos.

O classificador de emoções foi aplicado no corpus anotado e as etiquetas preditas por ele foram comparadas àquelas esperadas. Três métricas foram

utilizadas para medir o desempenho do método: precisão, cobertura e medida-F, presentes na Tabela 8.1. Como o modelo prediz uma única classe, avaliou-se seu desempenho com base nas emoções primárias. A acurácia foi de 57,71%.

Classe	Precisão	Cobertura	Medida-F	Referência
alegria	78,3	78,3	78,3	23
asco	0,0	0,0	0,0	8
confiança	50,0	41,2	45,2	17
expectativa	44,4	28,6	34,7	14
medo	36,4	72,7	48,4	11
raiva	56,4	66,0	60,8	53
surpresa	50,0	56,2	52,9	16
tristeza	83,3	57,7	68,2	26
média	49,8	50,0	48,6	168

Tabela 8.1: Avaliação da classificação de emoções.

As duas classes com os melhores desempenhos foram “alegria” e “tristeza”, uma oposta a outra no modelo de Plutchik. Observando a precisão, vê-se que o classificador teve uma taxa alta de acerto na identificação dessas emoções, por mais que as palavras “alegria” e “tristeza” sejam próximas do ponto de vista da distribuição contextual. Como a classificação de emoções se baseou nos *embeddings* do Sentence-BERT, esse resultado sinaliza que essas representações capturaram características semânticas distintivas entre elas. Isto é, o modelo distinguiu entre “alegria” e “tristeza” porque as representações dessas palavras continham atributos suficientemente diferentes entre si.

Nas demais emoções, o modelo não se saiu bem, variando em torno de 50% de medida-F. Duas exceções são “asco”, que não obteve nenhum acerto, e “expectativa”, que ficou com uma medida-F de 34,7%. O “asco” é a categoria que possui o menor número de exemplos e pode ser considerada uma das mais difíceis, pois raramente apareceu sozinha, sendo combinada a outras emoções negativas. Já a “expectativa” foi muito associada pelo modelo a expressões que indicam o futuro, tal qual “irá” e “vai acontecer”, o que não necessariamente carrega a emoção de expectativa, mas de uma antecipação. Além disso, essa também foi uma emoção que se misturou a outras no texto.

A categoria de “medo” apresentou uma grande disparidade entre precisão e cobertura, com a primeira bem menor do que a segunda, portanto o modelo classificou muitos exemplos como “medo” que na verdade pertenciam a outra classe. Essa dificuldade na identificação do medo pode estar na base do próprio modelo, isto é, a representação de “medo” seria muito semelhante a de outras emoções, ou no próprio corpus, em que o “medo” estaria contido no texto junto a outras emoções.

Além da avaliação de uma única etiqueta, testou-se como o modelo se saía quando todas as etiquetas possíveis na anotação eram consideradas, pois mesmo que ele não tenha acertado a emoção principal, pode ter identificado uma secundária. Nessa tarefa, o vetor de saída do modelo de emoções é usado, em que cada uma das posições é um valor entre 0 e 1 que pontua a similaridade do texto com a emoção correspondente.

Tsoumakas, Katakis e Vlahavas (2010) apresentam diversas métricas específicas para a avaliação de tarefas que envolvem múltiplas etiquetas. Aqui, selecionaram-se três delas: a precisão média ranqueada, o ranqueamento da perda e o erro de cobertura, todas disponíveis na biblioteca Scikit-learn¹. A primeira métrica computa a média de etiquetas com valor mais alto que estavam entre as etiquetas previstas na anotação manual do corpus para aquele exemplo. A segunda calcula o número médio de pares de etiquetas que estão ranqueados incorretamente de acordo com as do corpus, isto é, emoções que não estão previstas na anotação manual com valor mais alto do que aquelas esperadas. Por fim, a terceira métrica avalia o quanto é preciso observar no ranqueamento das etiquetas preditas pelo modelo para cobrir todas as etiquetas esperadas. Os resultados da avaliação para múltiplas etiquetas está dado na Tabela 8.2.

A precisão média ranqueada foi boa (71,9%), indicando que, no geral, as emoções com maiores pontuações atribuídas pelo modelo estavam entre as esperadas no corpus anotado. Essa precisão ficou mais alta do que a precisão média da tarefa anterior. O ranqueamento da perda não foi tão alto, reforçando que ele fez uma boa correlação no ranqueamento de emoções mais relevantes dentro do texto. Por fim, o erro de cobertura mostra que é preciso

¹<https://scikit-learn.org/1.6/index.html>

Tabela 8.2: Avaliação da classificação de emoções multi-labels.

Figura 8.2: Matriz de confusão de classificação de emoções.

Dois tipos de erros podem ser analisados com base na matriz de confusão: falsos positivos (FP) e falsos negativos (FN). Os primeiros se referem aos casos em que o modelo identificou uma categoria quando na verdade se tratava de outra (por exemplo, classificou como “raiva”, mas era “tristeza”), afetando a precisão da classe, enquanto os segundos são o inverso (era “raiva”, mas ele classificou como “tristeza”) e interferem na cobertura.

Começando com os falsos positivos (colunas da matriz), duas das classes que o modelo mais errou foram “medo” e “expectativa”. No caso de “medo”, o modelo fez diversas confusões com “raiva” (6) e “tristeza” (4), duas emoções também negativas. Alguns exemplos desses erros são dados a seguir.

1-T1: Não desejo esse mal para ninguém, mas quando vejo esses caras que zombavam do vírus e diziam que tudo isso era invenção da mídia para derrubar o bostonaro e que com isso levaram várias pessoas a sair do isolamento social eu, lá no fundo, tenho vontade de rir... que feio né?

1-T2: Minha vontade se fez: que eles peguem a doença, não morram, mas vejam a face da morte na beira da cama

O Exemplo 1 foi classificado como “medo” pelo modelo, mas a classificação esperada era “raiva”. Talvez esse erro se deva à presença de palavras como “morte” e “doença”, que são similares ao medo, mas essa não é a interpretação fornecida pelo texto, que expressa uma revolta do usuário em relação às pessoas que não levaram a sério a gravidade da Covid-19 e deseja que elas contraíssem a doença.

2-T1: A volta ao futebol ? Estou com saudades sim de jogar futebol , mas ao mesmo tempo sei o quanto prezo a minha saúde. Vejo essa movimentação que estão fazendo para voltar. Mas seria isso o melhor cenário hoje? Deixem a sua opinião.

2-T2: Não quero que volte, acho que vocês, jogadores, se arriscariam “por nada” no momento tenso que vivemos. Óbvio que tô morrendo de saudade de assistir, de ir ao estádio e tudo mais. Só que assim como quero estar em um lugar seguro, de quarentena, vocês também têm esse direito.

O modelo classificou o Exemplo 2 como “medo”, mas a emoção esperada era “tristeza”. Nesse caso, a classificação de “medo” não é incoerente com o texto, sendo identificada na anotação como uma emoção secundária. Priorizou-se “tristeza” como a primária pela passagem “morrendo de saudades”, que indica um sentimento de tristeza e de falta por algo que o usuário perdeu. Por outro lado, trechos como “se arriscariam” e “lugar seguro” podem indicar um medo, portanto esse exemplo é complexo e as duas classificações parecem se adequar ao que é expresso no texto.

Já a classificação de “raiva” se confunde com todas as categorias, exceto “medo”, sendo as principais “asco” (6), “confiança” (5) e “expectativa” (5). A confusão com “asco” é esperada, dada a similaridade entre elas. Já com outras, como “alegria” e “confiança”, são mais incoerentes. O Exemplo 3 apresenta um desses erros para análise.

3-T1: Jogo nosso é enrolado demais!!!! Toca toca e nada. Domina domina e nada. Um time em formação. Uma filosofia sendo criada. Temos que respeitar isso. Cornetar menos. Temos chances, mas o que tá sendo feito é pro futuro

3-T2: Com certeza. Por exemplo, um cara que não critico de jeito nenhum é o Marrony. Está quebrando galho de centroavante, nao é a dele. E também acho que time é pro ano que vem. Resta colocar a ansiedade de lado e entender os erros e a oscilação esse ano!!

O Exemplo 3 foi classificado como “raiva” pelo modelo em vez de “confiança”, que era o que se esperava. A anotação como “confiança” se deve a trechos como “um cara que não critico de jeito nenhum” e “está quebrando galho de centroavante”, que expressam carinho e admiração pelo jogador em questão. A segunda emoção possível nesse exemplo seria “expectativa”, dada pela parte “resta colocar a ansiedade de lado”. Mas “raiva” não estava entre as etiquetas possíveis nesse caso, portanto o modelo cometeu um erro e a etiqueta com maior similaridade não está entre as esperadas.

As classes com mais falsos negativos (linhas da matriz) foram “tristeza”, “confiança” e “expectativa”. A emoção de “tristeza” foi mais confundida com

“medo” (4) e “raiva” (4), ambas negativas, “confiança” com “raiva” (5) e “alegria” (3) e “expectativa” principalmente com “raiva” (5). Alguns exemplos são dados a seguir.

4-T1: quer conversar?? ir call?? qlqr coisa q eu possa ajudar?

4-T2: Eu tô no hospital acompanhando a minha avó... Te juro que eu que queria tá internada morrendo

O Exemplo 4 traz emoções de “tristeza”, pela situação em que a avó do usuário está, e “medo”, de perder alguém querido. Todavia, o modelo o classificou como “raiva”, o que é incompatível com a interpretação fornecida pelo texto. A palavra “morrendo” pode ter aumentado a similaridade do texto com “raiva”.

5-T1: É lamentável você ver um presidente que não ajuda recusar ajuda de outras pessoas.

5-T2: Parabéns ao Presidente Bolsonaro por recusar essa ajuda ridícula que a Argentina daria, apenas para inglês ver, Os nossos militares são muito mais capazes e em condições de socorrer a região.

Em 5, as etiquetas possíveis eram “confiança” e “raiva”, a primeira emoção direcionada a Bolsonaro e aos militares e, a segunda, à oferta de ajuda oferecida pela Argentina. Por sua vez, o modelo o classificou como “asco”, o que deve se dar pela palavra “ridícula” contida no texto. Assim sendo, o asco pode estar contido no texto como um afastamento e desprezo pela ajuda que foi considerada ridícula pelo usuário. Contudo, essa não é a emoção mais relevante, nem mesmo a secundária, portanto esse seria considerado um erro do método.

Por fim, o Exemplo 6 representa um dos erros em que a classificação esperada era “expectativa”, mas o modelo identificou “raiva”.

6-T1: Variante ômicron, riscos globais, perigos de lockdown total novamente, mortes, altíssima taxa de transmissão, colapso mundial Eu vendo as notícias:

6-T2: Eu ouvi alguém falar no começo da pandemia que a época pior seria em 2022. Ohh senhor coloca a mão. 🙏

Esse exemplo foi classificado em primeiro como “expectativa”, por causa da primeira sentença em que o usuário expressa uma ansiedade sobre a pandemia, e, em segundo, como “medo”, já que essa preocupação parece deixá-lo receoso sobre o futuro. Essas duas emoções parecem coerentes com o texto, mas o modelo o classificou como “raiva”, que não condiz com o sentimento expresso pelo texto. Uma possível causa dessa associação seja a palavra “pior”, que pode ser alta similaridade à “raiva”.

Essa breve discussão de erros mostrou como o método proposto pode ser afetado pela presença de determinadas palavras com alto grau de similaridade com uma emoção, mesmo que o conteúdo geral do texto não expresse aquela emoção. Em alguns casos, o modelo classificou o exemplo com uma emoção compatível com a interpretação do texto, sendo uma emoção secundária entre as etiquetas, o que pode contar como um acerto. A matriz de confusão mostra que inúmeros exemplos classificados como “raiva” na verdade pertenciam a outras classes, o que mostra que ele teve pouca precisão nessa classe.

Por fim, essa avaliação foi feita em apenas uma pequena amostra do corpus e com exemplos não-irônicos. Os resultados em textos irônicos podem ser ainda piores, já que na ironia há uma mistura de emoções que combina um significado aparente a um significado subjacente.

8.2 Validação dos traços manuais para a tarefa de ironia

Os sete traços manuais (Pistas de ironia, Citação, Oposição dos sujeitos, Conflito de sentimentos, Conflito de emoções, Impertinência interna e Impertinência externa) propostos foram analisados por meio de análises estatísticas e descritivas com o objetivo de validar sua pertinência na identificação de ironia. A Figura 8.3 traz a distribuição dos traços no corpus e a Tabela 8.3 apresenta estatísticas de valores assumidos por cada um. Para a contagem

dos traços, considerou-se apenas “ausência” (valor igual a zero) ou “presença” (valor acima de zero).

Traço	Mínimo	Máximo	Média	Desvio-Padrão
Citação	0,016	0,93	0,12	0,17
Pistas de ironia	0,015	0,21	0,05	0,03
Impertinência externa	0,028	1,0	0,33	0,20
Impertinência interna	0,015	1,0	0,17	0,20
Oposição dos sujeitos	0,056	1,0	0,41	0,24
Conflito de emoções	0,059	0,62	0,21	0,11
Conflito de sentimentos	0,053	0,75	0,22	0,11

Tabela 8.3: Estatísticas para os traços manuais no corpus.




Figura 8.3: Distribuição dos traços no corpus.

Os traços mais frequentes no corpus foram Oposição dos sujeitos (666), Pistas de ironia (548), Impertinência externa (543) e Conflito de Sentimentos (506), enquanto os com menor frequência foram Conflito de emoções (193) e Citação (201). A diferença entre o número de ocorrências do traço de Conflito de sentimentos com o de Conflito de emoções mostra o quanto a distinção apenas pela polaridade emotiva é mais abrangente no corpus. O traço de Impertinência externa teve mais ocorrências do que o de Impertinência interna.

Esse dado mostra que é mais recorrente encontrar dissimilaridades entre o texto e o contexto do que internamente no texto, portanto o contexto pode fornecer pistas que estariam perdidas caso ele não fosse considerado.

Os valores assumidos pelos traços estão entre maior do que 0 e menor ou igual a 1, indicando a proporção do texto ativado por aquele traço. Vê-se que os mínimos são bem baixos, entre 0,015 e 0,059, correspondentes a cerca de 1 e 6% do texto. Para os traços ativados por palavras, como Pistas de ironia e Citação, esse valor significa que o texto era longo e o modelo deve ter encontrado apenas uma palavra correspondente ao traço. Com relação aos máximos, o traço com o menor patamar é o de Pistas de ironia (0,21), o que reflete o fato dele ser baseado em um conjunto restrito de palavras, o que significa que no máximo há uma ou duas ocorrências dentro do texto todo.

A Figura 8.4 traz a distribuição do número de traços por exemplo para cada etiqueta (ironia e não-ironia) no corpus.




Figura 8.4: Distribuição dos traços no corpus.

O número de exemplos sem nenhum traço (0) é menor para a categoria de ironia do que para a de não-ironia, correspondente a 6% do total de exemplos


irônicos contra 10% para os não-irônicos. Somando os valores para as duas classes, há 103 exemplos sem nenhum traço, equivalentes a 9% do corpus. Portanto, a maioria dos exemplos do corpus apresenta ao menos um dos traços.

Os exemplos contendo de um a três traços são mais frequentes, totalizando 795 exemplos entre ironia e não-ironia, o que representa quase 70% do corpus. Proporcionalmente, esses traços representam 68% dos não-irônicos e 65% dos irônicos. Os exemplos em que quatro ou mais traços foram ativados são menos frequentes, ao todo são 288 casos equivalentes a cerca de 24% do corpus. Considerando por classe, eles equivalem a 27% dos irônicos e 21% dos não-irônicos. Desse modo, a proporção de irônicos com quatro ou mais traços é maior do que a mesma proporção para os não-irônicos.

A Figura 8.5 traz a distribuição dos traços com base na etiqueta.

O único traço cuja presença em exemplos irônicos superou a dos não-irônicos foi o de Impertinência externa. Além disso, mais da metade dos exemplos irônicos apresentou Impertinência externa, o que corrobora a importância desse traço para a tarefa. Isso significa que o texto e o contexto em exemplos irônicos tendem a apresentar maior dissimilaridade entre si. Em nossa hipótese, o ironista tende a apresentar informações que, aparentemente, não têm relevância dentro do contexto conversacional como uma forma de conseguir a atenção de seu receptor e desencadear a interpretação de ironia. O fato de mais da metade dos irônicos ter disparado o traço de Impertinência externa reforça essa hipótese, já que a similaridade se baseia em relações de distribuição contextual entre o texto e o contexto. Quando os textos são muito dissimilares, isso mostra que eles têm baixa probabilidade de ocorrerem juntos, portanto baixa relação sintático-semântica. Em conclusão, os exemplos irônicos têm maior probabilidade de serem menos correlacionados sintático e semanticamente com seus contextos do que os não-irônicos.

Para os demais traços, a frequência absoluta em exemplos não-irônicos passou a dos irônicos. A Oposição de Sujeitos teve mais presença do que ausência para as duas categorias (ironia e não-ironia), contudo, a proporção de exemplos irônicos que indicam uma oposição dos sujeitos ultrapassa a de não-irônicos, com mais de 60% dos exemplos irônicos tendo a presença do traço. A

**Figura 8.5:** Distribuição dos traços por etiqueta.

Oposição de sujeitos significa que foram encontradas oposições de polaridade entre as emoções do texto e do contexto. Esse resultado corrobora nossa ideia de que, para a ironia, é muito mais comum que os sujeitos demonstrem emoções de polaridades opostas do que iguais. Entretanto, o número de exemplos não-irônicos que apresentam Oposição de Sujeitos também é alto,

equivalente a mais de 50% do total, o que faz com que esse traço não seja uma marca exclusiva de ironia.

Os traços de Pistas de ironia e Conflito de sentimentos também aparecem em quase metade dos exemplos irônicos do corpus, respectivamente 49% e 45%, portanto essas são marcas recorrentes em ironia. No caso das Pistas de ironia, cerca de 44% dos não-irônicos também o desencadeiam. Esse traço é ativado por palavras que indicam exagero, como superlativos e advérbios de intensidade, que estão presentes em diversos tipos de texto não-irônicos, de modo que, isoladamente, as pistas de ironia não são marcas confiáveis para identificá-la. Assim como as pistas de ironia, o Conflito de sentimentos não se limita a textos irônicos, dado que 40% dos não-irônicos apresentam o traço. O Conflito de sentimentos busca por emoções com polaridades opostas dentro do texto, para capturar construções como “Eu amo ficar doente”. Porém, nem sempre a presença de emoções conflitantes é irônica, como em “Estou feliz que você vai viajar, mas triste por não poder ir junto”, em que a primeira parte do texto é positiva e, a segunda, negativa. Além disso, é preciso considerar que esse traço é baseado no classificador de emoções, portanto sua precisão depende do desempenho do outro modelo.

Já os traços de Citação, Impertinência interna e Conflito de emoções representam uma proporção menor dos textos irônicos, presentes em menos de 30% deles. No caso da Impertinência interna, os irônicos com presença do traço representam 22% dos exemplos e os não-irônicos, 20%, um pouco menor, mas as distribuições são praticamente iguais entre eles. A baixa cobertura desse traço indica que foi mais difícil capturar dissimilaridades entre partes do texto, de modo que o texto parece apresentar maior coerência interna. Outra possibilidade é que o método de similaridade por *word embeddings* não foi eficiente para reconhecer padrões anômalos dentro do texto por não ser capaz de distinguir categorias semânticas como esperado. Por exemplo, “peixe” e “banana” são substantivos e pertencem a uma categoria de Comida. Já “peixe” e “computador” são substantivos, mas pertencem a categorias semânticas distintas. O que gostaríamos é que houvesse uma grande dissimilaridade no segundo par para capturar termos e expressões inesperados no texto. No entanto, não há garantias de que o modelo está fazendo esse tipo de distinção.

Por sua vez, a proporção de irônicos com a presença de Citação e de Conflito de emoções foi menor em comparação à dos não-irônicos. Esses também foram os dois traços com menor frequência no corpus, portanto eles têm uma baixa cobertura e não há correlação direta com a ironia quando se observa apenas sua presença ou ausência no corpus.

A Figura 8.6 apresenta a média dos valores dos traços para cada uma das classes (ironia e não-ironia).




Figura 8.6: Valor médio dos valores assumidos por cada traço por etiqueta.

Os valores médios para as classes de ironia e não-ironia ficaram muito próximos para todos os traços, com exceção de dois: Impertinência interna e Citação. Para o primeiro, a média dos irônicos ficou acima da dos não-irônicos, com uma diferença de 0,05. Por outro lado, na Citação a média dos não-irônicos superou a dos irônicos em 0,04. Essa média nos fez questionar se não seria o caso das citações curtas serem mais frequentes nos textos

irônicos, enquanto citações longas apareceriam mais em textos não-irônicos. Isso porque citações longas podem estar se referindo a trechos de livros, falas em filmes, letras de músicas etc. Por sua vez, na ironia, a citação curta costuma indicar o trecho irônico dentro do texto, como uma evidência visual.

Com o intuito de testar essa hipótese, classificamos as citações em curtas (até três palavras) e longas (mais do que três palavras) e verificamos sua distribuição nos textos irônicos e não-irônicos. O resultado mostrou que 77 citações irônicas eram curtas, o que equivale 84% dos exemplos irônicos que contêm citação. Nos exemplos não-irônicos, 76 citações curtas apareceram, correspondente a 69% dos não-irônicos com citações. Portanto, citações longas são mais incomuns nos textos irônicos. Isso explica o porquê da média ser mais alta para a não-ironia. Desse modo, a relevância desse traço seria inversa: uma média mais baixa teria maior chance de indicar ironia do que uma mais alta.

Concluindo, os traços de Impertinência externa, Oposição de Sujeitos, Conflito de Sentimentos e Pistas de ironia têm uma alta cobertura para os textos irônicos. Com exceção de Impertinência externa, a frequência absoluta desses traços é maior para os não-irônicos do que para os irônicos, o que indica que eles não são exclusivos da ironia. Do ponto de vista da modelagem computacional, isso significa que esses traços podem gerar confusões na classificação, já modelos de aprendizado se baseiam em distribuições estatísticas inferidas a partir dos dados.

8.2.1 Avaliação dos traços manuais em um modelo

Treinamos um modelo de Árvore de Decisão utilizando como entrada os sete traços manuais propostos para avaliar a relevância deles na tarefa. A biblioteca usada para o treinamento do modelo foi a Scikit-learn², com os parâmetros *default* do modelo. Utilizou-se 70% do corpus para o treino e 30% para o teste. Os resultados são apresentados na Tabela 8.4.

No geral, a classe de não-ironia apresentou um desempenho melhor do que a de ironia, cuja cobertura ficou abaixo de 50%. A precisão ficou um

²<https://scikit-learn.org/stable/index.html>

Categoria	Precisão	Cobertura	Medida-F	Referência
não ironia	57,6	66,5	61,7	188
ironia	54,7	45,2	49,5	168
média	56,1	55,9	55,6	356

Tabela 8.4: Desempenho da árvore de decisão treinada com os traços manuais.

pouco melhor, com 54,7%, mas ainda não pode ser considerada boa. O desbalanceamento entre a cobertura e a precisão de ironia significa que o modelo perdeu muitos exemplos que na verdade eram ironia, classificando-os como não-ironia. No corpus, existe um número um pouco menor de irônicos, o que pode estar refletindo nesse enviesamento do modelo para a não-ironia.

Mesmo que o desempenho do modelo não seja bom, escolhemos fazer a primeira avaliação dos traços em um modelo baseado em aprendizado de máquina clássico, pois isso nos permite verificar a importância de cada traço para a decisão do modelo, apresentada na Figura 8.7.




Figura 8.7: Relevância dos traços manuais para a decisão do modelo.

O traço considerado mais relevante pelo modelo foi o de Pistas de ironia, seguido pelo de Conflito de Sentimentos e de Impertinência Externa. Esses três traços estão entre os mais frequentes no corpus e que possuem alta cobertura dos textos irônicos. Contudo, não são apenas a frequência absoluta

e a cobertura que influenciaram na decisão do modelo, uma vez que o traço de Oposição de sujeitos, que é o mais frequente, ficou em quarta posição na relevância de decisão do modelo.

As pistas de ironia terem tido tanta relevância para o modelo indicam que traços baseados em informações lexicais derivadas de intuições linguísticas podem ser efetivos para a detecção de aspectos da ironia. Por sua vez, a importância do traço de Conflito de Sentimentos corrobora outras pesquisas que identificaram os traços emotivos como os mais relevantes para a tarefa (CARVALHO et al., 2009; REYES; ROSSO; VEALE, 2013). Esse resultado também vai na direção do apontamento de Bromberek-Dyzman (2012) sobre a influência da identificação de valência de uma emoção para o reconhecimento de uma ironia, isto é, a percepção de um conflito entre um sentimento subjacente e um superficial, que é o que esse traço tenta capturar.

Em contrapartida, o traço com a menor influência na decisão do modelo foi o de Conflito de emoções. Desse modo, a identificação de oposições emocionais, como proposta por Plutchik (2001), não apresentou relevância para a classificação de ironia da forma como foi implementada nesta pesquisa. Esse resultado vai em direção contrária ao que foi apresentado por Agrawal, An e Papagelis (2020), que verifica que a identificação de emoções é mais relevante do que a de polaridade para a classificação de ironia. Uma explicação para a ineficiência desse traço, além da baixa cobertura, é a precisão do modelo de emoções utilizado para classificar o corpus. Apesar do classificador ser capaz de acertar a polaridade da emoção na maior parte dos casos, acertar a emoção em si é mais difícil. Além disso, nem sempre a oposição direta de emoções é o que caracteriza a ironia: uma pessoa pode estar com raiva e ironizar usando um discurso superficialmente alegre.

Como teste de validação final, treinamos a Árvore de Decisão com cada traço individualmente e combinados entre si para uma comparação de como eles afetam o desempenho, o que está apresentado na Tabela 8.5. As métricas se referem ao desempenho para a categoria de ironia.

Individualmente, o traço que alcançou o melhor desempenho foi o de Impertinência externa, superando os demais em todas as métricas (precisão, cobertura e medida-F), com o segundo melhor resultado sendo o de Oposição

Traços	Precisão	Cobertura	Medida-F
Citação	33,3	5,0	9,2
Pistas de ironia	46,8	26,8	34,0
Impertinência externa	53,0	36,9	43,5
Impertinência interna	51,8	16,7	25,2
Oposição dos sujeitos	50,0	33,3	40,4
Conflito de sentimentos	50,0	19,0	27,6
Conflito de emoções	40,7	6,5	11,3
Confl. de emoções e confl. de sentimentos	42,6	27,4	33,3
Impert. interna e impert. externa	57,8	35,1	43,7
Oposição dos sujeitos e pistas de ironia	43,3	32,7	37,2
Impert. externa, pistas de ironia e confl. de sentimentos	50,3	41,0	45,2
Impert. externa, impert. interna e pistas de ironia	56,8	44,6	50,0
Impert. externa, pistas de ironia, confl. de sentimentos e oposição dos sujeitos	45,1	38,7	41,7
Impert. externa, impert. interna, pistas de ironia e confl. de sentimentos	58,2	52,3	55,2
Impert. externa, impert. interna, pistas de ironia, confl. de sentimentos e oposição dos sujeitos	46,5	39,9	42,9
Impert. externa, impert. interna, pistas de ironia, confl. de sentimentos e confl. de emoções	55,1	44,6	49,3
Impert. externa, impert. interna, pistas de ironia, confl. de sentimentos e citação	57,1	45,2	50,5
Todos os traços	54,7	45,2	49,5

Tabela 8.5: Desempenho do modelo com os traços individuais e combinados.

dos sujeitos, com 40.4% de medida-F. O traço de Impertinência interna,

apesar de ter uma baixa cobertura, apresentou a segunda precisão mais alta entre os traços, com 51,8%.

A combinação entre os traços revelou subconjuntos que trouxeram resultados mais promissores do que a combinação de todos eles. Primeiro, os traços de Impertinência externa e interna combinados mostraram uma boa precisão de 57,8%, porém uma cobertura ruim de 35,1%. Acrescentando ao conjunto o traço de Pistas de ironia, a cobertura sobe para 44,6%, com um pequeno custo na precisão. Adicionado a esse o traço de Conflito de sentimentos, obteve-se o melhor desempenho do modelo, com uma precisão de 58,2% e uma cobertura de 52,3%, ambas medidas ultrapassando o desempenho do modelo com todos os traços.

A inserção de qualquer outro traço nesse conjunto causa uma perda de desempenho no modelo. Entre as combinações, a inserção do traço de Oposição dos sujeitos é a mais prejudicial ao desempenho, fazendo-o cair de 55,2% de medida-F para 42,9%, mais de 10%. Como já apontado, esse traço tem uma boa cobertura para a ironia, mas também para a não-ironia, de modo que ele não traz muita informação útil na tarefa de ironia especificamente e, pior, parece estar confundindo o modelo e fazendo seu desempenho piorar.

Em conclusão, nem todos os traços se mostraram relevantes para a tarefa, seja por sua baixa cobertura ou por não contribuírem com pistas relevantes para a tarefa. No caso do traço de Citação, além da baixa cobertura, constatamos que sua relevância para a ironia é inversa, portanto valores de ativação mais baixos têm maior chance de serem irônicos. Para a Oposição de sujeitos, não identificamos uma correlação direta entre o traço e a presença de ironia. Por fim, o Conflito de emoções não se mostrou relevante do ponto de vista do modelo, o que pode estar associado à precisão do classificador de emoções, mas também ao fato de que nem sempre uma ironia é construída por uma conflito de emoções específicas. Assim sendo, esses traços foram descartados e ficamos apenas com os restantes (Impertinência externa, Impertinência interna, Conflito de sentimentos e Pistas de ironia) para a implementação da versão final do modelo.

8.3 Validação das representações de palavras

Tendo selecionado os traços manuais, o modelo proposto foi treinado e testado no corpus, com a divisão de 80% dos dados para treinamento, correspondente a 948 exemplos, e 20% para avaliação, sendo 238 exemplos. Avaliaram-se quatro *word embeddings* para determinar qual proporcionava os melhores resultados: GloVe, FastText, BERT e XLM-RoBERTa. Para medir o desempenho do modelo foi feita uma validação em dez rodadas. Essa consiste no treinamento por 10 rodadas distintas no mesmo conjunto de dados para obter-se uma média dos resultados. Esse método de avaliação é necessário porque o desempenho de uma rede neural não é o mesmo sempre. Cada vez que o modelo é treinado, a rede pode apresentar resultados ligeiramente distintos.

A representação dos resultados foi feita com um gráfico *boxplot* (Figura 8.8), em que são dadas a mediana (linha laranja), a média (círculo azul), o valor mais alto (linha da extremidade superior) e o valor mais baixo (linha da extremidade inferior). Os círculos brancos indicam valores *outliers*, ou seja, que estão muito distantes da distribuição do restante da amostra. O gráfico traz as taxas de precisão, cobertura e medida-F para os modelos com os diferentes vetores. Os valores se referem à média entre as categorias de ironia e não-ironia para cada uma das métricas.




Figura 8.8: Validação das representações de palavras em 10 rodadas.

Comparando os quatro métodos de representação de palavras, vê-se que os *embeddings* contextuais (BERT e XLM-RoBERTa) se saíram melhor do que os não-contextuais. Entre os últimos, o GloVe superou o FastText, ficando com uma média mais alta nas três métricas. O GloVe também se mostrou mais estável, o que se verifica pela altura das caixas indicando uma distribuição em um intervalo pequeno e pelo valor mínimo e máximo estarem próximos das extremidades da caixa. Uma exceção apareceu em uma rodada, gerando os três *outliers* que estão bem abaixo dos demais resultados da amostra. Já os modelos contextuais obtiveram desempenhos similares, o BERT alcançando uma medida-F média de 69,77% e o XLM-RoBERTa, de 68,4%. No entanto, O BERT alcançou uma precisão média mais alta, de 72,0%, em comparação aos 69,5% obtido pelo XLM-RoBERTa.

Comparamos os modelos com relação à classe de ironia para garantir que os resultados eram válidos para a categoria de interesse (Figura 8.9).




Figura 8.9: Validação das representações de palavras para a categoria de ironia.

Observando individualmente a categoria de ironia, vê-se que a precisão do BERT superou a dos demais, ficando com uma média de 76%, o que equivale a 5% a mais do que o segundo melhor modelo (XLM-RoBERTa). Essa vantagem na precisão pode estar relacionada ao fato de que o BERT, além de contextual, foi pré-treinado somente para o português, enquanto o

XLM-RoBERTa é multilíngue, portanto as representações do BERT podem ser mais acuradas, capturando traços sintático-semânticos que sejam úteis para o reconhecimento da ironia.

Na cobertura, o GloVe obteve a maior média (60%), superando até mesmo os modelos contextuais, com uma diferença de cerca de 2% do XLM-RoBERTa. As representações contextuais obtiveram melhor resultado do que o FastText com uma grande diferença, mas de apenas 2% se comparado ao do GloVe. Entre o BERT e o XLM-RoBERTa, a diferença na medida-F entre os dois foi insignificante, com 64,8% para o primeiro e 64,2% para o segundo. Enquanto o BERT teve a melhor precisão, sua cobertura média foi pior do que a do XLM-RoBERTa, portanto o contrapeso entre precisão e cobertura deixou os dois modelos com desempenhos praticamente iguais.

No geral, a precisão média foi maior do que a cobertura para os quatro modelos de *word embeddings* testados. Os *word embeddings* contextuais se mostraram mais vantajosos do que os não-contextuais, principalmente com relação ao FastText e na medida de precisão. Esse resultado indica que os traços capturados pelos *word embeddings* contextuais fornecem informações mais relevantes para a classificação de ironia. Uma possível explicação para isso é que os significados na ironia muitas vezes são construídos dentro do contexto e esse nem sempre condiz com o significado da palavra isolada. Por exemplo, em “Isso sim é um amigo”, a palavra “amigo” tem um sentido positivo, mas se for “Isso sim é um amigo da onça”, a palavra adquire um novo significado dentro da expressão figurada. O GloVe alcançou a melhor cobertura e se mostrou mais estável do que os outros, mas, no geral, seu desempenho não superou as representações contextuais.

Desse modo, optou-se pelos *word embeddings* do BERT nesta pesquisa. Mesmo que o desempenho dele tenha ficado parecido ao do XLM-RoBERTa, o BERT apresentou uma precisão média maior do que o outro e a diferença na cobertura dos modelos é bem pequena. Sendo assim, os resultados daqui por diante foram realizados com os *word embeddings* do BERT.

8.4 Impacto dos traços para o modelo

Avaliamos o peso dos traços para a arquitetura comparando o desempenho do modelo em quatro cenários: sem nenhum traço, somente com traços emotivos, somente com os traços manuais e com todos os traços. O modelo sem traços consiste em uma rede neural convolucional que recebe como entrada as representações *word embeddings* do texto e do contexto. As arquiteturas em que apenas um traço foi testado são idênticas às do modelo proposto, mas recebem apenas um vetor correspondente ao traço avaliado, em vez do vetor dos dois traços concatenados.

Assim como nos testes das representações de palavras, separamos o corpus em 80% para o treinamento e 20% para o teste e validamos cada variação do modelo em 10 rodadas distintas no mesmo conjunto de treino e teste. A Figura 8.10 apresenta o desempenho médio entre ironia e não-ironia para as variações testadas.




Figura 8.10: Validação dos traços no desempenho do modelo.

O modelo sem traços foi o que apresentou a menor dispersão dos valores, mas também o com o maior número de *outliers*, alguns acima do valor médio da distribuição e, outros, abaixo. O modelo somente com os traços manuais foi o que obteve a maior precisão, com uma média de 72,5%, seguido do

modelo com todos os traços, com 72,0%. Quando treinado sem traços, a precisão média fica em 71,% e somente com os traços emotivos, em 71,4%. Portanto, o aumento na precisão ocorreu quando os traços manuais foram inseridos no modelo.

Com relação à cobertura, as quatro variações obtiveram valores muito semelhantes, por volta de 71%. No geral, o modelo somente com os traços manuais alcançou a melhor medida-F, com 70,9%, e o pior foi o modelo com todos os traços, com 69,7%, mas é uma diferença bem pequena. O fato de que o desempenho do modelo caiu quando todos os traços foram considerados em comparação ao modelo somente com os traços manuais indica que os traços emotivos podem ter prejudicado a classificação do modelo.

Na Figura 8.11 estão os valores de desempenho considerando somente a categoria de ironia.




Figura 8.11: Validação dos traços no desempenho do modelo para a categoria de ironia.

Isolando-se a categoria de ironia, observa-se que a precisão média do modelo somente com traços manuais é ainda maior do que a do modelo sem traços, com uma diferença de cerca de 4%. Quando treinado com todos os traços, o modelo também alcança uma precisão média mais alta do que sem traços. Portanto, os traços manuais representaram um aumento na precisão de classificação de ironia do modelo. Na arquitetura somente com os

traços emotivos, a precisão média ficou muito próxima do modelo sem traços, indicando que eles não influenciaram muito na classificação.

Já para a cobertura, há um cenário diferente: os modelos em que os traços manuais estavam presentes obtiveram médias menores, entre 57% e 59%, em contraste com os modelos sem traços e somente com os traços emotivos, que chegaram a 64%. Desse modo, ao mesmo tempo que melhoraram a precisão do modelo, os traços manuais prejudicaram a cobertura para a classificação de ironia. Uma possível razão para essa queda da cobertura pode ser o peso associado aos traços manuais, isto é, o modelo pode estar identificando apenas padrões muito específicos para a classificação de ironia, o que o faz perder diversos exemplos. Contudo, é preciso destacar que as médias dos modelos sem traços e somente com traços emotivos ficou mais alta por conta de *outliers* muito altos que a puxaram para cima, o que é ainda mais evidente para o modelo sem traços, em que a média está fora da caixa no *boxplot*. Desconsiderando esses *outliers*, as médias das coberturas vão para 60,8% no modelo sem traços e para 61,8% no modelo somente com traços emotivos.

O modelo com a melhor medida-F média foi o sem traços (67,8%), com o segundo lugar sendo do modelo somente com os traços emotivos (67,5%) e a pior classificação ficando com o modelo que considera todos os traços (64,0%). Uma das rodadas do modelo com todos os traços também teve um valor *outlier* que puxou a média para baixo. Ao desconsiderá-lo, o valor médio da medida-F sobe para 66,0%. Considerando que o modelo sem traços também teve duas rodadas com *outliers* que subiram seu desempenho, a diferença entre os modelos quando os *outliers* estão de fora é pequena.

Com o objetivo de afirmar com certeza se os desempenhos não apresentavam diferenças significativas entre si, aplicou-se um teste de significância estatística, o teste U de Mann-Whitney (MANN; WHITNEY, 1947). Esse é um teste não-paramétrico usado para testar se duas amostras independentes foram retiradas de populações com médias iguais. No teste, os demais modelos foram comparados ao desempenho do modelo sem traços para avaliar se a inserção de traços (manuais ou emotivos) teve influência no desempenho do modelo. Considerando um grau de liberdade de 0,1, se o valor-*p* do teste for maior do que o grau de liberdade, a diferença entre os desempenhos dos

modelos não é significativa (hipótese nula). Caso o valor- p seja menor do que o grau de liberdade, a diferença é significativa (hipótese alternativa). Utilizou-se as amostras de medida-F na classe de ironia para a comparação, resultados dados na Tabela 8.6.

Modelo	Valor- p
Traços emotivos	1,0
Traços manuais	0,42
Todos os traços	0,42

Tabela 8.6: Teste U para avaliar a significância dos traços.

O valor- p do teste de comparação de desempenho do modelo sem traços com o do modelo somente com os traços emotivos foi igual a 1, o que significa que as amostras são idênticas. Portanto, os traços emotivos isoladamente não representaram um impacto significativo para o desempenho do modelo. Nossa hipótese de que o vetor de emoções poderia ajudar o modelo a identificar conflitos de emoções no texto se mostrou inválida. Apesar de não terem prejudicado o desempenho, as emoções, da forma como foram inseridas, não melhoraram o modelo. Analisando as possíveis causas para isso, conclui-se que o modelo não aprendeu associações entre a presença de ironia e as emoções da forma esperada, portanto o seu peso durante o aprendizado foi pequeno. Uma parte do problema pode estar ligado à arquitetura da rede, em que os traços emotivos não foram concatenados ao vetor de palavras diretamente, mas aprendidos separadamente pela rede neural *feedforward*. Assim, diferente do trabalho de Agrawal, An e Papagelis (2020), a inserção de informação emotiva não ajudou no desempenho do nosso modelo.

Com relação ao vetor de traços manuais, os modelos somente com traços manuais e com todos os traços também não apresentaram diferença significativa do modelo sem traços. As medidas-F desses modelos ficaram um pouco abaixo da medida-F do modelo sem traços, porém, o teste comprovou que essa diferença não é estatisticamente significativa considerando um grau de liberdade de 0,1. Assim, a pequena queda na medida-F do modelo com os

traços manuais e com todos os traços não é estatisticamente significativa para a classe de ironia.

No caso dos traços manuais, a única medida que parece ter oferecido uma melhora de desempenho foi a precisão. Para avaliar se essa era significativa, aplicamos teste U comparando as amostras referentes à precisão dos modelos com todos os traços e somente com os traços manuais ao modelo sem traços para a classe de ironia. Adotando-se um grau de liberdade de 0,05, se o valor- p do teste for menor que o grau de liberdade, isso significa que houve uma melhora na precisão com a inserção dos traços manuais. Além disso, aplicamos o mesmo teste para a cobertura, com o objetivo de verificar se a aparente queda na cobertura com a inserção dos traços manuais foi realmente significativa, considerando um grau de liberdade de 0,05. Os resultados estão apresentados na Tabela 8.7.

Modelo	Precisão Valor- p	Cobertura Valor- p
Traços manuais	0,04	0,06
Todos os traços	0,12	0,13

Tabela 8.7: Teste U aplicado sobre a precisão e a cobertura nos modelos com os traços manuais.

O teste U evidenciou que o aumento médio de 4% na precisão do modelo somente com os traços manuais é significativo considerando um grau de liberdade de 0,05. Por sua vez, o teste com a cobertura mostrou que a diferença vista nas médias no *boxplot* não tem relevância estatística. Conclui-se que os traços manuais representaram uma melhora significativa na precisão do modelo. Mesmo que o impacto dos traços no desempenho final do modelo não tenha sido relevante, o modelo teve mais certeza sobre a classificação de ironia com a inserção dos traços, sem um prejuízo significativo em sua cobertura.

A partir desses resultados, desconsideramos os traços emotivos da arquitetura do modelo, uma vez que, além de não representarem uma melhora no desempenho, esses traços também fazem com que a precisão de classificação

de ironia decaia. Ou seja, o modelo somente com os traços manuais ficou sendo a arquitetura final.

8.5 Comparação dos métodos avaliados

A arquitetura final do modelo, nomeada de ConvContextual+traços, foi comparada a quatro modelos para a classificação de ironia: uma árvore de decisão alimentada pelos traços manuais, que é o modelo de base, uma arquitetura de rede convolucional alimentada com *word embeddings* do BERT que recebe apenas os textos como entrada, o modelo proposto sem traços (ConvContextual) e as redes neurais BERTimbau base, pré-treinada para o português, e XLM-RoBERTa multilíngue. Todos os modelos foram treinados no mesmo conjunto constituído de 80% dos dados e testados nos 20% restantes. As redes neurais foram validadas por dez rodadas para garantir a estabilidade dos resultados e o desempenho apresentado na Tabela 8.8 se refere à média das rodadas para a categoria de ironia.

Modelo	Precisão	Cobertura	Medida-F
Árvore de decisão	61,2	50,0	55,0
Convolucional	68,2	62,1	64,7
XLM-RoBERTa	71,5	54,2	60,2
BERTimbau	70,5	69,3	69,9
ConvContextual	72,3	64,0	67,5
ConvContextual+traços	76,0	59,5	66,9

Tabela 8.8: Comparação dos modelos avaliados para classificação de ironia.

O modelo de árvore de decisão alimentado com os traços manuais alcançou uma cobertura de 50% dos exemplos irônicos. Considerando que são apenas duas etiquetas (irônico e não-irônico) e que o corpus está bem balanceado, essa cobertura é quase aleatória. A precisão foi um pouco melhor, acima de 60%, mas tendo em vista que os traços manuais foram codificados especificamente pensando na detecção de ironia, esperava-se uma precisão mais alta. Seu desempenho é de um modelo de base, com uma medida-F perto de 50% para a detecção de ironia.

A rede convolucional apresenta uma melhora significativa em relação ao modelo de base, ficando com 64,7% de medida-F. Uma das vantagens do modelo convolucional são as representações de palavras contextuais fornecidas pelo BERT, que se mostraram o melhor modelo de *word embeddings* nos testes realizados. Comparando a rede convolucional com a ConvContextual, a única diferença entre os modelos é que o segundo tem camadas de convolução para o contexto além do texto. A consideração do contexto representou uma melhora de 4% na precisão do modelo, que se mostrou significativa quando aplicado um teste U de significância com 0,05 graus de liberdade. Portanto, corroborando a influência do contexto para a Detecção de Ironia apontada nos trabalhos de Ghosh, Fabbri e Muresan (2018), Srivastava et al. (2020) e Wallace, Charniak et al. (2015), o contexto conversacional ajudou a melhorar o desempenho do modelo na tarefa. Conclui-se que somente com o texto-alvo é mais difícil para o modelo identificar pistas de ironia. Fornecer o contexto pode ajudá-lo a desambiguar exemplos dependentes de informações externas ao texto para a classificação e torná-lo mais robusto.

Com relação às redes Transformer (BERTimbau e XLM-RoBERTa), a diferença no desempenho do BERTimbau para a XLM-RoBERTa mostra a vantagem dos modelos pré-treinados na língua-alvo sobre os multilíngues. Apesar de a XLM-RoBERTa ter alcançado uma boa precisão média, sua cobertura foi bem ruim, indicando que o modelo perdeu muitos exemplos irônicos. Com isso, a rede convolucional, mesmo sendo um modelo mais simples, saiu-se melhor do que a XLM-RoBERTa, com uma diferença de 4%. Já o BERTimbau alcançou a melhor medida-F entre os modelos comparados, com uma média de 69,9%.

Contudo, a diferença do BERTimbau para a ConvContextual e a ConvContextual+traços foi pequena, apenas 2% para a primeira e 3% para a segunda. A principal desvantagem dos modelos aqui propostos foi a cobertura, principalmente para a ConvContextual+traços. Na precisão, os dois modelos superam o BERTimbau, no caso da ConvContextual+traços com uma diferença de 6% que se provou estatisticamente significativa adotando um grau de liberdade de 0,05. Novamente, esse resultado fornece argumentos

em defesa da inserção de traços manuais na Detecção de Ironia com o objetivo de melhorar sua precisão, com um possível custo na cobertura.

A Figura 8.12 apresenta uma comparação das rodadas com o melhor desempenho para cada modelo nas categorias de ironia e não-ironia.




Figura 8.12: Comparação do desempenho geral dos modelos.

Quando as classes de ironia e não-ironia são comparadas, a segunda se saiu melhor em todos os modelos avaliados. Em todos os modelos, a medida-F para a classe de não-ironia supera a da ironia, significando que é mais fácil classificar o que não é ironia do que o que é. No caso, a cobertura da classe de não-ironia foi melhor, exceto para a ConvContextual, em que o inverso ocorreu. No geral, todos os modelos, exceto o modelo de base, alcançaram resultados semelhantes, com cerca de 70% de medida-F para a classe de ironia e 74% para não-ironia. Esse resultado está parecido ao que foi reportado por outras pesquisas em Detecção de ironia no X (SRIVASTAVA et al., 2020; WANG et al., 2015; GONÇALVES et al., 2015).

Um ponto relevante a ser considerado sobre os resultados é o tamanho do corpus: a maioria das pesquisas com dados de redes sociais utiliza corpora maiores, com cerca de 10000 exemplos. O nosso corpus anotado e revisado manualmente conta com 1085 exemplos, sendo apenas 541 irônicos. Conside-

rando que somente 80% dos dados foram usados para o treinamento, o total de exemplos irônicos visto durante o aprendizado foi pequeno, o que pode ter prejudicado o desempenho dos modelos.

8.6 Investigação dos n-gramas ativados pela rede

No trabalho de [Jacovi, Shalom e Goldberg \(2018\)](#), os autores examinam os n-gramas com maiores valores de ativação para cada filtro da rede convolucional com o intuito de verificar se eles eram relevantes para a resolução da tarefa ou escolhas aleatórias da rede. Inspirados pelo trabalho deles, treinamos a ConvContextual em uma rodada aleatória e investigamos se os n-gramas com as maiores ativações nos filtros correspondem aos mais relevantes para a Detecção de Ironia. Essa análise visa a compreender se os traços encontrados pelo modelo correspondem a trechos que humanos identificariam como mais importantes para a classificação de ironia ou não.

Nesse experimento, treinou-se a ConvContextual no corpus para a classificação de ironia com os *word embeddings* do GloVe. Optou-se por esses no lugar dos vetores contextuais do BERT por manterem a forma da palavra intacta, enquanto o BERT a separa em partes menores. Reduzimos o número de filtros de 64 para 32, com a finalidade de obter filtros mais especializados e facilitar a visualização. Após o treinamento, os exemplos irônicos foram aplicados no modelo e os pesos associados aos n-gramas pelos filtros foram extraídos do contexto e do texto, representados por um mapa de calor como na Figura 8.13, em que os quadrados mais escuros representam ativações mais altas do n-grama pelo filtro. Estamos considerando somente a camada convolucional com tamanho de janela igual a 3, isto é, trigramas. No eixo *X* estão os filtros e no *Y*, os n-gramas que constituem o texto.

É possível identificar que diversos filtros focam nos mesmos n-gramas. Um exemplo no Turno 2 é o n-grama “Eu tenho certeza”, que tem ativações mais altas nos filtros 11, 15 e 16. Além do mais, o mesmo filtro pode ativar diversas partes do texto, que podem ou não ser sequenciais. No Turno 2,





Figura 8.13: Exemplo 1 das ativações dos filtros de um texto irônico e seu contexto.


o filtro 31 mapeia os n-gramas que formam o trecho “certeza que o senhor Romildo Bonzinho”. No Turno 1, o filtro 8 ativou n-gramas no trecho “serviu para isolar alguns clubes”.

Analisando a relevância dos n-gramas ativados pela rede convolucional, aquele com o maior valor no Turno 2 é o n-grama “senhor Romildo Bonzinho” (filtro 6), que é um dos principais desencadeadores da ironia no texto, eviden-

ciado pelo uso de diminutivo no adjetivo (“bonzinho”). Correspondentemente, o n-grama “Romildo, presidente”, no Turno 1, tem a maior ativação no filtro 17, indicando uma correlação entre ativações do texto e do contexto.



(a) Turno 1.



(b) Turno 2.

Figura 8.14: Exemplo 2 das ativações dos filtros de um texto irônico e seu contexto.

O exemplo da Figura 8.14 apresenta alguns padrões de ativação interessantes para o Turno 2. Primeiro, o modelo atribuiu pesos altos para os n-gramas do trecho “esses políticos são super e honestos” (filtros 0, 4 e 27), que é a parte mais irônica do texto. Esse também é um trecho que contém um adjetivo (“honestos”) e o prefixo “super” que indica exagero, dois traços que marcam a ironia. Segundo, no Turno 1, o n-grama com a maior ativação é “nosso governo é”, que tem uma associação com o n-grama “esses políticos são” do Turno 2, que também recebeu a maior ativação. O último n-grama não traz nenhuma informação relevante do ponto de vista da identificação de ironia, mas estabelece uma correlação sintático-semântica com o contexto,

reforçando mais uma vez que o modelo codificou associações entre o texto e o contexto para atribuir o peso dos n-gramas. A partir disso, levantou-se a suposição de que o modelo atribuiu maior peso aos n-gramas do texto e do contexto com base na semelhança entre os seus *word embeddings*.

Realizou-se um experimento para avaliar essa hipótese da similaridade. Nele, extraiu-se o n-grama com o maior peso do texto e do contexto para cada um dos exemplos irônicos, totalizando 427 pares de n-gramas. A seguir, os n-gramas foram convertidos em *word embeddings* e calculou-se as similaridades entre os pares. Dos 427 pares, 341 alcançaram uma similaridade maior do que 50%, o que corresponde a quase 80% dos pares. A similaridade média da amostra ficou em 60,7% e a mediana em 62%. Isso mostra que há uma tendência de que os n-gramas com a maior ativação no texto e no contexto sejam semelhantes entre si. Essa similaridade pode se dar por palavras iguais nos n-gramas, como no caso do nome “Romildo” no exemplo 8.13, ou por palavras da mesma categoria morfosintática, como no exemplo 8.14.

Nos dois exemplos examinados, as ativações nos textos são mais intensas do que nos contextos, além de serem mais concentradas em determinados n-gramas, enquanto no contexto são mais esparsas. Talvez porque seja mais difícil identificar padrões relevantes para a classificação de ironia no contexto do que no texto, que é onde a ironia se encontra.

Para investigar se os n-gramas com ativações altas seguem algum padrão sintático-semântico, selecionaram-se os n-gramas com a maior ativação em cada um dos exemplos irônicos e aplicou-se um modelo de clusterização K-means para agrupá-los. Os n-gramas foram representados por seus *word embeddings*, que tiveram a sua dimensão reduzida por um modelo t-SNE (VAN DER MAATEN; HINTON, 2008). O número de aglomerados usado como parâmetro do algoritmo K-means foi igual a 6. Alguns exemplos dos n-gramas identificados para cada aglomerado estão na Tabela 8.9.

Os aglomerados mostram que as camadas convolucionais encontraram diversos padrões sintáticos similares. Um exemplo é o Aglomerado 1, que apresenta diversos n-gramas com o padrão preposição-nome-preposição. O modelo também identificou alguns n-gramas associadas a determinados temas, como Saúde (“vacina chinesa do”, “este vírus é”, “para a cloroquina”) e

Aglomerado	N-gramas
1	de leite para., do cidadão de, em 2021 em, em aglomera- dos de, eram garotas de, foi movida por, foi violento em, como partido político, de presidente honesto
2	o medicamento em, o governo desfez, o Senador Omar, o ouro olímpico, o Brasil está, o vírus na, este vírus é, ao vírus para
3	um pequeno filme, esse governador é, fosse uma empresa, renda para milhões, ela gastou milhões, a esquerda é, como inimigos é, mulher agora é
4	do hospital ., com a poluição, para a pandemia, para a cloroquina, da vacina é, peste chinesa no, vacina chinesa do, vacina Cubana que
5	esses políticos são, os barriga estão, coitadinhos os dois, sendo oprimidos por, só 8 jogos, foram 10 jogos, profissi- onalismo dos canais, ele procura críticas
6	, parabéns pela, do grandioso Diniz, do calça apertada, que grupo bom, por gentileza ACORDEM, senhor Ro- mildo Bonzinho, todos com máscara, futebol encantador que, vagabundo conspirador do

Tabela 8.9: Agrupamentos dos n-gramas gerado pelo método K-means.

Política (“o governo desfez”, “esse governador é”, “de presidente honesto”). Portanto, as camadas convolucionais capturaram padrões sintático-semânticos dos exemplos. Também é possível identificar alguns marcadores comuns em ironia, como o uso de diminutivo, em “coitadinhos os dois” (Aglomerado 5) e “senhor Romildo Bonzinho” (Aglomerado 6), e adjetivos, como em “do grandioso Diniz”, “do calça apertada” e “futebol encantador que” no Aglomerado 6.

Contudo, analisar os n-gramas fora dos textos dos quais foram extraídos é difícil quando se trata de ironia, uma vez que um n-grama que não parece relevante isoladamente pode o ser dentro do texto do qual foi retirado, de modo que é difícil medir de forma objetiva a relevância dos n-gramas selecionados pelo modelo de modo global. A nossa solução para obter uma análise mais precisa foi anotar manualmente uma amostra de 45 exemplos extraídos do

corpus de acordo com as partes consideradas mais irônicas dentro do texto. Esses trechos podem corresponder a uma única palavra, um trecho de sentença ou uma sentença completa. A anotação manual foi comparada aos três n-gramas com as maiores ativações no texto.

A classificação de correspondência entre a anotação esperada e a do modelo é: (1) exata, (2) parcial ou (3) nenhuma. A anotação é considerada “exata” se o trecho anotado manualmente está contido em um ou mais dos n-gramas do modelo; “parcial” caso apenas parte do trecho esperado esteja contido nos n-gramas; e “nenhuma” quando os n-gramas não contêm nada do trecho esperado.

Dos 45 exemplos, 7 (15,5%) foram classificados como correspondências exatas, 19 como parciais (42,2%) e 19 não encontraram nenhuma correspondência (42,2%). O número de correspondências exatas foi o menor, o que é esperado, considerando que, em alguns casos, a anotação esperada correspondia a uma sentença completa, enquanto os n-gramas selecionados eram apenas os três com maiores ativações. Nos casos de correspondências parciais, nem sempre a parte identificada pelo modelo era a mais relevante do ponto de vista da identificação da ironia. Por fim, em quase metade dos casos, o trecho esperado não estava entre os n-gramas selecionados no exemplo. Isso não quer dizer que o modelo não tenha identificado, apenas que ele não estava entre os três primeiros n-gramas no ranqueamento dos filtros.

Alguns exemplos de classificação do modelo em comparação ao que era esperado estão na Tabela 8.10, em que os trechos em negrito representam a anotação manual.

No primeiro exemplo, o n-grama com a maior ativação pelo modelo é uma correspondência exata do trecho irônico esperado. Esse é um exemplo interessante, pois a expressão irônica tem um sentido figurado que não é evidente, que poderia ser traduzido como “muito patriota”. Outros n-gramas com ativação alta foram associados a emoções negativas contidas na primeira sentença.

O segundo exemplo também contém uma correspondência exata, sendo uma única palavra em que o autor evidenciou a ironia pelo uso de aspas. Na classificação do modelo, o segundo n-grama com maior ativação é idêntico

Texto anotado	Classificação do modelo	Correspondência
E a galera morrendo de doença no teu país ficam como? Patriota pra caralho , tu.	Patriota para caralho, a galera morrendo, doença no teu	exata
Estas “ excelências ” daCPI não tem moral pra nada. Não se metam com Bolsonaro que vão se arrepender.	“ não tem, “ excelências ”, excelências ” não	exata
Primeiro jogo do retorno após a morte da mãe? Parabéns tá sabendo legal mane	a morte da, mãe ? Parabéns, ? Parabéns está	parcial
Escândalo da Covaxin! Acabou a mamata, não é mesmo? #sqn Governo genocida e corrupto!	da ! Acabou, , não é, Governo genocida e	parcial
Bahia está bem demais né? As receitas estão ótimas! #ironia . Como conseguem fazer malabarismos para defender esse presidente. E olha que o próprio usava o CAP de meta. Kkkkk	o próprio usava, meta . Kkkkk, As receitas estão	parcial
Aline, Chuvas acabando com parte de Minas, Espírito Santo, Rio de Janeiro continua “ lindo ” nas balas perdidas e violência e os CANTORES GOSPEIS #preocupados com visualizações de vídeos, shows, lançamento de músicas e clipes !!! Que “LEGAL” #sqn!!! O amor do Ciro pelo Brasil me moveu. #Ironia E depois de assistir ao programa... tenho, ainda, mais certeza do meu voto no Lula	de músicas e, com visualizações de, de vídeos , meu voto no, do meu voto, depois de assistir	nenhuma

Tabela 8.10: Comparação da anotação de trecho irônico por um humano e pelo modelo.

ao que era esperado, inclusive com as aspas. O uso de aspas foi um dos

traços inicialmente codificados como relevantes para a Detecção de Ironia, mas depois foi descartado por não apresentar impacto no desempenho do modelo. Analisando os n-gramas descobertos pela camada convolucional, é possível levantar a hipótese de que o próprio modelo codificou a importância da presença de aspas.

No terceiro exemplo, correspondências parciais foram encontradas pelo modelo no segundo e no terceiro n-gramas, com a palavra “Parabéns”. Essa é uma das principais desencadeadoras da ironia no exemplo, junto com “sabendo legal”.

No quarto, a ironia se constrói por uma pergunta irônica, portanto uma sentença completa e o modelo identificou parte dela nos n-gramas “da ! Acabou” e “, não é”. Já no quinto, são duas sentenças irônicas, em que o modelo mapeia parte da segunda no terceiro n-grama “As receitas estão”. Esse não seria o n-grama mais relevante na sequência. Por exemplo, “receitas estão ótimas” ou “estão ótimas !” seriam trechos mais interessantes para ter um peso mais alto por serem o ponto que desencadeia a ironia.

Nos últimos dois exemplos, nenhum dos trechos anotados manualmente estava entre os n-gramas selecionados. No penúltimo, dois trechos foram selecionados como desencadeadores de ironia em partes distintas do texto, ambos evidenciados pelo uso de aspas em uma palavra. O modelo considerou relevantes n-gramas da parte final do texto, que não trazem muita informação para a detecção de ironia. Da mesma forma, o último exemplo não corresponde ao que era esperado como mais relevante, já que a ironia se encontra na primeira sentença e os n-gramas selecionados são da segunda.

Com essa análise, foi possível estimar o quanto dos n-gramas com as maiores ativações do modelo estão entre os considerados mais relevantes por um humano. O resultado revelou que mais de 40% dos n-gramas entre os três mais altos não têm relevância para a classificação de ironia, enquanto as correspondências parciais nem sempre acertam na parte mais irônica do trecho anotado manualmente. O número de correspondências exatas encontrado foi equivalente a menos de 10% da amostra, revelando a dificuldade de determinar o trecho mais irônico de um texto com precisão.

No caso da correspondência exata, o método de análise proposto limita a acertabilidade do modelo, já que em alguns exemplos é difícil isolar um trecho como desencadeador da ironia, que é dada pela sentença completa. Uma opção mais flexível de métrica de correspondência seria considerar como acerto se o modelo identificasse a sentença irônica em vez do trecho. Além disso, apenas os três n-gramas com ativações mais altas no exemplo foram selecionados. Se a janela fosse maior, o número de correspondências parciais e exatas seria maior.

A análise com o K-means revelou que a camada de convolução identificou padrões sintático-semânticos e associações por similaridade. Contudo, esses padrões contêm muitas palavras vazias, como preposições e artigos, que não são as mais informativas do conteúdo do texto. Esses n-gramas receberem um peso tão alto pelo modelo é uma evidência de que ele aprende construções baseadas em padrões morfossintáticos mais simples, contudo, tem dificuldade em identificar construções semânticas mais complexas, como figuras de linguagem.

Por fim, a análise revelou que o modelo atribuiu pesos altos para n-gramas semelhantes entre o texto e o contexto. Portanto, ele tentou recuperar informações do contexto que se assemelhavam às do texto para identificar pistas de classificação. Esses padrões baseados em similaridade nem sempre são os mais relevantes para a resolução da tarefa. Sendo assim, a atribuição de pesos do modelo está longe de ser acurada como a busca de um humano por padrões linguísticos para a evidência de ironia.

8.7 Análise de erros do modelo

Realizamos uma rodada aleatória da ConvContextual+traços para analisar descritivamente os erros cometidos pelo modelo em via de compreender quais foram os casos mais difíceis para ela. A Figura 8.15 traz a matriz de confusão para acertos e erros do modelo.

Nessa rodada, o modelo classificou 27 exemplos como irônicos quando na verdade eram não-irônicos (falsos positivos). Alguns exemplos de erros do tipo falsos positivos são dados a seguir.




Figura 8.15: Matriz de confusão para a ConvContextual+traços em uma rodada aleatória.

1-T1: Finalmente, a ditadura chavista da Venezuela conseguiu levar o país à “igualdade” socialista. Agora, toda a população é miserável por igual. Enquanto o ditador e seus amigos desfrutam de todo conforto e riqueza de elite, claro.

1-T2: Meu Deus, o tanto de gente falando que o Brasil está igual Venezuela... São os mesmos que gritavam (fica em casa, economia vemos depois) quanta hipocrisia. E ainda vão botar a culpa no presidente! Essa turma deve ter problemas piscicologicos, tem base não.

O modelo classificou o Exemplo 1 como irônico, mesmo não havendo nenhuma indicação de ironia no Turno 2. Por outro lado, o contexto do exemplo contém uma ironia quando o usuário diz “conseguiu levar o país à “igualdade” socialista”. Nesse caso, o modelo pode ter identificado traços de ironia no Turno 1, como o uso de aspas, que o levaram a essa classificação. Dois traços manuais foram ativados nesse exemplo: Impertinência externa e Pistas de ironia, que também podem ter dado indicação de que o exemplo era irônico. A ativação da Impertinência externa é justificada do ponto de vista da relevância do texto em relação ao contexto, uma vez que, enquanto

o primeiro texto acusa a “ditadura chavista” de ter tornado a Venezuela miserável, o segundo texto se volta para o Brasil com o intuito de criticar as pessoas que foram à favor da quarentena, fugindo do foco de assunto do primeiro texto. Desse ponto de vista, a falta de relevância, apesar de fornecer pistas de ironia, também está presente em textos não-irônicos.

2-T1: Confirmando a informação destacada pela manhã. Decreto divulgado agora a pouco com informações a respeito do Lockdown contra o crescimento da Covid-19. Futebol Profissional (Campeonato Goiano) não será paralisado.

2-T2: Campeonato Goiano é tão ruim com vírus sem vírus com chuva de meteoro não faz falta, igual ter sogra ruim,, bons já sabem

No Exemplo 2, nenhum dos dois turnos apresenta ironia. No entanto, o Turno 2 tem aspectos metafóricos, como “chuva de meteoro”, “igual ter sogra ruim”, que podem ter sido confundidos pelo modelo como sendo ironia. Ademais, três dos quatro traços manuais foram ativados: Pistas de ironia, Impertinência externa e Conflito de sentimentos. O último traço é evidente pela oposição de polaridades entre “tão ruim” e “bons já sabem”. Todos esses elementos parecem ter corroborado as evidências de que se tratava de uma ironia.

Já nos falsos negativos, o modelo perdeu 35 exemplos que eram ironia, como é o caso do Exemplo 3 a seguir.

3-T1: Dome teria sido campeão desse Brasileirão facinho, mesmo com todas as goleadas nas costas.

3-T2: Tanto qto o Abel teria ganho o brasileiro e libertadores em 2019.
#SQN

Esse exemplo é um típico caso em que, sem a hashtag irônica, é muito difícil determinar se o usuário está sendo irônico ou não, mesmo com o contexto conversacional, pois ele depende de conhecimentos relacionados às crenças do usuário. A expressão “tanto quanto” dá uma pista linguística de que se trata

de uma ironia, tendo em vista que é um tipo de construção canonizada para desencadear a ironia, mesmo assim essa é uma pista fraca. Essas palavras ativaram o traço de Pistas de ironia, mas eles não foram suficientes para que o modelo atribuísse a classificação de ironia ao exemplo.

4-T1: Já entrei em contato com a Defensoria Pública p/ que possam prestar a devida assistência jurídica e sigo acompanhando.

4-T2: Defensoria publica 🙋, são 99% esquerdistas agora o coitado vai pegar prisão perpetua, valeu deputada por ajudar o cara #SQN

O Exemplo 4 se contradiz internamente quando o usuário primeiro diz “vai pegar prisão perpetua” e logo em seguida “valeu deputada por ajudar o cara”. Essa contradição só fica clara quando se tem o Turno 1 para saber que o usuário julgou que a ação da deputada de contatar a Defensoria fez com que a pessoa em julgamento fosse prejudicada. O único traço ativado para esse exemplo foi o Conflito de Sentimentos, o que comprova que os traços capturaram a oposição de polaridade nas expressões que expressam a contradição. Diferente do exemplo anterior, que depende muito mais da etiqueta irônica fornecida pelo usuário, esse poderia ser identificado como irônico apenas com o texto e o contexto, já que a contradição está contida neles.

5-T1: Agora acho que todos concordam que é melhor investir em ciência do que investir em armas, não dá pra matar o corona com um tiro de fuzil

5-T2: verdade, você lembra quantos caças de guerra o Lula comprou? Ainda por cima houve suspeita de favorecimento da empresa ganhadora da licitação. Há desculpe você estava falando de fuzil, que é muito mas caro que avião. Uma ultima observação onde você estava na copa? #ironia

No Exemplo 5, a ironia é construída com base em conhecimento de mundo, sendo esse um dos casos mais complexos de ironia para o modelo computacional, já que ele não possui as informações necessárias para compreendê-lo.

Por exemplo, ele envolve saber que aviões são mais caros que fuzis e que o favorecimento da empresa ganhadora significa “corrupção”. Mesmo assim, o modelo contou com a informação de três traços manuais que foram ativados: Conflito de sentimentos, Impertinência externa e Pistas de ironia. Entre eles, a Impertinência externa teve o maior valor de ativação, com 0,25, capturando a quebra de relevância vista no momento em que o usuário em T2 traz diversas informações sobre o governo Lula, quando o primeiro estava falando sobre investimento em ciência e pandemia. Desse modo, as informações dos traços foram pertinentes como pistas de ironia. Porém, o modelo não foi capaz de identificá-la.

6-T1: Alguém conhece algum time que trocou de técnico 3 vezes em menos de 1 mês e ganhou um campeonato? Normalmente, os times que fazem isso estão na zona de rebaixamento.

6-T2: De futebol vc entende né? #SQN pq de analogia tá lascado.

Já Exemplo 6 contém ironia nos dois turnos, ambas em forma de perguntas. A primeira é uma pergunta retórica que dá a entender que o usuário não acredita que um time que trocou de técnico três vezes possa ganhar um campeonato. O usuário em T2 compreendendo a ironia, responde com outra pergunta irônica implicitando que o primeiro não entende nada de futebol. A construção de todo o diálogo é sutil na ironia, já que não evidencia pistas de exagero, aspas ou outros recursos irônicos além da *hashtag* em T2. O único traço manual presente no exemplo foi o de Impertinência externa, por causa da dissimilaridade da segunda sentença de T2 com T1. Portanto, o texto e o contexto fornecem poucas pistas de ironia, ambos trazem ironias sutis e apenas um traço manual foi encontrado.

7-T1: Para descobrir se um fato político tornou o país melhor ou pior, basta saber quem se entristeceu e quem ficou feliz. A demissão de Sergio Moro foi lamentada pelos brasileiros que detestam corruptos e bandidos em geral. Mas uniu num Carnaval temporão o PT, o Centrão e o PCC.

7-T2: Mas claro que tudo de ruim que aconteceu entre Bolsonaro e Moro é culpa do PT. E foi o PT que trouxe o coronavírus pra Brasil pra acabar

com o governo Bolsonaro. Também não podemos esquecer que a Globo Lixo ajudou o PT nisso tudo. #sqn

O último exemplo traz uma ironia construída com base no que pode ser chamado de uma “paródia” do discurso que o usuário atribui a um determinado grupo, nesse caso, defensores do Bolsonaro. O exagero construído vai se tornando cada vez mais uma “teoria da conspiração” ao longo do texto e é isso que vai deixando mais evidente a interpretação de ironia. Esse exemplo é fortemente embasado em conhecimento de mundo, pois só seria possível reconhecê-lo como ironia quem conhecesse o cenário político brasileiro, as figuras mencionadas, a situação de pandemia etc, de modo que esse é um exemplo difícil. Além disso, o único traço encontrado foi o de Pistas de ironia, que, isoladamente, não é confiável para a classificação do texto como irônico.

A análise de erros ajudou a compreender quais foram os tipos de exemplos em que o modelo estava errando. No caso dos falsos positivos, os erros parecem ocorrer quando o texto contém marcas que o modelo deve ter associado à ironia, como pontuação exagerada, aspas e pistas de ironia. Dos 27 falsos positivos, 20 deles ativaram ao menos um traço manual. Nesse sentido, os traços manuais podem ter enviesado o modelo a classificações incorretas. Já para os falsos negativos, muitos dos exemplos perdidos são ironias dependem de conhecimento de mundo, informações sobre o usuário e aqueles com poucas evidências textuais de ironia. Apenas 5 dos 35 falsos negativos não continham nenhum traço, portanto a maioria deles tinha informações além daquelas fornecidas pelo texto e pelo contexto.

A influência dos traços não é determinística na classificação do modelo. No Exemplo 2, três dos quatro traços foram ativados indicando ironia e o modelo classificou o exemplo como irônico, enquanto no Exemplo 5 os mesmos três traços foram identificados, mas o modelo não identificou uma ironia. É claro que o valor de ativação do traço pode variar o peso associado a ele. No entanto, talvez a influência dos traços na decisão do modelo seja pequena, por isso ele não foi capaz de identificar ironias mesmo quando havia várias evidências externas oferecidas pelos traços manuais.

9 | Conclusões

Como discutido no Capítulo 2, a ironia não é um fenômeno que possui uma definição bem-estabelecida. Cada linha teórica e autor apresentam perspectivas de análise distintas sobre ela. Um ponto em comum encontrado nessas teorias foi a relevância do contexto para a sua compreensão, o que se tornou o cerne desta pesquisa. O trajeto desde os primeiros levantamentos de dados para a criação do corpus, a formulação e avaliação de hipóteses sobre padrões irônicos até os testes e validações com os modelos computacionais foi desafiador, o que não poderia ser diferente dada a complexidade envolvida no tema em si. Sendo a Detecção de Ironia uma tarefa recente, inicialmente encontramos dificuldades na busca por literatura de interesse, principalmente no que se refere à inserção de contexto na tarefa. Ao fim, concluímos a pesquisa cumprindo os objetivos estabelecidos. Neste capítulo, apresentam-se as principais contribuições oferecidas por esta pesquisa e trabalhos futuros em que pretendemos continuar pesquisando.

9.1 Contribuições desta pesquisa

Esta pesquisa teve como um de seus principais objetivos investigar características consideradas relevantes para o reconhecimento de textos irônicos dentro de um contexto conversacional em rede social. Ela teve início com a criação de um corpus de ironia em português extraído da rede social X, em que as primeiras hipóteses e buscas de pistas irônicas foram realizadas. A anotação manual do corpus mostrou que não é possível confiar com total certeza na *hashtag* fornecida pelo usuário para a classificação de ironia, principalmente

com relação à *hashtag* #sqn, que apresenta mais de um uso pelos usuários do X, um para a ironia e outro apenas como um negador não-irônico do que foi dito, como a inserção de um “mas não é” ao fim do texto. Essa divergência nos levou a uma taxa de discordância de 0,10 entre a anotação manual e a por *hashtag* para a classe de ironia. Esse resultado corrobora a importância de uma revisão manual para tarefas complexas e dependentes de informações que estão fora do texto, como é o caso da ironia.

A etapa de anotação manual do corpus ressaltou a importância do contexto conversacional para a identificação de uma ironia, já que algumas construções só são percebidas como irônicas a partir do que veio anteriormente. Cerca de 14,7% dos exemplos do corpus suscitaram dúvidas nos anotadores, sendo considerados difíceis por falta de informações de contexto, ambiguidades e ausência de referências sobre assuntos. Desses, 14 foram excluídos. Wallace, Kertz, Charniak et al. (2014) mostraram que humanos precisam recuperar o contexto conversacional em 30% dos casos na anotação de um corpus. Os resultados aqui obtidos indicam que determinados exemplos não podem ser resolvidos mesmo com a recuperação do contexto conversacional, o que ocorre principalmente em exemplos dependentes de conhecimentos prévios sobre o autor, tal como seu posicionamento político, gostos pessoais e crenças.

Nesses casos, a etiquetagem dada pela *hashtag* foi essencial para a classificação manual do corpus. Na análise de erros cometidos pelo modelo, verificou-se que alguns deles foram em exemplos cuja interpretação irônica era dada fortemente pela presença da *hashtag*. Esses casos seriam realmente difíceis para o modelo, já que, em sua maioria, não apresentam pistas linguísticas da presença de ironia. Outro aspecto que teve um papel relevante na classificação de ironia foram os conhecimentos de mundo, que também apareceram como um erro recorrente na análise de erros. Conclui-se que o contexto conversacional ajuda a resolver algumas das dificuldades enfrentadas pelos modelos de Detecção de Ironia, mas que outros aspectos extralinguísticos também precisam ser considerados para que a tarefa possa ser considerada resolvida. Além disso, vê-se que a intenção irônica nem sempre está acessível a todos os leitores, portanto a auto-etiquetagem por *hashtag* aparece como uma das formas de garantir que o significado irônico seja compreendido por

um público amplo e, dessa forma, proteger sua face de possíveis retaliações dentro da rede.

A melhora de 4% na precisão da ConvContextual em comparação a uma rede convolucional que recebe apenas o texto como entrada reforça o argumento em favor da influência do contexto conversacional para a Detecção de Ironia, corroborando os resultados de [Srivastava et al. \(2020\)](#), [Ghosh, Fabbri e Muresan \(2018\)](#) e [Wallace, Charniak et al. \(2015\)](#). Desse modo, tanto anotadores humanos quanto modelos computacionais se beneficiam do contexto conversacional para a classificação de ironia.

Por sua vez, a análise dos filtros da ConvContextual mostrou que 80% dos pares de n-gramas com a maior ativação no texto e no contexto possuem uma similaridade maior que 50%, de modo que o modelo parece ter priorizado informações semelhantes dentro do contexto conversacional para a atribuição de pesos. Esses n-gramas nem sempre continham informações relevantes para a identificação da ironia, representando padrões sintáticos compostos de muitas preposições e artigos. A comparação de n-gramas com ativações altas pelo modelo e por um anotador humano revelou que apenas 15,5% deles correspondiam exatamente ao que era esperado pela anotação manual, enquanto 42,2% apresentavam uma correspondência parcial. Assim sendo, a rede convolucional aprendeu muitos padrões irrelevantes para a identificação de ironia, que receberam peso mais alto do que padrões que eram relevantes. Isso condiz com o resultado reportado por [Jacovi, Shalom e Goldberg \(2018\)](#), em que 44% dos n-gramas selecionados pelos filtros se mostraram padrões aleatórios que pouco contribuem para a tarefa em que o modelo foi treinado.

Com relação aos traços manuais, consideraram-se inicialmente sete características para a classificação de ironia: Pistas de ironia, Impertinência externa, Impertinência interna, Conflito de sentimentos, Conflito de emoções, Citação e Oposição dos sujeitos. A validação dos traços com o modelo computacional revelou que a combinação das quatro primeiras alcançava o melhor desempenho, enquanto as demais foram abandonadas. Portanto, os traços associados à presença de incongruências dentro do texto (Conflito de sentimentos e Impertinência interna) e entre o texto e o contexto (Impertinência externa)

são relevantes para a tarefa de ironia, corroborando nossas intuições iniciais a respeito dos padrões irônicos.

A ConvContextual+traços alcançou uma melhora de 4% na precisão média em comparação ao modelo sem os traços manuais para a categoria de ironia, comprovando que os traços ajudaram na identificação de padrões irônicos. Contudo, a inserção de traços teve um custo na cobertura que acabou fazendo os resultados não apresentarem uma melhora em relação à ConvContextual. Uma das conclusões a que chegamos com esse resultado foi a de que os traços tornaram a rede muito especializada em padrões específicos que a fizeram perder diversos exemplos irônicos. Para confirmar essa hipótese, seria necessário avaliar qual foi o peso atribuído aos traços na camada *feedforward*.

A comparação dos métodos avaliados revelou que o modelo com a melhor precisão média foi a ConvContextual+traços, superando a do BERTimbau em 6%. No desempenho geral, contudo, o BERTimbau se saiu melhor por uma diferença de 3% impulsionada pela cobertura do modelo.

Já os traços emotivos representados pelo vetor de emoções não representaram uma melhora para a ConvContextual, frustrando nossa hipótese de que a inserção de informação emocional poderia ajudar o modelo na classificação de ironia. Como discutido no Capítulo 8, o modelo de emoções avaliado não alcançou um bom desempenho, confundindo diversas classes entre si, de modo que o vetor pode não ter capturado a similaridade do texto com as emoções da forma esperada. Portanto, o método de emoções avaliado não foi eficiente para a Detecção de ironia, o que não significa que as emoções não tenham um papel relevante para a tarefa, uma vez que outras pesquisas já provaram o benefício da combinação de ambas (AGRAWAL; AN; PAPAGELIS, 2018; REYES; ROSSO; VEALE, 2013; AGRAWAL; AN; PAPAGELIS, 2020).

9.2 Trabalhos futuros

Analisando os prós e contras do modelo proposto, verificamos alguns aspectos em que poderíamos tentar melhorá-lo. Consideramos converter os traços manuais em valores categóricos em vez de decimais. A razão para isso é que os valores de ativação dos traços manuais foram extremamente baixos, com

a maior média entre eles sendo igual a 0,41 para a Oposição dos Sujeitos. Considerando que diferenças de 0,01, por exemplo, não teriam nenhum impacto para aquele traço, poderia ser mais eficaz fatiá-los a partir de intervalos, pois assim apenas diferenças entre ativações mais altas e mais baixas seriam computadas.

Os traços emotivos não tiveram impacto no desempenho da maneira que foram implementados. Desse modo, queremos avaliar a substituição do vetor de similaridades por um vetor de *embeddings* emotivos, por exemplo o Emo2Vec (XU et al., 2018) e o DeepMoji (FELBO et al., 2017), como foi feito no trabalho de Babanejad et al. (2020). Os corpora de emoções, como LIWC (BALAGE FILHO; PARDO; ALUÍSIO, 2013) e WordNet-Affect (STRAPPARAVA, 2004), também podem ser opções para a identificação de emoções no texto.

Como demonstrado pela análise de erros, a rede neural teve problemas em classificar ironias construídas com base em conhecimento de mundo. Nesse sentido, uma linha de pesquisa interessante na área seria a implementação desse tipo de informações para o modelo. Um esforço nesse sentido é encontrado no trabalho de Van Hee, Lefever e Hoste (2018b), que exploram a codificação de sentimentos para as expressões baseadas em senso comum (como “perder o voo” e “se atrasar para a reunião”). Essa é uma área de exploração que ainda tem poucas pesquisas a respeito, mas consideramos como um ponto essencial na resolução da tarefa.

Com relação à rede convolucional, um dos problemas encontrados no modelo é que muitos dos n-gramas com ativações altas na verdade não eram relevantes para a tarefa. Para contornar esse problema, Jacovi, Shalom e Goldberg (2018) propõem a aplicação de uma função de ativação com um peso mínimo após a camada de *max pooling* para selecionar apenas n-gramas relevantes para a tarefa em treinamento. Essa função substituiria a ReLU, geralmente utilizada. Com essa filtragem, os autores mostram que os n-gramas aprendidos pela rede melhoram. Desse modo, considera-se a avaliação desse método como uma pesquisa futura para verificar se isso poderia tornar a rede convolucional mais robusta para a Detecção de Ironia.

Comparando os resultados desta pesquisa ao cenário geral da tarefa, vê-se que a Detecção de Ironia está longe de ser resolvida. No SemEval-2018

(VAN HEE; LEFEVER; HOSTE, 2018a), o modelo com o melhor desempenho na classificação binária de ironia alcançou 70,5% de medida-F, sendo esse o estado-da-arte no corpus. No português, o melhor resultado no IDT-2021 (CORRÊA et al., 2021) ficou em 55% de medida-F no corpus de redes sociais, com uma grande diferença de desempenho para o corpus de notícias, que obteve 89% de medida-F. Portanto, essa tarefa se torna mais difícil quando consideram-se textos curtos, que, além de serem ruidosos, são textualmente rasos para uma análise. Para textos curtos, a inserção do contexto conversacional se prova essencial. Os modelos de linguagem gerativos baseados em *prompts*, como GPT-4 (ACHIAM et al., 2023), DeepSeek (GUO et al., 2024) e Llama (TOUVRON et al., 2023), têm chamado muito a atenção por suas capacidades em elaborar, sumarizar e classificar textos. Há interesse em investigar futuramente como esses modelos se saem na classificação de ironia.

Ademais, a escolha de um corpus anotado manualmente para o treinamento e a avaliação do modelo foi um fator limitante, pois o número de dados de qualidade obtidos foi pequeno. Em uma pesquisa futura, pretende-se usar o corpus anotado manualmente apenas para a avaliação do modelo e o corpus não-revisado, que é composto por cerca de 4000 exemplos, para o treinamento. Desse modo, o modelo teria mais chances de aprender traços relevantes para a tarefa. Também gostaríamos de avaliar o modelo aqui proposto no corpus de ironia do português disponibilizado pelo IDT-2021 (CORRÊA et al., 2021) para uma comparação de desempenho com o estado-da-arte. Por fim, avaliamos a possibilidade de disponibilizar nosso próprio corpus de ironia para que outros pesquisadores possam utilizá-lo.

Referências

- ACHIAM, Josh et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- ADITYA JOSHI, VT. Are Word Embedding-based Features for Sarcasm Detection. *EMNLP 2016*, 2016.
- AGRAWAL, Ameeta; AN, Aijun. Affective representations for sarcasm detection. In: THE 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018. p. 1029–1032.
- AGRAWAL, Ameeta; AN, Aijun; PAPAGELIS, Manos. Learning Emotion-enriched Word Representations. In: _____. *Proceedings of the 27th International Conference on Computational Linguistics*. Santa Fe, New Mexico, USA: Association for Computational Linguistics, ago. 2018. p. 950–961. Disponível em: <<https://aclanthology.org/C18-1081>>.
- _____. Leveraging transitions of emotions for sarcasm detection. In: PROCEEDINGS of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2020. p. 1505–1508.
- AKIMOTO, Yoritaka et al. Irony comprehension: Social conceptual knowledge and emotional response. *Human Brain Mapping*, Wiley Online Library, v. 35, n. 4, p. 1167–1178, 2014.
- AMIR, Silvio et al. Modelling context with user embeddings for sarcasm detection in social media. *arXiv preprint arXiv:1607.00976*, 2016.
- AREAS, Eduardo Kenedy. *Curso básico de linguística gerativa*. Editora Contexto, 2013.

- ATTARDO, Salvatore. Irony as relevant inappropriateness. *Journal of pragmatics*, Elsevier, v. 32, n. 6, p. 793–826, 2000.
- BA, Jimmy Lei; KIROS, Jamie Ryan; HINTON, Geoffrey E. *Layer Normalization*. 2016. arXiv: [1607.06450 \[stat.ML\]](https://arxiv.org/abs/1607.06450). Disponível em: [1607.06450](https://arxiv.org/abs/1607.06450).
- BABANEJAD, Nastaran et al. Affective and contextual embedding for sarcasm detection. In: PROCEEDINGS of the 28th international conference on computational linguistics. 2020. p. 225–243.
- BALAGE FILHO, Pedro; PARDO, Thiago Alexandre Salgueiro; ALÚSIO, Sandra. An evaluation of the Brazilian Portuguese LIWC dictionary for sentiment analysis. In: PROCEEDINGS of the 9th Brazilian Symposium in Information and Human Language Technology. 2013.
- BAMMAN, David; SMITH, Noah. Contextualized sarcasm detection on twitter. In: 1. PROCEEDINGS of the international AAAI conference on web and social media. 2015. v. 9, p. 574–577.
- BARBIERI, Francesco; SAGGION, Horacio; RONZANO, Francesco. Modelling sarcasm in twitter, a novel approach. In: PROCEEDINGS of the 5th workshop on computational approaches to subjectivity, sentiment and social media analysis. 2014. p. 50–58.
- BARR, Dale J. Pragmatic expectations and linguistic evidence: Listeners anticipate but do not integrate common ground. *Cognition*, Elsevier, v. 109, n. 1, p. 18–40, 2008.
- BARRY, Elena; JAMEEL, Shoaib; RAZA, Haider. Emojional: Emoji embeddings. In: SPRINGER. UK Workshop on Computational Intelligence. 2021. p. 312–324.
- BATBAATAR, Erdenebileg; LI, Meijing; RYU, Keun Ho. Semantic-Emotion Neural Network for Emotion Recognition From Text. *IEEE Access*, v. 7, p. 111866–111878, 2019. DOI: [10.1109/ACCESS.2019.2934529](https://doi.org/10.1109/ACCESS.2019.2934529).
- BROMBEREK-DYZMAN, Katarzyna. Affective twist in irony processing. *Humana. Mente Journal of Philosophical Studies*, v. 5, n. 23, p. 83–111, 2012.

- BROWN, Penelope; LEVINSON, Stephen C. *Politeness: Some universals in language usage*. Cambridge university press, 1987. v. 4.
- BROWN, PF; DESOUZA, PV et al. Class-Based n-gram Models of Natural Language. *Comput. Linguist*, n. 1950, 1992.
- CALVO, Hiram; GAMBINO, Omar J; GARCÍA MENDOZA, Consuelo Varinia. Irony detection using emotion cues. *Computación y Sistemas*, Instituto Politécnico Nacional, Centro de Investigación en Computación, v. 24, n. 3, p. 1281–1287, 2020.
- CAMBRIA, Erik et al. Senticnet: A publicly available semantic resource for opinion mining. In: 2010 AAAI fall symposium series. 2010.
- CARVALHO, Paula et al. Clues for detecting irony in user-generated contents: oh...!! it's"so easy";-. In: PROCEEDINGS of the 1st international CIKM workshop on Topic-sentiment analysis for mass opinion. 2009. p. 53–56.
- CHOMSKY, Noam. Three models for the description of language. *IRE Transactions on information theory*, IEEE, v. 2, n. 3, p. 113–124, 1956.
- CIGNARELLA, Alessandra Teresa et al. Overview of the evalita 2018 task on irony detection in italian tweets (ironita). In: CEUR-WS. CEUR Workshop Proceedings. 2018. v. 2263, p. 1–6.
- COLLOBERT, Ronan et al. Natural language processing (almost) from scratch. *Journal of machine learning research*, v. 12, p. 2493–2537, 2011.
- CONNEAU, Alexis et al. Unsupervised Cross-lingual Representation Learning at Scale. *CoRR*, abs/1911.02116, 2019. arXiv: 1911.02116. Disponível em: <<http://arxiv.org/abs/1911.02116>>.
- CORRÊA, Ulisses B et al. Overview of the idpt task on irony detection in portuguese at iberlef 2021. *Procesamiento del Lenguaje Natural*, v. 67, p. 269–276, 2021.
- DA SILVA, Fábio Ricardo Araújo. Detecção de ironia e sarcasmo em língua portuguesa: Uma abordagem utilizando deep learning.(2018). *Monografia Universidade Federal de Mato Grosso, Instituto de Computação, Cuiabá*, 2018.

- DARWIN, Charles. *The Expression Of The Emotions In Man And Animals*. Oxford University Press, abr. 1998. ISBN 9780195112719. DOI: [10.1093/oso/9780195112719.001.0001](https://doi.org/10.1093/oso/9780195112719.001.0001). Disponível em: <https://doi.org/10.1093/oso/9780195112719.001.0001>.
- DEVLIN, Jacob. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- EKMAN, Paul. Expression and the nature of emotion. *Approaches to Emotion*, Erlbaum, Hillsdale, NJ, p. 319–343, 1984.
- _____. An argument for basic emotions. *Cognition & emotion*, Taylor & Francis, v. 6, n. 3-4, p. 169–200, 1992.
- EKMAN, Paul et al. Universals and cultural differences in the judgments of facial expressions of emotion. *Journal of personality and social psychology*, American Psychological Association, v. 53, n. 4, p. 712, 1987.
- FARÍAS, Delia Irazú Hernández; PATTI, Viviana; ROSSO, Paolo. Irony detection in twitter: The role of affective content. *ACM Transactions on Internet Technology (TOIT)*, ACM New York, NY, USA, v. 16, n. 3, p. 1–24, 2016.
- FELBO, Bjarke et al. Using millions of emoji occurrences to learn any-domain representations for detecting sentiment, emotion and sarcasm. *arXiv preprint arXiv:1708.00524*, 2017.
- FIORIN, José Luiz. *Figuras de retórica*. Contexto, 2014.
- FIRTH, J. *A synopsis of linguistic theory 1930-1955*. Longman, 1957. (Studies in Linguistic Analysis, Philological).
- FISH, Karyn; ROTHERMICH, Kathrin; PELL, Marc D. The sound of (in) sincerity. *Journal of Pragmatics*, Elsevier, v. 121, p. 147–161, 2017.
- FREDA, Simona et al. Computational rule-based model for Irony Detection in Italian Tweets. In: CEUR WORKSHOP PROCEEDINGS. PROCEEDINGS of Third Italian Conference on Computational Linguistics (CLiC-it 2016) & Fifth Evaluation Campaign of Natural Language Processing and Speech Tools for Italian. Final Workshop (EVALITA 2016). 2016. v. 1749, p. 1–6.

- GARCIA, Klaifer; BERTON, Lilian. Topic detection and sentiment analysis in Twitter content related to COVID-19 from Brazil and the USA. *Applied soft computing*, Elsevier, v. 101, p. 107057, 2021.
- GHANEM, Bilal et al. Idat at fire2019: Overview of the track on irony detection in arabic tweets. In: PROCEEDINGS of the 11th Annual Meeting of the Forum for Information Retrieval Evaluation. 2019. p. 10–13.
- GHOSH, Debanjan; FABBRI, Alexander R; MURESAN, Smaranda. Sarcasm analysis using conversation context. *Computational Linguistics*, MIT Press One Rogers Street, Cambridge, MA 02142-1209, USA journals-info ..., v. 44, n. 4, p. 755–792, 2018.
- GHOSH, Debanjan; VAJPAYEE, Avijit; MURESAN, Smaranda. A report on the 2020 sarcasm detection shared task. *arXiv preprint arXiv:2005.05814*, 2020.
- GIRLEA, Codruta; GIRJU, Roxana. Decoding the Perception of Sincerity in Dialogues. *IEEE Transactions on Affective Computing*, IEEE, v. 12, n. 1, p. 2–15, 2018.
- GONÇALVES, Pollyanna et al. Bazinga! caracterizando e detectando sarcasmo e ironia no Twitter. In: SBC. ANAIS do IV Brazilian Workshop on Social Network Analysis and Mining. 2015.
- GORACH, Tasneem. Deep convolutional neural networks-a review. *International Research Journal of Engineering and Technology (IRJET)*, v. 5, n. 07, p. 439–452, 2018.
- GRICE, Herbert P. Logic and conversation. In: SPEECH acts. Brill, 1975. p. 41–58.
- GUMPERZ, John. Contextualization and understanding. In: *Rethinking Context: Language as an Interactive Phenomenon*. Edição: Alessandro Duranti e Charles Goodwin. Cambridge: Cambridge University Press, 1992. p. 229–252.
- GUO, Daya et al. DeepSeek-Coder: When the Large Language Model Meets Programming—The Rise of Code Intelligence. *arXiv preprint arXiv:2401.14196*, 2024.

- GUPTA, Raj Kumar; YANG, Yinping. Crystalfeel at semeval-2018 task 1: Understanding and detecting emotion intensity using affective lexicons. In: PROCEEDINGS of the 12th international workshop on semantic evaluation. 2018. p. 256–263.
- HAKAK, Nida Manzoor et al. Emotion analysis: A survey. In: IEEE. 2017 international conference on computer, communications and electronics (COMPTELIX). 2017. p. 397–402.
- HARRIS, Zellig S. Distributional Structure. *WORD*, Routledge, v. 10, n. 2-3, p. 146–162, 1954. DOI: [10.1080/00437956.1954.11659520](https://doi.org/10.1080/00437956.1954.11659520). eprint: <https://doi.org/10.1080/00437956.1954.11659520>. Disponível em: <https://doi.org/10.1080/00437956.1954.11659520>.
- HARTMANN, Nathan et al. Portuguese word embeddings: Evaluating on word analogies and natural language tasks. *arXiv preprint arXiv:1708.06025*, 2017.
- HAVERKATE, Henk. A speech act analysis of irony. *Journal of pragmatics*, Elsevier, v. 14, n. 1, p. 77–109, 1990.
- HE, Kaiming et al. Deep residual learning for image recognition. In: PROCEEDINGS of the IEEE conference on computer vision and pattern recognition. 2016. p. 770–778.
- HOVY, Eduard; LAVID, Julia. Towards a ‘science’ of corpus annotation: a new methodological challenge for corpus linguistics. *International journal of translation*, v. 22, n. 1, p. 13–36, 2010.
- HUBEL, D. H.; WIESEL, T. N. Receptive fields and functional architecture of monkey striate cortex. *The Journal of Physiology*, v. 195, n. 1, p. 215–243, 1968. DOI: <https://doi.org/10.1113/jphysiol.1968.sp008455>. eprint: <https://physoc.onlinelibrary.wiley.com/doi/pdf/10.1113/jphysiol.1968.sp008455>. Disponível em: <https://physoc.onlinelibrary.wiley.com/doi/abs/10.1113/jphysiol.1968.sp008455>.
- ILIĆ, Suzana et al. Deep contextualized word representations for detecting sarcasm and irony. *arXiv preprint arXiv:1809.09795*, 2018.

- JACOVI, Alon; SHALOM, Oren Sar; GOLDBERG, Yoav. Understanding convolutional neural networks for text classification. *arXiv preprint arXiv:1809.08037*, 2018.
- JAIN, Vinay Kumar; KUMAR, Shishir; FERNANDES, Steven Lawrence. Extraction of emotions from multilingual text using intelligent text processing and computational linguistics. *Journal of computational science*, Elsevier, v. 21, p. 316–326, 2017.
- JAN, Deriu et al. Sentiment classification using an ensemble of convolutional neural networks with distant supervision. *Proceedings of SemEval (2016)*, p. 1124–1128, 2016.
- JIA, Xiuyi et al. Three-way decisions based feature fusion for Chinese irony detection. *International Journal of Approximate Reasoning*, Elsevier, v. 113, p. 324–335, 2019.
- JOSHI, Aditya; BHATTACHARYYA, Pushpak; CARMAN, Mark J. Automatic sarcasm detection: A survey. *ACM Computing Surveys (CSUR)*, ACM New York, NY, USA, v. 50, n. 5, p. 1–22, 2017.
- JOSHI, Aditya; SHARMA, Vinita; BHATTACHARYYA, Pushpak. Harnessing context incongruity for sarcasm detection. In: PROCEEDINGS of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 2: Short Papers). 2015. p. 757–762.
- JOULIN, Armand et al. Bag of tricks for efficient text classification. *arXiv preprint arXiv:1607.01759*, 2016.
- JURAFSKY, Dan; MARTIN, James H. Speech and language processing : an introduction to natural language processing, computational linguistics, and speech recognition. In: Pearson Prentice Hall, 2009. Introduction.
- JURAFSKY, Daniel. Pragmatics and computational linguistics. *The handbook of pragmatics*, Wiley Online Library, p. 578–604, 2006.

- JURAFSKY, Daniel; MARTIN, James H. Vector Semantics and Embeddings. In: SPEECH and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models. 3rd, 2024. Disponível em: <<https://web.stanford.edu/~jurafsky/slp3/>>.
- KALCHBRENNER, Nal; GREFFENSTETTE, Edward; BLUNSON, Phil. A convolutional neural network for modelling sentences. *arXiv preprint arXiv:1404.2188*, 2014.
- KAUFER, David. Irony and rhetorical strategy. *Philosophy & Rhetoric*, JSTOR, p. 90–110, 1977.
- KHATTI, Anupam et al. Your sentiment precedes you: Using an author’s historical tweets to predict sarcasm. In: PROCEEDINGS of the 6th workshop on computational approaches to subjectivity, sentiment and social media analysis. 2015. p. 25–30.
- KHODAK, Mikhail; SAUNSHI, Nikunj; VODRAHALI, Kiran. A Large Self-Annotated Corpus for Sarcasm. In: PROCEEDINGS of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018). Miyazaki, Japan: European Language Resources Association (ELRA), 2018. Disponível em: <<https://aclanthology.org/L18-1102>>.
- KIM, Yoon. *Convolutional Neural Networks for Sentence Classification*. 2014. arXiv: 1408.5882 [cs.CL]. Disponível em: <<https://arxiv.org/abs/1408.5882>>.
- KRALJ NOVAK, Petra et al. Sentiment of Emojis. *PLOS ONE*, Public Library of Science, v. 10, n. 12, p. 1–22, dez. 2015. DOI: 10.1371/journal.pone.0144296. Disponível em: <<https://doi.org/10.1371/journal.pone.0144296>>.
- KRICHEN, Moez. Convolutional neural networks: A survey. *Computers*, MDPI, v. 12, n. 8, p. 151, 2023.
- LECUN, Yann et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, Ieee, v. 86, n. 11, p. 2278–2324, 1998.

- LEVY, Omer. 334Word Representation. In: THE Oxford Handbook of Computational Linguistics. Oxford University Press, jun. 2022. ISBN 9780199573691. DOI: 10.1093/oxfordhb/9780199573691.013.57. eprint: <https://academic.oup.com/book/0/chapter/358150020/chapter-pdf/45719790/oxfordhb-9780199573691-e-57.pdf>. Disponível em: <<https://doi.org/10.1093/oxfordhb/9780199573691.013.57>>.
- LIU, Yijiang; WAN, Yinghong; SU, Xiao. Identifying individual expectations in service recovery through natural language processing and machine learning. *Expert Systems with Applications*, Elsevier, v. 131, p. 288–298, 2019.
- LIU, Yinhan. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*, v. 364, 2019.
- LOSHCHILOV, Ilya; HUTTER, Frank. *Decoupled Weight Decay Regularization*. 2019. arXiv: 1711.05101 [cs.LG]. Disponível em: <<https://arxiv.org/abs/1711.05101>>.
- MAHENDRAN, Aravindh; VEDALDI, Andrea. Visualizing deep convolutional neural networks using natural pre-images. *International Journal of Computer Vision*, Springer, v. 120, p. 233–255, 2016.
- MANN, Henry B; WHITNEY, Donald R. On a test of whether one of two random variables is stochastically larger than the other. *The annals of mathematical statistics*, JSTOR, p. 50–60, 1947.
- MARTEN, Gabriel Schubert; FREITAS, Larissa Astrogildo de. The construction of a corpus for detecting irony and sarcasm in portuguese. *Brazilian Journal of Development*, v. 7, n. 5, p. 47973–47984, 2021.
- MAYNARD, Diana G; GREENWOOD, Mark A. Who cares about sarcastic tweets? investigating the impact of sarcasm on sentiment analysis. In: ELRA. LREC 2014 proceedings. 2014.
- MESQUITA, Raúl; DUARTE, Fernanda. *Dicionário de psicologia*. Plátano Lisboa, 1996.

- MIKHEEV, Andrei. 549Text Segmentation. In: THE Oxford Handbook of Computational Linguistics. Oxford University Press, jun. 2022. ISBN 9780199573691. DOI: [10.1093/oxfordhb/9780199573691.013.34](https://doi.org/10.1093/oxfordhb/9780199573691.013.34). eprint: <https://academic.oup.com/book/0/chapter/358151387/chapter-pdf/45719882/oxfordhb-9780199573691-e-34.pdf>. Disponível em: <https://doi.org/10.1093/oxfordhb/9780199573691.013.34>.
- MIKOLOV, Tomas et al. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.
- MOHAMMAD, Saif; BRAVO-MARQUEZ, Felipe et al. Semeval-2018 task 1: Affect in tweets. In: PROCEEDINGS of the 12th international workshop on semantic evaluation. 2018. p. 1–17.
- MOHAMMAD, Saif M; TURNEY, Peter D. Crowdsourcing a word–emotion association lexicon. *Computational intelligence*, Wiley Online Library, v. 29, n. 3, p. 436–465, 2013.
- MOHAMMADI, Elham; AMINI, Hessam; KOSSEIM, Leila. Neural feature extraction for contextual emotion detection. In: PROCEEDINGS of the International Conference on Recent Advances in Natural Language Processing (RANLP 2019). 2019. p. 785–794.
- MOXEY, Linda M; SANFORD, Anthony J. Prior expectation and the interpretation of natural language quantifiers. *European Journal of Cognitive Psychology*, Taylor & Francis, v. 5, n. 1, p. 73–91, 1993.
- NANDWANI, Pansy; VERMA, Rupali. A review on sentiment analysis and emotion detection from text. *Social network analysis and mining*, Springer, v. 11, n. 1, p. 81, 2021.
- NIKUNEN, Kaarina. From irony to solidarity: Affective practice and social media activism. *Studies of Transition States and Societies*, Rahvusvaheliste ja Sotsiaaluuringute Instituut ja Riigiteaduste Instituut, v. 10, n. 2, p. 10–21, 2018.

- ORTEGA-BUENO, Reynier et al. Overview of the task on irony detection in Spanish variants. In: PROCEEDINGS of the Iberian languages evaluation forum (IberLEF 2019), co-located with 34th conference of the Spanish Society for natural language processing (SEPLN 2019). CEUR-WS. org. 2019. v. 2421, p. 229–256.
- PAIVA, Vera Lúcia Menezes de Oliveira e. A linguagem dos emojis. *Trabalhos em Linguística Aplicada*, SciELO Brasil, v. 55, n. 02, p. 379–401, 2016.
- PENG, Sancheng et al. A survey on deep learning for textual emotion analysis in social networks. *Digital Communications and Networks*, v. 8, n. 5, p. 745–762, 2022. ISSN 2352-8648. DOI: <https://doi.org/10.1016/j.dcan.2021.10.003>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2352864821000833>>.
- PENNINGTON, Jeffrey; SOCHER, Richard; MANNING, Christopher. GloVe: Global Vectors for Word Representation. In_____. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Doha, Qatar: Association for Computational Linguistics, out. 2014. p. 1532–1543. DOI: [10.3115/v1/D14-1162](https://doi.org/10.3115/v1/D14-1162). Disponível em: <<https://aclanthology.org/D14-1162/>>.
- PETERS, Matthew E. et al. *Deep contextualized word representations*. 2018. arXiv: [1802.05365](https://arxiv.org/abs/1802.05365) [cs.CL]. Disponível em: <<https://arxiv.org/abs/1802.05365>>.
- PLUTCHIK, Robert. The Emotions: Facts, Theories and a New Model. *New York: Random House*, 1962.
- _____. A general psychoevolutionary theory of emotion. *Emotion: Theory, research, and experience*, v. 1, 1980.
- _____. The nature of emotions: Human emotions have deep evolutionary roots, a fact that may explain their complexity and provide tools for clinical practice. *American scientist*, JSTOR, v. 89, n. 4, p. 344–350, 2001.
- POTAMIAS, Rolandos Alexandros; SIOLAS, Georgios; STAFYLOPATIS, Andreas-Georgios. A transformer-based approach to irony and sarcasm detection. *Neural Computing and Applications*, Springer, v. 32, p. 17309–17320, 2020.

- RANGWANI, Harsh; KULSHRESHTHA, Devang; SINGH, Anil Kumar. NLPRL-IITBHU at SemEval-2018 task 3: Combining linguistic features and emoji pre-trained CNN for irony detection in Tweets. In: PROCEEDINGS of the 12th international workshop on semantic evaluation. 2018. p. 638–642.
- REIMERS, Nils; GUREVYCH, Iryna. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In: PROCEEDINGS of the 2019 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, nov. 2019. Disponível em: <<http://arxiv.org/abs/1908.10084>>.
- _____. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation. *arXiv preprint arXiv:2004.09813*, abr. 2020. Disponível em: <<http://arxiv.org/abs/2004.09813>>.
- REYES, Antonio; ROSSO, Paolo; VEALE, Tony. A multidimensional approach for detecting irony in twitter. *Language resources and evaluation*, Springer, v. 47, n. 1, p. 239–268, 2013.
- SARDINHA, Tony Berber. *Linguística de corpus*. Editora Manole Ltda, 2004.
- SHOEB, Abu Awal Md; MELO, Gerard de. EmoTag1200: Understanding the Association between Emojis and Emotions. In _____. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Online: Association for Computational Linguistics, nov. 2020. p. 8957–8967. DOI: [10.18653/v1/2020.emnlp-main.720](https://doi.org/10.18653/v1/2020.emnlp-main.720). Disponível em: <<https://aclanthology.org/2020.emnlp-main.720>>.
- SOUZA, Fábio; NOGUEIRA, Rodrigo; LOTUFO, Roberto. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: 9TH Brazilian Conference on Intelligent Systems, BRACIS, Rio Grande do Sul, Brazil, October 20-23 (to appear). 2020.
- SPARCK JONES, Karen. A statistical interpretation of term specificity and its application in retrieval. *Journal of documentation*, MCB UP Ltd, v. 28, n. 1, p. 11–21, 1972.

- SPERBER, Dan; WILSON, Deirdre. Irony and the use-mention distinction. *Philosophy*, University College of London Inglaterra, v. 3, p. 143–184, 1981.
- SRIVASTAVA, Himani et al. A novel hierarchical BERT architecture for sarcasm detection. In: PROCEEDINGS of the Second Workshop on Figurative Language Processing. 2020. p. 93–97.
- STRAPPARAVA, C. WordNet-Affect: an affective extension of WordNet. In: PROCEEDINGS of the 4th International Conference on Language Resources and Evaluation (LREC 2004). 2004.
- SZEGEDY, Christian et al. Going deeper with convolutions. In: PROCEEDINGS of the IEEE conference on computer vision and pattern recognition. 2015. p. 1–9.
- TANNEN, Deborah. What's in a frame? Surface evidence for underlying expectations. *Framing in discourse*, v. 14, p. 56, 1993.
- TAUSCZIK, Yla R; PENNEBAKER, James W. The psychological meaning of words: LIWC and computerized text analysis methods. *Journal of language and social psychology*, Sage Publications Sage CA: Los Angeles, CA, v. 29, n. 1, p. 24–54, 2010.
- TOUVRON, Hugo et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- TSOUMAKAS, Grigorios; KATAKIS, Ioannis; VLAHAVAS, Ioannis. Mining Multi-label Data. In: *Data Mining and Knowledge Discovery Handbook*. Edição: Oded Maimon e Lior Rokach. Boston, MA: Springer US, 2010. p. 667–685. ISBN 978-0-387-09823-4. DOI: [10.1007/978-0-387-09823-4_34](https://doi.org/10.1007/978-0-387-09823-4_34). Disponível em: https://doi.org/10.1007/978-0-387-09823-4_34.
- TURING, Alan Mathison. Mind. *Mind*, v. 59, n. 236, p. 433–460, 1950.
- UTSUMI, Akira. A unified theory of irony and its computational formalization. In: COLING 1996 Volume 2: The 16th International Conference on Computational Linguistics. 1996.

- UTSUMI, Akira. Verbal irony as implicit display of ironic environment: Distinguishing ironic utterances from nonirony. *Journal of pragmatics*, Elsevier, v. 32, n. 12, p. 1777–1806, 2000.
- VAN DER MAATEN, Laurens; HINTON, Geoffrey. Visualizing data using t-SNE. *Journal of machine learning research*, v. 9, n. 11, 2008.
- VAN HEE, Cynthia; LEFEVER, Els; HOSTE, Véronique. Semeval-2018 task 3: Irony detection in english tweets. In: PROCEEDINGS of The 12th International Workshop on Semantic Evaluation. 2018. p. 39–50.
- _____. We usually don't like going to the dentist: Using common sense to detect irony on Twitter. *Computational Linguistics*, MIT Press One Rogers Street, Cambridge, MA 02142-1209, USA journals-info ..., v. 44, n. 4, p. 793–832, 2018.
- VASWANI, A. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.
- VEALE, Tony; HAO, Yanfen. Detecting ironic intent in creative comparisons. In: ECAI 2010. IOS Press, 2010. p. 765–770.
- VU, Thanh et al. Nihrio at semeval-2018 task 3: A simple and accurate neural network model for irony detection in twitter. *arXiv preprint arXiv:1804.00520*, 2018.
- WALLACE, Byron C. Computational irony: A survey and new perspectives. *Artificial intelligence review*, Springer, v. 43, n. 4, p. 467–483, 2013.
- WALLACE, Byron C; CHARNIAK, Eugene et al. Sparse, contextually informed models for irony detection: Exploiting user communities, entities and sentiment. In: PROCEEDINGS of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2015. p. 1035–1044.
- WALLACE, Byron C; KERTZ, Laura; CHARNIAK, Eugene et al. Humans require context to infer ironic intent (so computers probably do, too). In: PROCEEDINGS of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2014. p. 512–516.

- WANG, Zelin et al. Twitter sarcasm detection exploiting a context-based model. In: SPRINGER. INTERNATIONAL conference on web information systems engineering. 2015. p. 77–91.
- WANKHADE, Mayur; RAO, Annavarapu Chandra Sekhara; KULKARNI, Chaitanya. A survey on sentiment analysis methods, applications, and challenges. *Artificial Intelligence Review*, Springer, v. 55, n. 7, p. 5731–5780, 2022.
- WILSON, Deirdre; SPERBER, Dan. On verbal irony. *Lingua*, v. 87, n. 1, p. 53–76, 1992.
- WU, Chuhan et al. Thu_ngn at semeval-2018 task 3: Tweet irony detection with densely connected lstm and multi-task learning. In: PROCEEDINGS of The 12th International Workshop on Semantic Evaluation. 2018. p. 51–56.
- XING, Linjie et al. Convolutional Character Networks. In: PROCEEDINGS of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019.
- XU, Peng et al. Emo2Vec: Learning Generalized Emotion Representation by Multi-task Training. In: _____. *Proceedings of the 9th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis*. Brussels, Belgium: Association for Computational Linguistics, out. 2018. p. 292–298. DOI: [10.18653/v1/W18-6243](https://doi.org/10.18653/v1/W18-6243). Disponível em: <https://aclanthology.org/W18-6243>.
- YAGHOUBIAN, Hamed; ARABNIA, Hamid R; RASHEED, Khaled. Sarcasm detection: A comparative study. *arXiv preprint arXiv:2107.02276*, 2021.
- YANG, Zhilin. XLNet: Generalized Autoregressive Pretraining for Language Understanding. *arXiv preprint arXiv:1906.08237*, 2019.
- ZEILER, Matthew D; FERGUS, Rob. Visualizing and understanding convolutional networks. In: SPRINGER. COMPUTER Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6–12, 2014, Proceedings, Part I 13. 2014. p. 818–833.

- ZHANG, Ruoyu et al. Medical named entity recognition based on dilated convolutional neural network. *Cognitive Robotics*, v. 2, p. 13–20, 2022. ISSN 2667-2413. DOI: <https://doi.org/10.1016/j.cogr.2021.11.002>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2667241321000197>>.
- ZHANG, Shiwei et al. Irony detection via sentiment-based transfer learning. *Information Processing & Management*, Elsevier, v. 56, n. 5, p. 1633–1644, 2019.
- ZHANG, Xiang; ZHAO, Junbo; LECUN, Yann. Character-level Convolutional Networks for Text Classification. In_____. *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2015. v. 28. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2015/file/250cf8b51c773f3f8dc8b4be867a9a02-Paper.pdf>.
- ZHU, Yuying; WANG, Guoxin; KARLSSON, Börje F. *CAN-NER: Convolutional Attention Network for Chinese Named Entity Recognition*. 2020. arXiv: 1904.02141 [cs.CL]. Disponível em: <<https://arxiv.org/abs/1904.02141>>.

Apêndices

A | Manual de Anotação

A.1 Manual de Anotação do corpus TwIronia

O TwIronia é um corpus composto de tweets em português coletados entre os anos de 2020-2021 com o objetivo de ser usado para a tarefa de detecção automática de ironia. Os tweets foram coletados a partir de um conjunto de palavras-chave relacionadas aos temas Saúde, Entretenimento e Política. O conjunto completo de palavras-chaves adotadas está no Anexo 1 deste manual. A busca por tweets irônicos foi guiada por *hashtags* – “#ironia”, “#sarcasmo” e “#sqn” (abreviação para a expressão “só que não”) – usadas pelo usuário para marcar a presença de ironia. Também foram coletados tweets sobre os mesmos temas que não contêm nenhuma dessas *hashtags*. Além dos tweets-alvo a serem classificados, também foi coletado o seu contexto de ocorrência, dado pelo tweet que o antecede em uma conversa, como no Exemplo (1).

1-T1 Comissão rejeita projeto de lei para porte de arma em voo, proposta por Eduardo Bolsonaro <URL>

1-T2 Recessão, fome, desemprego e pandemia. Essa família está focada nos problemas reais #sqn

O exemplo acima é uma tupla de textos composta de um Turno 1 (T1), que é o contexto, e um Turno 2 (T2), que é o texto-alvo que deverá ser classificado. Em (1-T2), o usuário usou a *hashtag* “#sqn” para marcar ironia.

O objetivo deste manual é fornecer instruções para a classificação dos tweets-alvo em “irônico” ou “não-irônico”. O corpus será anotado **apenas** com relação aos tweets do Turno 2 (T2). O Turno 1 (T1) não será classificado,

mas deve ser usado pelos anotadores para a identificação de pistas a respeito da classificação do tweet-alvo. Desse modo, não importa se T1 é ou não irônico.

A.1.1 Ironia: definição e exemplos

São considerados irônicos textos que evidenciam uma incongruência de sentidos entre o que é dito e o que é interpretado. A incongruência pode ser desencadeada por uma única palavra, partes do texto ou mesmo em relação ao que foi dito no turno anterior. Exemplos:

2-T1 tentei convencer meu padrasto a me ensinar a jogar lol mas ele disse que eu vou ficar viciadinha kkkkk

2-T2 Errado ele n tá pq eu **jogo a 8 anos todos dias e n sou viciado**, #sqn kkkkkkkkkkkkkkkkk

3-T1 Em meio a aumento da Covid-19, Bolsonaro diz que medidas de isolamento podem levar ao 'caos' <URL>

3-T2 Isolamento pode levar ao caos. **Milhares de mortes por COVID podem levar à ordem e progresso.** #SQN

O texto em negrito nos exemplos (2) e (3) indica a parte que traz uma incongruência de interpretação. Em (2), a incongruência está entre “jogar todos os dias” e “ser viciado”, ou seja, jogar todos corresponde a um comportamento de alguém viciado. A utilização de risadas ao fim do tweet reforça a presença da ironia nesse caso, assim como o usuário começa o texto com “Errado ele n tá”. Já em (3), temos uma incongruência entre “milhares de mortes por COVID” e “ordem e progresso”, tendo em vista que não é coerente falar em progresso quando milhares de pessoas estão morrendo por causa de uma doença. A construção da ironia fica evidente pela retomada do discurso citado de Bolsonaro em (3-T1) (“isolamento pode levar ao caos”) de forma a ironizar sua fala.

Para ser classificado como irônico, é preciso que pelo menos uma parte do texto seja irônica, não necessariamente o texto inteiro. Em determinados

casos, a ironia vai ser desencadeada por uma única palavra, como nos exemplos a seguir.

4-T1 Meta de vida: tirar as férias do @CaioCastro 😎 Além dos passeios românticos com a amada, Grazi Massafera, o ator está fazendo aulas de mergulho avançado em Fernando de Noronha → <URL> #Gshow-Famosos <URL>

4-T2 Aglomeração em plena segunda onda, pesca em área de preservação, ameaçando coral... **bonito** #sqn

5-T1 Bolsonaro faz live com Ernesto Araújo e diz que “política externa está excepcional” <URL>

5-T2 Com certeza! Bem como a educação e a saúde!!! Aliás o Brasil vai de vento em popa... #sqn

No exemplo (4), a palavra “bonito” é aquela que indica a presença de ironia no texto. Já em (5), somente a *hashtag* “#sqn” indica ironia, pois sem ela não teria nenhuma marca textual de ironia. A utilização de múltiplas interrogações pode ser uma pista, mas não é forte o suficiente, já que poderia ser algum apoiador de Bolsonaro falando de maneira sincera.

Por fim, nem todos os exemplos de ironia serão marcados por *hashtags*. Alguns tweets que não apresentam as *hashtags* irônicas podem ser irônicos. Exemplo:

6-T1 Para o bem da saúde e o combate à corrupção a **#DireitaQuerImpeachment** do 🐭Bolsonaro🐭...

6-T2 **Se preocupem não**, eu soube que bolsonaro vai sair SÓ QUE NO FINAL DE 2026 kkkkkkkkkk

No exemplo (6), temos um caso de ironia que o usuário não sinalizou com nenhuma *hashtag*. Em (6-T1), o usuário pede o impeachment de Bolsonaro, ao que (6-T2) responde ironicamente que ele vai sair, mas apenas em 2026. Veja que o texto começa irônico dizendo “se preocupem não” e ainda termina com uma expressão de riso (“kkk”). Portanto, trata-se claramente de uma ironia.

7-T1 Milhões de brasileiros e brasileiras choram seus mortos todos os dias. Passamos a França e **somos o quarto país no mundo em números de vítimas pelo Coronavírus**. Minha solidariedade às famílias dos mais de 28.800 mortos. **Não temos governo, seguimos sem rumo**.

7-T2 Pois é! É culpa do governo de Bolsonaro que a saúde está péssima! Que esse vírus veio da China ou **veio do condomínio dele! Vai lá fazer estádios! É mais útil !**

Em (7), também vemos um tweet irônico que não apresenta *hashtags*. No primeiro tweet, o usuário cita o número de mortos por covid-19 e critica: “Não temos governo, seguimos sem rumo”. O usuário em (7-T2) concorda, mas está sendo irônico. Quando ele diz “Que esse vírus veio da China ou veio do condomínio dele” (se referindo a Bolsonaro), vemos a incongruência, pois ninguém acusou o Bolsonaro de ter produzido o vírus. Além disso, a ironia continua em “Vá lá fazer estádios! É mais útil”, o que é se relaciona ao governo de Lula, cujo usuário parece culpar pela saúde estar ruim. Desse modo, nem todos os tweets irônicos serão marcados com *hashtags* de ironia (#sqn, #ironia e #sarcasmo).

A.1.2 Não-ironia: definição e exemplos

Textos em que não há indícios de incongruência de sentidos entre o que é dito e o que é interpretado serão considerados não-irônicos. Assim como nos exemplos irônicos, os não-irônicos são compostos de uma tupla com Turno 1 (T1) e Turno 2 (T2). Exemplos:

8-T1 O Atila vai ter seu celular apreendido pelo Moraes por espalhar fake news de um milhão de mortos no Brasil pelo vírus chinês?

8-T2 Não: ele espalhou uma *projeção*, que teria sido verdade caso os estados não tivessem agido e caso o Mandetta não tivesse agido apesar do presidente.

9-T1 O que acontece com a Clotilde nas versões anteriores? Ô mulher pra sofrer viu

9-T2 No livro ela termina sozinha. Mas na versão 94 do SBT ela termina feliz ao lado de Almeida.

10-T1 Apenas traço um cenário: do jeito que a coisa anda caminhando, o PT e o Centrão apoiarão @jairbolsonaro para derrotar @SF_Moro. A canalhada da política se unirá “defendendo” a Constituição. Será a prova final do fracasso da democracia no Brasil. Deus nos proteja.

10-T2 Bolsonaro já é favorito. Imagina com a economia recuperando. Quem apoiar vai ser pra pegar carona. Moro se queimou com sua traição. Se lascou sozinho.

Os exemplos (8), (9) e (10) são não-irônicos, pois os textos não apresentam nenhum indício de contradição entre o sentido literal e a interpretação.

Em determinados casos, o usuário pode ter usado uma *hashtag* irônica, mesmo que o texto seja não-irônico. Entre elas, a *hashtag* mais problemática no corpus é #sqn, que pode ter mais de uma utilização no Twitter, nem sempre sendo usada para indicar ironia. Exemplos:

11-T1 Amanhã é pra ser o dia que nossos deputados fazem uma representação em algum órgão do judiciário contra os partidos de esquerda que CONVOCARAM E PARTICIPARAM dos atos de TERRORISMO praticados em São Paulo

11-T2 #issoaglobonaomostre gente do “bem” fazendo atos democrático. Depois fica de mimi contra o Bolsonaro e ainda querem ganhar em 2022. #SQN segue o jogo #LulaNaCadeia”

O exemplo (11) não traz uma ironia, pois não apresenta uma incongruência entre o que é dito e o que é interpretado. No caso, a *hashtag* “#sqn” é usada para contrastar a sentença que a antecede, não para negar o seu sentido, mas expressar algo como “querem ganhar em 2022, mas não vão”.

12-T1 Jair Bolsonaro ficará marcado para sempre como o presidente que não cuidou nem da saúde nem da economia durante a pandemia.

12-T2 🤔🤔🤔🤔🤔 vcs são idiotas achando q estão falando com idiotas.
#sqn Bolsonaro. Melhor remédio contra esquerdopatas.

Em (12), temos o mesmo caso do anterior. O usuário utiliza “#sqn” para contrapor o que foi dito anteriormente, significando “acham que estão falando com idiotas, mas não somos idiotas”. Vemos que não há nenhum tipo de incongruência entre o que é dito e o que é interpretado, portanto não se trata de uma ironia.

A.1.3 Instruções para anotação

A anotação será feita em uma planilha no Google Planilhas composta por cinco colunas (ID, Turno 1, Turno 2, Classificação e Observação), como mostra a Figura A.1 Todas as URLs foram substituídas por “<URL>” para evitar que os anotadores cliquem em links para obter informações externas ao texto, uma vez que durante o pré-processamento os links serão removidos.

A	B	C	D	E
ID	Turno 1	Turno 2	Classificação	Observação
1364734779233550338	*Fundamentalmente, é para evitar eventos, aglomerações. Quando as pessoas bebem e perdem o controle, perdem a capacidade de usar suas máscaras, expõem o vírus, multiplicam a contaminação e ampliam a possibilidade de óbitos”. João Dória Não é. Hoje é o último jogo do São Paulo na Era Leco. • 5 anos • 9 treinadores • Mais de 200 milhões em reforços • 16 eliminações • 0 títulos • Dívidas aumentaram em quase 300 milhões	QUE BELEZA. #sqn Aqui no Paraná a justificativa foi essa - das mortes e acidentes violentos. Citaram os nº, demanda de atendimento de emergência, as vagas de UTI, stress dos médicos, etc. Depois de um tempo verificaram queda significativa. Bem interessante.		
1344432937681510406	Até nunca mais. <URL> Sargento da PM condenado por chefiar milícia é solto pela Justiça e apresenta candidatura a vereador <URL> <URL>	Se eu fosse presidente, a primeira coisa que faria seria zerar essa dívida, depois que zerar a dívida, TUDO é lucro. Da pra fazer tudo sem pensar em guardar dinheiro pra pagar dívida		
1306275189957824513	GIZELLY É DO MAL, UMA MULHER AMARGURADA!!!	Criminosos entrando na política, que novidade... #SQN! Este o 'normal' neste paiseco de 7o mundo!		
	*AINDA BEM QUE O PRIOR SAIU" "FLAY VAI SAIR AGORA"	A Gizelly tá em um JOGO + não pode torcer q NÃO ganhe quem indica ela p/ o paredão? Não pode ficar aliviada se quem a indica saiu da prova?Realmente,pecado terrível a Gi		

Figura A.1: Exemplo da tabela de anotação.

A coluna “ID” traz o número de identificação do tweet, que serve para a recuperação do tweet, caso seja necessário. A coluna “Turno 1” traz os textos que representam o contexto conversacional (T1). A coluna “Turno 2” contém os tweets que serão classificados, (T2) nos exemplos. A coluna “Classificação” será preenchida com as classificações dos tweets. Por fim, a coluna “Observação” é destinada a comentários quando o anotador estiver em dúvida sobre a classificação.

Para a anotação, os anotadores deverão seguir os seguintes passos:

1. Ler o contexto (coluna Turno 1) e o texto (coluna Turno 2). É importante ler os dois para ter certeza a respeito da classificação e evitar erros.
2. Classifique o texto contido na coluna Turno 2 usando as etiquetas «ironia» ou «não ironia», inserindo-a na coluna Classificação.

A classificação dos textos deve ser feita com base nas definições apresentadas neste manual, que deverá servir de base para a anotação, portanto é importante consultá-lo sempre que necessário. Em caso de dificuldade ou dúvida, deve-se classificar o texto com a classificação que parece mais aceitável (coluna “Classificação”) e deixar algum comentário (coluna “Observações”) a respeito da dúvida na classificação, como mostra na Figura A.2.

A	B	C	D	E
ID	Turno 1	Turno 2	Classificação	Observação
1341713655189168128	perdoem o delay, mas se o lphan-PA aprovou aquela aberração da prefeitura na João Alfredo, tem mais coisas muito erradas pra serem denunciadas e corrigidas nessa história	enterrar sob o concreto parte da história é o último feito do prefeito Zenaldo Coutinho p/ demonstrar o quanto ele aprecia #sgn Belém. essa prefeitura foi movida por valores sinônimos: gentrificação e violência simbólica. se isso já não era um protobolconarismo em plena atividade	ironia	parece ambiguo
1418305791644381184	Nem eu...não faz sentido isso. Acho que eles se garantem na fidelidade da galera...mas esse preço é exagero.	Para convencer seus assinantes a ficar e atrair novos, o streaming destaca o cardápio de novidades prometidas para os próximos meses, como a última temporada de "La Casa de Papel" haha agora eu fico #sgn <URL>	ironia	

Figura A.2: Exemplo de anotação em caso de dúvida.

IMPORTANTE!

Não utilize informações externas para a classificação do texto, como buscas na Web ou imagens/gifs contidos no tweet.

Não faça extrapolações baseadas em informações a respeito de acontecimentos/fatos/pressuposições que não estão no texto ou contexto.

B | Lista de abreviações

Abreviação	Transcrição	Abreviação	Transcrição
adm	administrador	ngm	ninguém
adms	administradores	obg	obrigada
agr	agora	oq	o que
amg	amigo	p	para
app	aplicativo	pfv	por favor
bj	beijo	plmdds	pelo amor de deus
bjs	beijos	pls	por favor
blz	beleza	pq	porque
br	Brasil	pqp	puta que pariu
c	com	pra	para
cê	você	pro	para o
cmg	comigo	pse	pois é
ctz	certeza	pv	privado
d+	demais	q	que
dnv	de novo	qd	quando
doq	do que	qdo	quando
dps	depois	qq	qualquer
dsd	desde	qqr	qualquer
ent	então	qt	quanto
fav	favorito	qta	quanta
fdp	filho da puta	qtas	quantas
fml	família	qto	quanto
ft	foto	qtos	quantos

fut	futebol	rlx	relaxa
fzd	fazendo	rpz	rapaz
fzr	fazer	sdds	saudades
gnt	gente	sla	sei lá
hj	hoje	slk	você é louco
hrs	horas	smt	se mata
jss	jesus	tá	está
krl	caralho	tamo	estamos
mds	meu deus	tb	também
mn	mano	tbm	também
msg	mensagem	td	tudo
msm	mesmo	tlgd	está ligado
mt	muito	tmj	estamos juntos
mta	muita	tô	estou
mtas	muitas	vc	você
mto	muito	vcs	vocês
mtos	muitos	vdd	verdade
mts	muitos	vlw	valeu
n	não	vms	vamos
ñ	não	vsf	vai se foder
nd	nada	vtnc	vai tomar no cu

Tabela B.1: Lista de abreviações e suas respectivas transcrições.

C | Traduções para as emoções de Plutchik

C.0.1 Emoção: Anger

Linguee: raiva, ira, ódio, cólera, fúria, irritação, zanga, revolta, furor.

Cambridge: raiva, braveza.

Collins: raiva.

Michaelis: raiva, ira, fúria, cólera, ódio.

C.0.2 Emoção: Anticipation

Linguee: antecipação, expectativa, ansiedade.

Cambridge: expectativa.

Collins: expectativa, entusiasmo.

Michaelis: 1 antecipação, adiantamento; 2 intuição, previsão, preconcepção, pressentimento; 3 conhecimento antecipado; 4 prevenção; 5 expectativa, prelibação, antegoço.

C.0.3 Emoção: Disgust

Linguee: repugnância, nojo, aversão, asco, repulsa, desagrado.

Cambridge: repugnância, asco, revolta, nojo.

Collins: repugnância.

Michaelis: desgosto, aversão, fastio, náusea, repugnância, asco, ódio.

C.0.4 Emoção: Fear

Linguee: medo, receio, temor, pavor, terror, ansiedade, insegurança.

Cambridge: medo, temor.

Collins: medo, temor.

Michaelis: 1 medo, temor, susto, receio, apreensão: *there is no fear of his forgetting* / não há perigo de que ele esqueça; 2 terror, pavor: *to put the fear of God into someone* / intimidar alguém, ameaçar alguém com uma punição severa; 3 preocupação, ansiedade: *he goes in constant fear of his life* / ele está em constante receio pela sua vida; 4 pessoa ou coisa que causa medo; 5 reverência, respeito.

C.0.5 Emoção: Joy

Linguee: alegria, felicidade, regozijo, gozo, prazer, satisfação, júbilo, gosto, agrado, contentamento, deleite, regalo, entusiasmo, deleitamento, deleitação, comprazimento.

Cambridge: alegria, deleite.

Collins: alegria.

Michaelis: 1 alegria, contento, regozijo, júbilo: *she leapt for joy* / ela pulou de alegria; 2 prazer, contentamento, felicidade: *I wish you joy* / desejo-lhe felicidades: *it gives me great joy* / dá-me grande prazer; 3 encanto, arrebatamento, êxtase; 4 pessoa amada.

C.0.6 Emoção: Sadness

Linguee: tristeza, pesar, pena.

Cambridge: tristeza.

Collins: tristeza.

Michaelis: tristeza, melancolia.

C.0.7 Emoção: Surprise

Linguee: surpresa, espanto, estranheza, perplexidade.

Cambridge: surpresa.

Collins: surpresa, assombro.

Michaelis: 1 surpresa, coisa inesperada: *I got the surprise of my life* / foi uma surpresa para mim; 2 sobressalto; 3 emoção, perplexidade, pasmo.

C.0.8 Emoção: Trust

Linguee: confiança, fundo, truste, fideicomisso, confiabilidade, consórcio, fé, crédito, fiabilidade, cuidados, encargo.

Cambridge: ter confiança em, acreditar em.

Collins: confiança, responsabilidade, truste, fideicomisso.

Michaelis: 1 confiança, crença, fé, confiança: *I put (place, have) great trust in you* / confio em você, tenho fé na sua pessoa: *there is no trust to be placed in him* / não se pode ter confiança nele; 2 pessoa ou coisa em que se confia; 3 esperança; 4 crédito; 5 obrigação, responsabilidade, cargo, dever; 6 guarda, cuidado; 7 Jur. fideicomisso, procurador em confiança; 8 monopólio, truste; 9 cartel, sindicato; 10 depósito em custódia, custódia.